

矩阵分解



2023-2024学年第一学期

课程编码：03521003

主讲：董晓东

目录



1. 矩阵的 LU 分解
2. 矩阵的 QR 分解
3. 矩阵的奇异值分解

3.1 矩阵的 LU 分解



类似于数的因子分解、代数式的因式分解，矩阵的各种分解在矩阵计算中也扮演相当重要的角色。由于变换即矩阵，所以**各种分解从根本上看是各种变换**，其目的是将矩阵变换成特殊的矩阵，比如特征值分解的对角矩阵、Jordan分解的Jordan矩阵、Schur分解的上三角阵，等等。将分解用于数值计算缓慢出现在电子计算机诞生之后。最早是Dwyer（1951），然后是Householder（1964）和Wilkinson（1965）

3.1 矩阵的 LU 分解



许多分解源自十九世纪对二次型和双线性型的研究。LU分解源自Gauss处理表示最小二乘问题的对称正定系统时所使用的消元法，确切地说，Gauss使用的是分解。对于双线性型，则归功于Jacobi（1857）。Dwyer（1944）最早注意到消元法与其矩阵表示间的联系。

本节介绍矩阵的LU分解可用于求行列式、逆矩阵、解线性方程组等。

3.1 矩阵的 LU 分解



首先回顾在线性代数中学的初等矩阵的概念。设 A 是 $m \times n$ 的矩阵， E 是 $m \times m$ 的初等矩阵， A 左乘 E ，即是对 A 作相应的初等行变换，下面以 $m=2$ 为例给出初等矩阵的形式。

3.1 矩阵的 LU 分解



$r_1 \leftrightarrow r_2$ 对应的初等矩阵是 $E = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$

αr_1 对应的初等矩阵是 $E = \begin{pmatrix} \alpha & 0 \\ 0 & 1 \end{pmatrix}$

$r_2 + \alpha r_1$ 对应的初等矩阵是 $E = \begin{pmatrix} 1 & 0 \\ \alpha & 1 \end{pmatrix}$

3.1 矩阵的 LU 分解



初等矩阵都是非奇异的，且它的逆即是它定义的初等变换的逆变换。

奇异矩阵就是该矩阵的秩不是满秩的矩阵。

首先，看这个矩阵是不是方阵（即行数和列数相等的矩阵，若行数和列数不相等，那就谈不上奇异矩阵和非奇异矩阵）。然后，再看此矩阵的行列式 $|A|$ 是否等于0，若等于0，称矩阵 A 为奇异矩阵；若不等于0，称矩阵 A 为非奇异矩阵。同时，由 $|A| \neq 0$ 可知矩阵 A 可逆，这样可以得出另外一个重要结论：可逆矩阵就是非奇异矩阵，非奇异矩阵也是可逆矩阵。如果 A 为奇异矩阵，则 $AX=0$ 有无穷解， $AX=b$ 有无穷解或者无解。如果 A 为非奇异矩阵，则 $AX=0$ 有且只有唯一零解， $AX=b$ 有唯一解。

3.1 矩阵的 LU 分解



$$r_1 \leftrightarrow r_2 \text{ 的逆变换为 } r_2 \leftrightarrow r_1 \quad E^{-1} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

$$\alpha r_1 \text{ 的逆变换为 } \alpha^{-1} r_1 \quad E^{-1} = \begin{pmatrix} \alpha^{-1} & 0 \\ 0 & 1 \end{pmatrix}$$

$$r_2 + \alpha r_1 \text{ 的逆变换为 } r_2 - \alpha r_1 \quad E^{-1} = \begin{pmatrix} 1 & 0 \\ -\alpha & 1 \end{pmatrix}$$

3.1 矩阵的 LU 分解



若用Gauss消去法将矩阵 A 转化成一个阶梯形矩阵 U ，相应的初等变换对应的矩阵为 $E_1, \dots, E_r$ ，则

$$E_r \cdots E_1 A = U$$

3.1 矩阵的LU分解

例 1 求解线性方程组

$$\begin{cases} x_1 + 2x_2 - x_3 = 0 & \text{①} \\ 3x_1 + x_2 = -1 & \text{②} \\ -x_1 - x_2 - 2x_3 = 1 & \text{③} \end{cases} \quad (I)$$

解:

$$(I) \xrightarrow[\text{1} \times \text{①} + \text{③}]{(-3) \times \text{①} + \text{②}} \begin{cases} x_1 + 2x_2 - x_3 = 0 & \text{①} \\ -5x_2 + 3x_3 = -1 & \text{②} \\ x_2 - 3x_3 = 1 & \text{③} \end{cases}$$

3.1 矩阵的LU分解

$$\xrightarrow{\frac{1}{5} \times \textcircled{2} + \textcircled{3}} \begin{cases} x_1 + 2x_2 - x_3 = 0 & \textcircled{1} \\ -5x_2 + 3x_3 = -1 & \textcircled{2} \\ -\frac{12}{5}x_3 = \frac{4}{5} & \textcircled{3} \end{cases}$$

$$\xrightarrow[\frac{3}{5} \times \textcircled{3} + \textcircled{2}]{(-\frac{5}{12}) \times \textcircled{3}} \begin{cases} x_1 + 2x_2 = -1/3 & \textcircled{1} \\ x_2 = 0 & \textcircled{2} \\ x_3 = -1/3 & \textcircled{3} \end{cases}$$

$$\xrightarrow{(-2) \times \textcircled{2} + \textcircled{1}} \begin{cases} x_1 = -1/3 & \textcircled{1} \\ x_2 = 0 & \textcircled{2} \\ x_3 = -1/3 & \textcircled{3} \end{cases} \quad (II)$$

3.1 矩阵的LU分解

用矩阵形式表示，系数矩阵

$$A = \begin{bmatrix} 1 & 2 & -1 \\ 3 & 1 & 0 \\ -1 & -1 & -2 \end{bmatrix} \xrightarrow[r_{13}(1)]{r_{12}(-3)} \begin{bmatrix} 1 & 2 & -1 \\ 0 & -5 & 3 \\ 0 & 1 & -3 \end{bmatrix}$$

$$\xrightarrow{r_{23}(\frac{1}{5})} \begin{bmatrix} 1 & 2 & -1 \\ 0 & -5 & 3 \\ 0 & 0 & -12/5 \end{bmatrix} \equiv U$$

3.1 矩阵的LU分解

$$R_{23}(\frac{1}{5})R_{13}(1)R_{12}(-3)A = U.$$

$$\begin{aligned} A &= [R_{23}(\frac{1}{5})R_{13}(1)R_{12}(-3)]^{-1}U \\ &= [R_{12}(-3)]^{-1}[R_{13}(1)]^{-1}[R_{23}(\frac{1}{5})]^{-1}U \\ &= R_{12}(3)R_{13}(-1)R_{23}(\frac{-1}{5})Q \equiv LU \end{aligned}$$

$$= \begin{bmatrix} 1 & 0 & 0 \\ 3 & 1 & 0 \\ -1 & -1/5 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & -1 \\ 0 & -5 & 3 \\ 0 & 0 & -12/5 \end{bmatrix}$$

3.1 矩阵的LU分解



这就是Gauss提出消元法100多年后才被Dwyer注意到的LU分解：

$$A = LU$$

据此，有

$$Ax = LUx = L(Ux) = b$$

因此可通过求解两个特殊的三角方程组

$$Ly = b, Ux = y$$

来求解线性方程组
用的方法。

$$Ax = b$$
，这就是数值软件中采

3.1 矩阵的 LU 分解



定义 如果方阵 A 可以分解成一个**单位下三角矩阵** L 与一个上三角矩阵 U 的乘积

$$A = LU$$

则称其为 A 的 **LU 分解**或**三角分解**。

3.1 矩阵的 LU 分解



定理 设 A 是 $m \times n$ 的矩阵, 则存在
置换矩阵 P 使得

$$PA = LU$$

其中 L 是 $m \times m$ 单位下三角阵, U 是
 $m \times n$ 的阶梯形矩阵。

3.1 矩阵的 LU 分解



定义 设 A 是 $m \times n$ 的矩阵, 如果 A (或 A 的某个排列 PA) 可分解为 $A = LU$ (或 $PA = LU$), 其中 L 是单位下三角阵, U 是阶梯形矩阵, 则称此分解为 A 的 *Doolittle* 分解, 如果 A (或 PA) 可分解为 $A = LU$ (或 $PA = LU$), 其中 L 是下三角矩阵, U 是非零对角元均为1的阶梯形矩阵, 则称此分解为 A 的 *Crout* 分解.

3.1 矩阵的 LU 分解



定理 设 A 是 $n \times n$ 的对称正定矩阵,
则存在 $n \times n$ 的下三角阵 L 使得

$$A = LL^T$$

此分解称为矩阵 A 的 Cholesky 分解。

3.1 矩阵的 LU 分解



矩阵的 LU 分解最常应用于求解线性方程组 $Ax = b$ ，首先我们作分解 $PA = LU$ ，然后求解方程组 $LUx = Pb$ ，求解过程分两步进行：

(1) 首先解线性方程组 $Ly = Pb$ ，可得

$$y = L^{-1}Pb$$

(2) 接着计算原方程组的解 $x = U^{-1}y$ ，

即求解方程组 $Ux = y$ 。

3.1 矩阵的 LU 分解



看到上面的求解，大家可能会产生疑问，既然矩阵的 LU 分解可由 Gauss 消去法得到，为什么不在消去的过程中直接解方程组呢？为什么要先进行 LU 分解，然后再解两个三角方程组呢？

3.1 矩阵的 LU 分解



其原因是在实际工作中，有时会出现这样的情况：线性方程组的系数矩阵不变而右端项发生了变化，若此时已经得到了系数矩阵 LU 的分解，则当右端项发生变化时，只需求解两个三角方程组即可（ $Ly = Pb$ ， $Ux = y$ ），而不必重新进行Gauss消去，这样就可大大节省计算量。

3.1 矩阵的 LU 分解



下面说明在应用迭代法改进线性方程组 $Ax = b$ 的解时 LU 分解的优势。

设 $A \in R^{n \times n}$ 是满秩矩阵, $b \in R^n$, $\hat{x}$ 是由数值方法得到的 $Ax = b$ 的解。由于舍入等原因, $\hat{x}$ 不是 $Ax = b$ 的精确解, 即 $r_1 = b - A\hat{x} \neq 0$ 。下面我们通过求解线性方程组 $Ax = r_1$ 得到 a_1 来改进线性方程组的解。

3.1 矩阵的LU分解



若 a_1 是 $Ax = r_1$ 的精确解，则

$$A(\hat{x} + a_1) = A\hat{x} + Aa_1 = b - r_1 + r_1 = b$$

即 $\hat{x} + a_1$ 是 $Ax = b$ 的精确解，从而达到改进解的目的。当然很可能还存在误差，得到的是 $\hat{a}_1$ ，而不是 a_1 。此时，设 $r_2 = b - A(\hat{x} + \hat{a}_1)$ ，解线性方程组 $Ax = r_2$ ，得到 $\hat{a}_2$ ，将 $Ax = b$ 的解改进为 $\hat{x} + \hat{a}_1 + \hat{a}_2$

3.1 矩阵的 LU 分解



如此继续下去，可以证明，只要 $\text{cond}(A)$ 不是太大，序列 $\hat{x}, \hat{x} + \hat{a}_1, \hat{x} + \hat{a}_1 + \hat{a}_2, \dots$ ，最终会收敛到 $Ax = b$ 的解，通常只需迭代几步就可以得到很精确的解。

3.1 矩阵的 LU 分解



在迭代的过程中，我们求解了如下一系列方程组

$$Ax = b$$

$$Ax = r_1$$

.....

若将 A 分解成 LU ，则每次计算只需求解两个三角方程组，从而达到节省计算量的目的。

3.2 矩阵的 QR 分解



QR 分解在矩阵计算中占据相当重要的地位。利用 QR 分解，可以解决各种应用中（例如工程力学、流体力学、图像压缩处理、结构分析等）出现的最小二乘问题、特征值问题等矩阵计算中的核心问题。尤其是基于 QR 分解的 QR 算法，是求解小型稠密矩阵特征值问题的最主要的、数值稳定的算法。

3.2 矩阵的QR分解



可逆阵 A 的列向量组 $\alpha_1, \alpha_2, \dots, \alpha_n$ 构成欧氏空间 $R(A)$ 的一个基。而 Gram-Schmidt 方法实际上就是寻找正交向量序列 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_j$ ，使得

$$\text{span}(\alpha_1, \alpha_2, \dots, \alpha_j) = \text{span}(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_j)$$

即有

$$(\alpha_1, \alpha_2, \dots, \alpha_n) = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n) \begin{pmatrix} r_{11} & \cdots & r_{1n} \\ & \ddots & \vdots \\ & & r_{nn} \end{pmatrix}$$

3.2 矩阵的QR分解

使用矩阵语言，就是QR分解：

$$A = QR$$

这里， Q 是酉矩阵或正交矩阵， R 是上三角阵

此时线性方程组

$$Ax = b$$

变成

$$QRx = b$$

即三角方程组

$$Rx = Q^{-1}b = Q^H b$$

3.2 矩阵的QR分解



由Gram-Schmidt过程可知

$$(\alpha_1, \alpha_2, \dots, \alpha_j) = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_j) \begin{pmatrix} r_{11} & \cdots & r_{1j} \\ & \ddots & \vdots \\ & & r_{jj} \end{pmatrix}$$

可用矩阵表示为

$$A_j = Q_j R_j \quad (j = 1, 2, \dots, n)$$

这说明列满秩的长方阵也存在QR分解。

3.2 矩阵的QR分解



例 利用Gram-Schmidt方法将下列矩阵进行QR分解：

$$A = \begin{pmatrix} 4 & 2 & 1 \\ 2 & 0 & 1 \\ 2 & 0 & -1 \\ 1 & 2 & 1 \end{pmatrix}$$

3.2 矩阵的QR分解



解: $\alpha_1 = (4, 2, 2, 1)^T, \quad \beta_1 = \alpha_1 = (4, 2, 2, 1)^T$

$$\varepsilon_1 = \frac{\beta_1}{\|\beta_1\|_2} = (0.8, 0.4, 0.4, 0.2)^T$$

$$\beta_2 = \alpha_2 - (\alpha_2, \varepsilon_1)\varepsilon_1 = (0.4, -0.8, -0.8, 1.6)^T$$

$$\varepsilon_2 = \frac{\beta_2}{\|\beta_2\|_2} = (0.2, -0.4, -0.4, 0.8)^T$$

$$\beta_3 = \alpha_3 - (\alpha_3, \varepsilon_1)\varepsilon_1 - (\alpha_3, \varepsilon_2)\varepsilon_2 = (0, 1, -1, 0)^T$$

$$\varepsilon_3 = \frac{\beta_3}{\|\beta_3\|_2} = \frac{1}{\sqrt{2}}(0, \sqrt{2}, -\sqrt{2}, 0)^T$$

3.2 矩阵的QR分解

所以 A 的QR分解为：

$$Q = (\varepsilon_1, \varepsilon_2, \varepsilon_3) = \begin{bmatrix} 0.8 & 0.2 & 0 \\ 0.4 & -0.4 & \sqrt{2}/2 \\ 0.4 & -0.4 & -\sqrt{2}/2 \\ 0.2 & 0.8 & 0 \end{bmatrix}$$
$$R = Q^T A = \begin{pmatrix} 5 & 2 & 1 \\ 0 & 2 & 1 \\ 0 & 0 & \sqrt{2} \end{pmatrix}$$

3.2 矩阵的QR分解



Gram-Schmidt方法实质上是一种投影类方法，它将 C^m 正交投影到空间 $\text{span}(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_{j-1})^\perp$ 。在标准Gram-Schmidt方法中， $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 是逐步计算出来的，需要计算 ε_j 时，才用到 α_j ，此前不需要改动 α_j 的值。遗憾的是Gram-Schmidt迭代方法在数值上是不稳定的。

3.2 矩阵的QR分解



幸运的是，一个简单修正就可以使问题得到改进，这就是**Modified Gram-Schmidt (MGS) 方法**。

Modified Gram-Schmidt方法的想法是每当产生一个新的 ε_j 后，就重新计算所有的后续向量 $\alpha_{j+1}, \alpha_{j+2}, \dots, \alpha_{j+n}$ ，消去其中包含的 ε_j 成分（即与 ε_j 平行的分量），从而使这些改变后的后续向量都与已计算出的 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_j$ 正交。因此它实质上也是投影类方法，是**处理大规模矩阵问题的Krylov子空间投影类方法**的基础。

3.2 矩阵的QR分解



例 利用Modified Gram-Schmidt方法将下列矩阵进行QR分解：

$$A = \begin{pmatrix} 4 & 2 & 1 \\ 2 & 0 & 1 \\ 2 & 0 & -1 \\ 1 & 2 & 1 \end{pmatrix}$$

3.2 矩阵的QR分解

解：

$$\varepsilon_1 = \frac{\alpha_1}{\|\alpha_1\|_2} = (0.8, 0.4, 0.4, 0.2)^T$$
$$\alpha_2^{(1)} = \alpha_2 - (\alpha_2, \varepsilon_1)\varepsilon_1 = (0.4, -0.8, -0.8, 1.6)^T$$
$$\alpha_3^{(1)} = \alpha_3 - (\alpha_3, \varepsilon_1)\varepsilon_1 = (0.2, 0.6, -1.4, 0.8)^T$$
$$\varepsilon_2 = \frac{\alpha_2^{(1)}}{\|\alpha_2^{(1)}\|_2} = (0.2, -0.4, -0.4, 0.8)^T$$
$$\alpha_3^{(2)} = \alpha_3^{(1)} - (\alpha_3^{(1)}, \varepsilon_2)\varepsilon_2 = (0, 1, -1, 0)^T$$
$$\varepsilon_3 = \frac{\alpha_3^{(1)}}{\|\alpha_3^{(1)}\|_2} = \frac{1}{\sqrt{2}}(0, \sqrt{2}, -\sqrt{2}, 0)^T$$

3.2 矩阵的QR分解



所以 A 的QR分解为：

$$Q = (\varepsilon_1, \varepsilon_2, \varepsilon_3) = \begin{bmatrix} 0.8 & 0.2 & 0 \\ 0.4 & -0.4 & \sqrt{2}/2 \\ 0.4 & -0.4 & -\sqrt{2}/2 \\ 0.2 & 0.8 & 0 \end{bmatrix}$$

$$R = Q^T A = \begin{pmatrix} 5 & 2 & 1 \\ 0 & 2 & 1 \\ 0 & 0 & \sqrt{2} \end{pmatrix}$$

3.2 矩阵的QR分解




定理3 约化QR分解 设 $n \times k (n > k)$ 阶矩阵 A 是列满秩阵，则必存在 $n \times k$ 阶列正交矩阵 $\tilde{Q}$ ($\tilde{Q}^H \tilde{Q} = I_n$) 和非奇异上三角方阵 R ，使得矩阵 A 具有约化QR分解

$$A = \tilde{Q} R$$

注意 A 的QR分解不是唯一的!!!

3.2 矩阵的QR分解

Reduced QR Factorization ($n \geq k$)



The diagram illustrates the reduced QR factorization of a matrix A . It shows a large rectangular matrix A on the left, followed by an equals sign, then a tall rectangular matrix $\hat{Q}$ and a square upper triangular matrix $\hat{R}$. The matrix $\hat{R}$ is depicted with a shaded upper triangle and an unshaded lower triangle. Below each matrix is its corresponding label: A , $\hat{Q}$, and $\hat{R}$.

$$A = \hat{Q} \hat{R}$$

3.2 矩阵的QR分解



证明： 由题，对任意 $x \neq 0$ ，都有 $Ax \neq 0$

$$\text{因此 } x^H A^H Ax = (Ax)^H Ax > 0$$

所以矩阵 A 是正定Hermite矩阵。从而存在唯一的上三角矩阵 R ，使得

$$A^H A = R^H R$$

$$\text{令 } \tilde{Q} = AR^{-1}, \text{ 则 } \tilde{Q}^H \tilde{Q} = R^{-H} R^H R R^{-1} = I$$

$$\text{因此 } \tilde{Q} \text{ 是列正交单位矩阵, 且有 } A = \tilde{Q} R$$


3.2 矩阵的QR分解

对列满秩的长方阵, $\tilde{Q}$ 也可以是方阵。


定理4 完全QR分解 设 $n \times k (n > k)$ 阶矩阵 A 是列满秩阵, 则必存在 k 阶非奇异上三角矩阵 R 和 n 阶酉矩阵或正交矩阵 Q , 使得矩阵 A 具有完全QR分解

$$A = Q \begin{pmatrix} R \\ O \end{pmatrix}$$

3.2 矩阵的QR分解



Full QR



Reduced QR

知乎 @YcoFlegs

3.2 矩阵的QR分解

对于任意矩阵，也存在QR分解：

定理5 QR分解 设 $n \times k (n > k)$ 阶矩阵 A 的秩为 r ，则必存在 $r \times k$ 阶行满秩矩阵 R 和 n 阶酉矩阵或正交矩阵 Q ，使得矩阵 A 具有QR分解

$$A = Q \begin{pmatrix} R \\ O \end{pmatrix} \equiv (\hat{Q}, Q_1) \begin{pmatrix} R \\ O \end{pmatrix} = \hat{Q} R$$

这里 $\hat{Q}$ 为 Q 的前 r 列。

3.2 矩阵的QR分解



Householder 变换是将向量 $x \in F^n$ 变换为关于
“与单位向量 $u \in F^n$ 正交的 $n-1$ 维子空间”
对称的向量 $y \in F^n$ 的镜像变换。($F = R \text{ or } C$)

定义3.2.1 设 $u \in C^n$ 为单位列向量，称矩阵

$$H = I - 2uu^H$$

为Householder 矩阵（初等反射矩阵），对应的
变换为Householder 变换（初等反射变换）

3.2 矩阵的QR分解



Householder 矩阵 H 具有下列性质：

- (1) H 为 Hermite 矩阵，即有 $H^H = H$
- (2) H 为酉矩阵，即有 $H^H H = H H^H = I$
- (3) H 为对合矩阵，即有 $H^2 = I$
- (4) H 为自逆矩阵，即有 $H^{-1} = H$
- (5) H 的特征值为 1 ($n-1$ 重) 和 -1 (单重)
- (6) $\tilde{H} \equiv \begin{pmatrix} I_r & O^T \\ O & H \end{pmatrix}$ 仍是 Householder 矩阵

3.2 矩阵的QR分解



(5) 证明: 设 $H = I - 2uu^H$, 则

$$\text{tr}(H) = \text{tr}(I) - 2\text{tr}(uu^H) = n - 2$$

设有 $H\alpha = \lambda\alpha$ 则 $\alpha = H^2\alpha = \lambda^2\alpha$, 因此
 $\lambda = \pm 1$

设特征值 1 与 -1 的重数分别为 k_1 、 k_2 , 则

$$k_1 + k_2 = n, \quad k_1 - k_2 = \text{tr}(H) = n - 2$$

解得 $k_1 = n - 1, k_2 = 1$

3.2 矩阵的QR分解



(6) 证明: 设 $H = I - 2uu^H$, 则

$$\begin{aligned}\tilde{H} &= \begin{pmatrix} I_r & O^T \\ O & I - 2uu^H \end{pmatrix} = \begin{pmatrix} I_r & O^T \\ O & I_n \end{pmatrix} - \begin{pmatrix} O & O^T \\ O & -2uu^H \end{pmatrix} \\ &= I_{n+r} - 2 \begin{pmatrix} \theta \\ u \end{pmatrix} (\theta^H, u^H) \equiv I_{n+r} - 2\tilde{u}\tilde{u}^H\end{aligned}$$

显然

$$\tilde{u} \in F^{n+r}, \quad \tilde{u}^H \tilde{u} = (\theta^H, u^H) \begin{pmatrix} \theta \\ u \end{pmatrix} = u^H u = 1$$

因此结论成立。

3.2 矩阵的QR分解

Householder变换后的像可以取 $\mathbf{e}_1$ ，这在几何上是显而易见的。从计算上讲，Householder首次意识到这意味着Householder变换也能将非零向量的后 $n-1$ 个分量变为零。

定理3.2.1 对任意 $\mathbf{x} \in \mathbf{R}^n$ ，存在Householder 矩阵 $\mathbf{H}$ ，使得

$$\mathbf{H}\mathbf{x} = \pm \|\mathbf{x}\|_2 \mathbf{e}_1$$

其中 $\mathbf{e}_1$ 为标准单位向量。

3.2 矩阵的QR分解



证明：若 $x = \pm \|x\|_2 e_1$ ，则取与 e_1 正交的单位列向量 u ，从而 $u^H x = (x, u) = 0$

$$Hx = x - 2uu^H x = x - 2u(x, u) = x = \pm \|x\|_2 e_1$$

若 $x \neq \pm \|x\|_2 e_1$ ，令 $u = x \mp \|x\|_2 e_1$

$$\begin{aligned} \text{注意到 } \|u\|_2^2 &= \|x \mp \|x\|_2 e_1\|_2^2 = 2(x \mp \|x\|_2 e_1, x) \\ &= 2(x, u) = 2u^H x \end{aligned}$$

$$\begin{aligned} \text{从而 } Hx &= (I - \frac{2}{\|u\|_2^2} uu^H)x = x - \frac{2uu^H x}{\|u\|_2^2} \\ &= x - \frac{2uu^H x}{2u^H x} = x - u = \pm \|x\|_2 e_1 \end{aligned}$$

3.2 矩阵的QR分解



虽然在数学上， $\|x\|_2$ 前的两种符号都令人满意。但为了数值稳定性的目的，希望向量 x 在大小和方向上都不要太接近 $\|x\|_2 e_1$ ，否则

$$u = x - \text{sgn}(\xi_1) \|x\|_2 e_1$$

就很接近零，这在几何上是显然的。因此算法实现时应取 $\|x\|_2$ 前的符号与 x 的第一个分量 ξ_1 的符号相同，即 $u = x + \text{sgn}(\xi_1) \|x\|_2 e_1$

并可加上规定：当 $\xi_1 = 0$ 时， $\text{sgn}(\xi_1) = 1$

3.2 矩阵的QR分解



例 用Householder变换化向量 $x = (3, 0, 4)^T$ 与 e_1 共线

解：令 $u = x + \|x\|_2 e_1 = \begin{pmatrix} 3 \\ 0 \\ 4 \end{pmatrix} + 5 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 8 \\ 0 \\ 4 \end{pmatrix}$

$$\begin{aligned} H &= I - \frac{2}{\|u\|_2^2} uu^T = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} - \frac{2}{80} \begin{pmatrix} 8 \\ 0 \\ 4 \end{pmatrix} (8 \ 0 \ 4) \\ &= \begin{pmatrix} -0.6 & 0 & -0.8 \\ 0 & 1 & 0 \\ -0.8 & 0 & 0.6 \end{pmatrix} \end{aligned}$$

此时 $Hx = (-5 \ 0 \ 0)^T$

3.2 矩阵的QR分解

可用一组 Householder 变换将任意方阵

$A = [\alpha_1, \alpha_2, \dots, \alpha_n]$ 变换为上三角矩阵

第一步, 当 $\alpha_1 \neq \theta$ 时, 存在Householder 矩阵 H_1 , 使得 (为方便说明, 不妨取负号)

$$H_1 \alpha_1 = -a_1 e_1, \quad |a_1| = \|\alpha_1\|$$

从而

$$H_1 A = (H_1 \alpha_1, \dots, H_1 \alpha_n) \equiv \begin{pmatrix} -a_1 & * \\ \theta & A_{n-1} \end{pmatrix}$$

如果 $\alpha_1 = \theta$, 则 $H_1 = I$, 直接进行下一步。

3.2 矩阵的QR分解



第二步, 对 $A_{n-1} = [\beta_2, \dots, \beta_n]$, 当 $\beta_2 \neq \theta$ 时, 存在 Householder 矩阵 $\tilde{H}_2$, 使得

$$\tilde{H}_2 \beta_2 = -a_2 \tilde{e}_1, \quad |a_2| = \|\beta_2\|, \quad \tilde{e}_1 \in F^{n-1}$$

从而

$$\tilde{H}_2 A_{n-1} = (\tilde{H}_2 \beta_2, \dots, \tilde{H}_2 \beta_n) \equiv \begin{pmatrix} -a_2 & * \\ \theta & A_{n-2} \end{pmatrix}$$

3.2 矩阵的QR分解

即有 $H_2 \equiv \begin{pmatrix} 1 & \theta^H \\ \theta & \tilde{H}_2 \end{pmatrix}$
使得

$$H_2 H_1 A = \begin{pmatrix} -a_1 & * & * \\ & -a_2 & * \\ & & A_{n-2} \end{pmatrix}$$

如果 $\beta_2 = \theta$ ，则 $H_2 = I$ ，直接进行下一步。

3.2 矩阵的QR分解



第三步，对 A_{n-2} 继续类似的变换，如此最多 $n-1$ 步，也即至多可以找到 $n-1$ 个矩阵

$$H_1, H_2, \dots, H_{n-1}$$

使得 $H_{n-1} \cdots H_2 H_1 A = R$

令 $Q \equiv (H_{n-1} \cdots H_2 H_1)^{-1}$ ，则 Q 为酉矩阵，
从而上述算法确实得到QR分解

$$A = QR$$

3.2 矩阵的QR分解



例 利用Householder变换将下列矩阵进行QR分解：

$$A = \begin{pmatrix} 0 & -3 & 1 \\ 2 & 1 & -6 \\ 0 & 4 & 2 \end{pmatrix}$$

3.2 矩阵的QR分解



解：对向量 $\alpha_1 = (0, 2, 0)^T$ ，令

$$u_1 = \frac{\alpha_1 + \|\alpha_1\|_2 e_1}{\|\alpha_1 + \|\alpha_1\|_2 e_1\|_2} = \frac{1}{\sqrt{2}} (1, 1, 0)^T$$

（ u_1 实际上是平面 $x + y = 0$ 的法向量）
从而得Householder 矩阵

$$H_1 = I - 2u_1 u_1^H = \begin{pmatrix} 0 & -1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

3.2 矩阵的QR分解



使得

$$H_1 A = \left(\begin{array}{c|cc} -2 & -1 & 6 \\ \hline 0 & 3 & -1 \\ 0 & 4 & -2 \end{array} \right)$$

对向量 $\beta_2 = (3, 4)^T$, 令 $\tilde{u}_2 = \frac{1}{\sqrt{5}}(2, 1)^T$

($\tilde{u}_2$ 实际上是平面 $2y + z = 0$ 的法向量)

3.2 矩阵的QR分解



可得 Householder 矩阵

$$\tilde{H}_2 = I - 2\tilde{u}_2\tilde{u}_2^H = \begin{pmatrix} \frac{3}{5} & -\frac{4}{5} \\ -\frac{4}{5} & \frac{3}{5} \end{pmatrix}$$

3.2 矩阵的QR分解

因此取

$$H_2 = \begin{pmatrix} \mathbf{1} & \mathbf{0}^T \\ \mathbf{0} & \tilde{H}_2 \end{pmatrix} = \begin{pmatrix} \mathbf{1} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & -\frac{3}{5} & -\frac{4}{5} \\ \mathbf{0} & -\frac{4}{5} & \frac{3}{5} \end{pmatrix}$$

从而有

$$H_2 H_1 A = \left(\begin{array}{cc|c} -2 & -1 & 6 \\ 0 & -5 & -1 \\ \hline 0 & 0 & 2 \end{array} \right) \equiv R$$

3.2 矩阵的QR分解

则

$$Q = (H_2 H_1)^{-1} = H_1^{-1} H_2^{-1} = H_1 H_2$$

$$= \begin{pmatrix} 0 & -1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & -\frac{3}{5} & -\frac{4}{5} \\ 0 & -\frac{4}{5} & \frac{3}{5} \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 0.6 & 0.8 \\ -1 & 0 & 0 \\ 0 & -0.8 & 0.6 \end{pmatrix}$$

3.2 矩阵的QR分解



QR算法是二十世纪十大算法之一，其基本思想基于QR迭代：

(1) 令 $A_1 = A$ ；

(2) 对 $k = 1, 2, \dots$ ， 重复

① 对 A_k 做QR分解： $A_k = Q_k R_k$

② 令 $A_{k+1} = R_k Q_k$

直至 $\{A_k\}$ 收敛。

3.2 矩阵的QR分解



由 $A_k = Q_k R_k$ 知 $Q_k^H A_k = R_k$ ，因此

$$\begin{aligned} A_{k+1} &= R_k Q_k = Q_k^H A_k Q_k \\ &= Q_k^H Q_{k-1}^H A_{k-1} Q_{k-1} Q_k = \cdots \\ &= Q_k^H Q_{k-1}^H \cdots Q_1^H A_1 Q_1 \cdots Q_{k-1} Q_k \\ &\equiv Q^H A Q \end{aligned}$$

其中 $Q = Q_1 \cdots Q_{k-1} Q_k$


因此迭代序列 $\{A_k\}$ 保持特征值不变

3.3 矩阵的奇异值分解



从Beltrami (1873)和Jordan (1874)提出奇异值分解(SVD, Singular value decomposition)至今, SVD及其推广已经成为矩阵计算最有用和最有效的工具之一, 在最小二乘问题、最优化、统计分析、信号与图像处理、系统理论与控制等领域被广泛使用。

3.3 矩阵的奇异值分解



圆 S 经过变换 A ，变成椭圆 AS 。圆的正交方向 v_1 、 v_2 变成椭圆的长、短轴方向 $\sigma_1 u_1$ 、 $\sigma_2 u_2$

3.3 矩阵的奇异值分解



假定矩阵 $A \in C^{m \times n}$ ($m \geq n$) 是列满秩矩阵。

一般地, n 维空间中的单位球面 S 经过变换 A 变成超椭圆 AS 。正交方向 $v_1, \dots, v_n$ 变成超椭圆的主半轴方向 $\sigma_1 u_1, \dots, \sigma_n u_n$ 。称 AS 的 n 个主半轴的长度 $\sigma_1, \dots, \sigma_n$ ($\sigma_1 \geq \dots \geq \sigma_n$) 为 A 的奇异值, 对应的单位向量 $u_1, \dots, u_n$ 为 A 的左奇异向量 (left singular vector), 对应的原象 $v_1, \dots, v_n$ 为 A 的右奇异向量。相应的空间称为奇异空间

3.3 矩阵的奇异值分解



前面已经指出: $Av_j = \sigma_j u_j \quad (1 \leq j \leq n)$

$$A(v_1, v_2, \dots, v_n) = (u_1, u_2, \dots, u_n) \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$$

矩阵形式为

$$AV = \hat{U} \hat{\Sigma}$$


这里矩阵 $\hat{U}$ 是列正交矩阵, V 是酉矩阵。

3.3 矩阵的奇异值分解

这样就得到 A 的约化奇异值分解

$$A = \hat{U} \hat{\Sigma} V^*$$


Reduced SVD ($m \geq n$)



3.3 矩阵的奇异值分解

同样地，将矩阵 $\hat{U}$ 扩充为 m 阶酉矩阵 U ，
并令 $\Sigma \equiv \begin{pmatrix} \hat{\Sigma} \\ \mathbf{0} \end{pmatrix}$ ，则得 A 的完全奇异值分解

$$A = U \Sigma V^*$$



3.3 矩阵的奇异值分解



定义1 对任意矩阵 $A \in \mathbb{C}^{m \times n}$ ，矩阵 A 的**非零**奇异值 $\sigma_1 \geq \dots \geq \sigma_r > 0$ 就是矩阵 $A^H A$ 或 AA^H 的**非零**特征值的平方根。

矩阵 $A^H A$ 在多元统计分析中称为**协方差矩阵**，这说明SVD会在其中被广泛使用，事实上也确实如此。

3.3 矩阵的奇异值分解



定理1 对任意矩阵 $A \in \mathbb{C}^{m \times n}$ ，都存在一个完全奇异值分解 $A = U \Sigma V^*$ 。并且奇异值 $\{\sigma_j\}$ 是唯一确定的。也就是任意矩阵酉等价于对角阵

定理2 对矩阵 $A \in \mathbb{C}^{m \times n}$ ， $\sigma_1 \geq \dots \geq \sigma_r$ 表示矩阵的 r ($r \leq \min(m, n)$) 个非零奇异值，则

$$\|A\|_2 = \sigma_1, \quad \|A\|_F = \sqrt{\sigma_1^2 + \sigma_2^2 + \dots + \sigma_r^2}$$

3.3 矩阵的奇异值分解



定理3 对任意矩阵 $A \in \mathbb{C}^{m \times n}$, 矩阵 A 的**非零**奇异值数目为 r ($r \leq \min(m, n)$) , $A = U\Sigma V^*$ 为矩阵 A 的SVD分解, 则

$$R(A) = \text{span}(u_1, u_2, \dots, u_r),$$

$$N(A) = \text{span}(v_{r+1}, v_{r+2}, \dots, v_n).$$

3.3 矩阵的奇异值分解

证明：将 A 的SVD分解分块为

$$A = \begin{bmatrix} \overset{r}{U_1} & \overset{m-r}{U_2} \end{bmatrix} \begin{bmatrix} \Sigma & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \begin{bmatrix} \overset{r}{V_1^H} \\ \underset{n-r}{V_2^H} \end{bmatrix} = U_1 \Sigma V_1^H$$

于是有

$$R(A) = \{y \mid y = Ax\} = \{y \mid y = U_1(\Sigma V_1^H x)\} \subset R(U_1)$$

$$R(U_1) = \{y \mid y = U_1 z\} = \{y \mid y = A(V_1 \Sigma^{-1} z)\} \subset R(A)$$

$$\text{从而 } R(A) = R(U_1) = \text{span}\{u_1, u_2, \dots, u_r\}$$

$$N(A) = \{x \mid Ax = \theta\} = \{x \mid (U_1 \Sigma)(V_1^H x) = \theta\}$$

$$= \{x \mid V_1^H x = \theta\} = \{x \mid x \in V_2\}$$

$$= \text{span}\{v_{r+1}, v_{r+2}, \dots, v_n\}$$

3.3 矩阵的奇异值分解



- 如果我们将A的转置和A做矩阵乘法，那么会得到 $n \times n$ 的一个方阵 $A^H A$ ，将其所有特征向量张成一个 $n \times n$ 的矩阵V，就是我们SVD公式里面的V矩阵了。
- 如果我们将A和A的转置做矩阵乘法，那么会得到 $m \times m$ 的一个方阵 AA^H ，将其所有特征向量张成一个 $m \times m$ 的矩阵U，就是我们SVD公式里面的U矩阵了。
- 证明：

$$A = U\Sigma V^T \Rightarrow A^T = V\Sigma U^T \Rightarrow A^T A = V\Sigma U^T U \Sigma V^T = V\Sigma^2 V^T$$

3.3 矩阵的奇异值分解



- 由于 Σ 除了对角线上是奇异值其他位置都是0，那我们只需要求出每个奇异值 σ 就可以了。

$$A = U\Sigma V^T \Rightarrow AV = U\Sigma V^T V \Rightarrow AV = U\Sigma \Rightarrow Av_i = \sigma_i u_i \Rightarrow \sigma_i = Av_i / u_i$$

- 也可以通过求出 $A^H A$ 和 AA^H 的特征值取平方根来求奇异值。

$$\sigma_i = \sqrt{\lambda_i}$$

3.3 矩阵的奇异值分解



任意矩阵 A 的SVD分解的算法为：

第一步： 形成 $A^H A$ 和 AA^H ，并计算特征值和特征向量

第二步： 利用特征向量张成左右奇异空间， U 和 V

第三步： 计算奇异值，得到 Σ

3.3 矩阵的奇异值分解



任意矩阵 A 的SVD分解的算法为：

第一步： 形成 $A^H A$ ，并计算特征值分解

$$A^H A = V \Lambda V^H, V \equiv [V_1, V_2]$$

第二步： 令 Σ 为 Λ 的非负对角的平方根，计算

$$U_1 = A V_1 \Sigma^{-1}$$

第三步： 通过求 $AA^H y = \theta$ 的解空间的单位正交基，得 U_2 ，从而得 $U = (U_1, U_2)$

3.3 矩阵的奇异值分解



例3.3.1 求下列矩阵的（完全）SVD分解：

$$(1) A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{pmatrix}; \quad (2) A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

3.3 矩阵的奇异值分解

解: (1) $A^T A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 2 \end{pmatrix}, AA^T = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 2 & 0 \\ 0 & 0 & 0 \end{pmatrix}$

矩阵 $A^T A$ 的特征值为 $3, 1, 0$, 对应的特征向量为 $\beta_1 = (1, 1, 2)^T, \beta_2 = (1, -1, 0)^T, \beta_3 = (1, 1, -1)^T$

从而

$$V = \left(\begin{array}{cc|c} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{-1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{-1}{\sqrt{3}} \end{array} \right) \equiv (V_1, V_2), \quad \Sigma = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \end{pmatrix}$$

3.3 矩阵的奇异值分解

计算 $U_1 = A V_1 \Sigma^{-1} = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \\ \mathbf{0} & \mathbf{0} \end{pmatrix}$

解 $AA^T y = \theta$, 得其基础解系为 $\beta_3 = (\mathbf{0}, \mathbf{0}, \mathbf{1})^T$

从而 $U_2 = \begin{pmatrix} \mathbf{0} \\ \mathbf{0} \\ \mathbf{1} \end{pmatrix}, \quad U = (U_1, U_2) = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & \mathbf{0} \\ \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{1} \end{pmatrix}$

3.3 矩阵的奇异值分解



因此所求（完全）SVD为

$$A = U \begin{pmatrix} \sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} V^T$$

由于是方阵，约化SVD同上面的结果一样。

3.3 矩阵的奇异值分解



解： (2) $A^T A = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}, AA^T = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$

矩阵 $A^T A$ 的特征值为 **2, 1**，对应的特征向量为

$$\beta_1 = (1, 0)^T, \beta_2 = (0, 1)^T$$

从而

$$V = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \equiv V_1, \Sigma = \begin{pmatrix} \sqrt{2} & 0 \\ 0 & 1 \end{pmatrix}$$

3.3 矩阵的奇异值分解

计算

$$U_1 = A V_1 \Sigma^{-1} = \begin{pmatrix} \frac{1}{\sqrt{2}} & 0 \\ 0 & 1 \\ \frac{1}{\sqrt{2}} & 0 \end{pmatrix}$$

解 $AA^T y = \theta$, 得其基础解系为

$$\beta_3 = (-1, 0, 1)^T$$

从而

$$U_2 = \begin{pmatrix} \frac{-1}{\sqrt{2}} \\ 0 \\ \frac{1}{\sqrt{2}} \end{pmatrix}, \quad U = (U_1, U_2) = \begin{pmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{-1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \end{pmatrix}$$

3.3 矩阵的奇异值分解

因此所求（完全）SVD为

$$A = U \begin{pmatrix} \sqrt{2} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} V^T$$

显然约化SVD为

$$A = U_1 \Sigma V_1^T = \begin{pmatrix} \frac{1}{\sqrt{2}} & 0 \\ 0 & 1 \\ \frac{1}{\sqrt{2}} & 0 \end{pmatrix} \begin{pmatrix} \sqrt{2} & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

3.3 矩阵的奇异值分解



因为上述算法把SVD问题约化到特征值问题，但遗憾的是特征值问题对扰动可能有更高的灵敏性，因此这个算法是不稳定的。

对Hermite特征值问题的变换算法一般分两个阶段：先把矩阵约化为三对角矩阵，然后把三对角矩阵对角化。因此计算SVD时，先把矩阵化为双对角形式 (Golub_Kahan 双对角化)，然后再把双对角矩阵对角化 (例如用QR算法)。Matlab中实际采用的是这种算法。

3.3 矩阵的奇异值分解

Golub_Kahan 双对角化的思想就是在矩阵 A 两侧交替进行Householder变换，也就是寻找酉等价的双对角矩阵 B ，使得

$$U_1^H A V_1 = B$$

对于双对角矩阵 B ，一般再用QR算法的变体将其对角化，即计算 B 的SVD：

$$B = U_2 \Sigma V^H$$

$$\text{这样 } A = U_1 B V_1^H = U_1 U_2 \Sigma V_2^H V_1^H \equiv U \Sigma V^H$$

3.3 矩阵的奇异值分解



如果将矩阵 A 的SVD中的对角阵 Σ 分解为

$$\Sigma = \Sigma_1 + \cdots + \Sigma_r,$$

这里

$$\Sigma_j \equiv \text{diag}(0, \cdots, 0, \overset{j}{\sigma_j}, 0, \cdots, 0)$$

则有 $A = U\Sigma V^H = U\Sigma_1 V^H + \cdots + U\Sigma_r V^H$

$$= \sigma_1 u_1 v_1^H + \sigma_2 u_2 v_2^H + \cdots + \sigma_r u_r v_r^H$$

这就是矩阵 A 的秩1矩阵分解式。

3.3 矩阵的奇异值分解



根据矩阵 A 的秩1 矩阵分解式，可以说明，在所有秩为 k 的矩阵中，以矩阵

$$A_k \equiv \sigma_1 u_1 v_1^H + \cdots + \sigma_k u_k v_k^H \equiv U_k \Sigma_k V_k^H$$

离矩阵 A 的“距离”最近，也即矩阵 A_k 是矩阵 A 的最佳秩 k 逼近，也就是包含了 A 中的“能量”最多。

3.1 矩阵的奇异值分解



定理8 对任意矩阵 $A \in \mathbb{C}^{m \times n}$, $A = U \Sigma V^H$ 为矩阵的SVD, $k < r = \text{rank}(A)$, 且

$$A_k \equiv \sigma_1 u_1 v_1^H + \cdots + \sigma_k u_k v_k^H$$

这里 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ 为 A 的非零奇异值, 则

$$\min_{\text{rank}(B)=k} \|A - B\|_2 = \|A - A_k\|_2 = \sigma_{k+1}$$

3.1 矩阵的奇异值分解



证明： 由 $U^H A_k V = \text{diag}(\sigma_1, \dots, \sigma_k, 0, \dots, 0)$ 知

$$U^H (A - A_k) V = \text{diag}(0, \dots, 0, \sigma_{k+1}, \dots, \sigma_r, 0, \dots, 0)$$

所以

$$\|A - A_k\|_2 = \|U^H (A - A_k) V\|_2 = \sigma_{k+1}$$

对任意满足 $\text{rank}(B) = k$ 的矩阵 $B \in C^{m \times n}$ ，存在单位正交向量 $x_1, \dots, x_{n-k}$ ，使得其零空间为

$$\text{Ker}(B) = \text{span}\{x_1, \dots, x_{n-k}\}$$

3.1 矩阵的奇异值分解



由维数可知，存在2范数单位向量 z ，使得

$$z \in \text{Ker}(B) \cap \text{span}\{v_1, \dots, v_{k+1}\} \neq \{\theta\}$$

设 $z = t_1 v_1 + \dots + t_{k+1} v_{k+1}$ ，则

$$\begin{aligned} Az &= \sigma_1 u_1 v_1^H z + \sigma_2 u_2 v_2^H z + \dots + \sigma_r u_r v_r^H z \\ &= \sigma_1 u_1 v_1^H z + \sigma_2 u_2 v_2^H z + \dots + \sigma_{k+1} u_{k+1} v_{k+1}^H z \\ &= \sigma_1 (v_1^H z) u_1 + \sigma_2 (v_2^H z) u_2 + \dots + \sigma_{k+1} (v_{k+1}^H z) u_{k+1} \\ &= \sigma_1 t_1 u_1 + \sigma_2 t_2 u_2 + \dots + \sigma_{k+1} t_{k+1} u_{k+1} \end{aligned}$$

3.1 矩阵的奇异值分解



注意到 $Bz = \theta$ ，因此

$$\begin{aligned}\|A - B\|_2^2 &\geq \|(A - B)z\|_2^2 = \|Az\|_2^2 \\ &= \sigma_1^2 t_1^2 + \sigma_2^2 t_2^2 + \cdots + \sigma_{k+1}^2 t_{k+1}^2 \\ &\geq \sigma_{k+1}^2 (t_1^2 + t_2^2 + \cdots + t_{k+1}^2) \\ &= \sigma_{k+1}^2 \|z\|_2^2 = \sigma_{k+1}^2\end{aligned}$$

3.1 矩阵的奇异值分解



从几何上看，用 σ_1 、 σ_2 为长、短轴作成的椭圆是所有椭圆中离矩阵 A 对应的超椭圆“距离”最近的；如果使用 σ_1 、 σ_2 、 σ_3 为轴作成椭球体，则得到所有椭球体中离矩阵 A 对应的超椭圆“距离”最近的椭球体。按这种方式， r 步之后，就得到了 A 的全部信息。但即使到了第 r 步，我们也只利用了 $r + nr + nr = (2n + 1)r$ 个数据，即矩阵的奇异值和对应的左右奇异向量。