

回归分析



2023-2024学年第一学期

课程编码：03521003

主讲：董晓东

目录



- 多元线性回归模型
- 回归方程的显著性检验
- 正规方程的等价形式
- 回归系数的显著性检验

5. 回归分析



- 回归分析是处理多个变量间相关关系的一种数学方法.
- 变量间的关系有两种类型:确定性的函数关系和相关关系.回归分析方法是处理变量间相关关系的有力工具.
- 回归分析用于确定一个或几个连续变量(称为响应变量、因变量或指标)与另一些连续变量(称为自变量或因素)间的相互依赖关系.

5. 回归分析



- 如果只要考察某一个因变量与其余多个变量的相互依赖关系,我们称为多元回归问题.
- 如果要同时考察 p 个因变量与 m 个自变量的相互依赖关系,我们称为多因变量的多元回归问题 (或简称为多对多回归) .

5. 回归分析



具体地说,我们研究以下几方面问题:

- ① 建立因变量 Y (或 $Y_1, \dots, Y_p$)与 $x_1, x_2, \dots, x_m$ 的经验公式(回归方程);
- ② 对经验公式的可信度进行检验;
- ③ 判断每个自变量 $x_i (i=1, \dots, m)$ 对 Y (或 $Y_1, \dots, Y_p$)的影响是否显著?
- ④ 利用经验公式(回归关系式)进行预报和控制,并用于指导生产;
- ⑤ 诊断经验公式是否适合这组数据。

5. 回归分析



- 在一元统计分析中讨论的多元线性回归是只考虑一个因变量的回归问题.
- 多元统计分析中讨论的回归问题是指有多个因变量的回归问题,它自然把一元统计中的回归作为特例.因多元线性回归问题在实际应用中更为广泛,它涉及的统计推断结论能够推广到多因变量的多元线性回归的问题中.
- 本章不加证明地介绍经典多元线性回归的一些结论

5.1 回归分析—多元线性回归模型



多元回归分析是研究因变量 Y 与 m 个自变量 $x_1, x_2, \dots, x_m$ 的相关关系.而且总是假设因变量 Y 是随机变量,而 $x_1, x_2, \dots, x_m$ 为一般变量.

假定因变量 Y 与 $x_1, x_2, \dots, x_m$ 线性相关.收集到的 n 组数据 $(y_t, x_{t1}, x_{t2}, \dots, x_{tm}) (t=1, 2, \dots, n)$ 满足以下回归模型:

$$\begin{cases} y_t = \beta_0 + \beta_1 x_{t1} + \dots + \beta_m x_{tm} + \varepsilon_t (t = 1, 2, \dots, n), \\ E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma^2, \text{Cov}(\varepsilon_i, \varepsilon_j) = 0 \text{ (当 } i \neq j) \\ \text{或 } \varepsilon_t \sim N(0, \sigma^2), \text{相互独立 } (t = 1, 2, \dots, n). \end{cases}$$

5.1 回归分析—多元线性回归模型



记

$$C_{n \times (m+1)} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1m} \\ 1 & x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nm} \end{bmatrix} = (\mathbf{I}_n | X)$$

$$Y_{n \times 1} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \beta_{(m+1) \times 1} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{bmatrix}, \quad \varepsilon_{n \times 1} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix},$$

5.1 回归分析—多元线性回归模型

则(4.1.1)的矩阵形式为

$$\begin{cases} Y=C\beta+\varepsilon, \\ E(\varepsilon)=0, D(\varepsilon)=\sigma^2 I_n, \end{cases} \quad (4.1.2)$$

或
$$\begin{cases} Y=C\beta+\varepsilon, \\ \varepsilon \sim N_n(0, \sigma^2 I_n), \end{cases} \quad (4.1.3)$$

并称模型(4.1.2)或(4.1.3)为经典多元线性回归模型. 其中 Y 是可观测的随机向量, ε 是不可观测的随机向量, C 是已知矩阵, β, σ^2 是未知参数. 并设 $n > m$, 且 $\text{rk}(C)=m+1$.

5.1 回归分析—多元线性回归模型



在经典回归分析中,我们讨论多元线性回归模型中未知的参数向量 $\beta = (\beta_0, \beta_1, \dots, \beta_m)'$ 和 σ^2 的估计和检验问题.

在近代回归分析中讨论变量筛选、估计的改进及对模型中的一些假定进行诊断.

5.1 回归分析——多元线性回归模型

定义4.1.1 在模型(4.1.2)中, 参数 β 的最小二乘估计量 $b=(b_0, b_1, \dots, b_m)'$ 是使误差平方和 $Q(b)$ 达最小. 即

其中

$$Q(b) = \min_{\text{一切}\beta} Q(\beta).$$

$$\begin{aligned} Q(\beta) &= \sum_{t=1}^n \varepsilon_t^2 = \sum_{t=1}^n [y_t - (\beta_0 + \beta_1 x_{t1} + \dots + \beta_m x_{tm})]^2 \\ &= (Y - C\beta)'(Y - C\beta). \end{aligned}$$

5.1 回归分析—多元线性回归模型

记 $C = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1m} \\ 1 & x_{21} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{nm} \end{pmatrix} = \begin{pmatrix} c'_{(1)} \\ c'_{(2)} \\ \vdots \\ c'_{(n)} \end{pmatrix}$, 则 $C\beta = \begin{pmatrix} c'_{(1)}\beta \\ c'_{(2)}\beta \\ \vdots \\ c'_{(n)}\beta \end{pmatrix}$,

$$Q(\beta) = \sum_{t=1}^n [y_t - (\beta_0 + \beta_1 x_{t1} + \cdots + \beta_m x_{tm})]^2 = \sum_{t=1}^n [y_t - c'_{(t)}\beta]^2$$
$$= (y_1 - c'_{(1)}\beta, \cdots, y_n - c'_{(n)}\beta) \begin{pmatrix} y_1 - c'_{(1)}\beta \\ \vdots \\ y_n - c'_{(n)}\beta \end{pmatrix}$$
$$= (Y - C\beta)'(Y - C\beta)$$

5.1 回归分析—多元线性回归模型



定理4.1.1 设 $\text{rk}(C)=m+1 \leq n$, 则

$$b=(C'C)^{-1}C'Y=BY$$

是 β 的最小二乘估计(其中 $B=(C'C)^{-1}C'$).

参数向量 β 的最小二乘估计 $\beta=\hat{\beta}$ 正好是 $m+1$ 阶的线性方程组

$$C'C\beta=C'Y$$

的解. 常称以上方程组为**正规方程**.

预测向量为 **$\hat{Y}=Cb=HY$** ,

其中 $H=C(C'C)^{-1}C'$ 称为“帽子”矩阵。

5.1 回归分析—多元线性回归模型



β 的最小二乘估计量 b 有以下性质:

(1) b 是 β 的极小方差线性无偏估计.

(2) $b \sim N_{m+1}(\beta, \sigma^2(C'C)^{-1})$.

因 $b=BY, Y \sim N_n(C\beta, \sigma^2 I_n)$,故 b 服从正态分布,

且 $E(b)=BC\beta=(C'C)^{-1}C'C\beta=\beta$,

$D(b)=B\sigma^2 I_n B' = \sigma^2(C'C)^{-1}$.

(3) 在 $\varepsilon \sim N_n(0, \sigma^2 I_n)$ 的假定下, b 还是一切无偏估计中方差最小的估计.

5.1 回归分析—多元线性回归模型

最小二乘法没有给出 σ^2 的估计.利用最大似然原则可得 β 的最大似然估计量仍为 b ,同时给出了 σ^2 的最大似然估计为

$$\begin{aligned}\hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n [y_i - (b_0 + b_1 x_{i1} + \cdots + b_m x_{im})]^2 \\ &= \frac{1}{n} (Y - Cb)'(Y - Cb) = \frac{1}{n} Q(b)\end{aligned}$$

但因 $\hat{\sigma}^2$ 不是 σ^2 的无偏估计量.通常取 s^2 作为 σ^2 的估计:

$$s^2 = \frac{1}{n - m - 1} Q(b)$$

定理4.1.2 设 $\text{rk}(C)=m+1 \leq n$,则 $E(s^2) = \sigma^2$ 。

5.1 回归分析—多元线性回归模型

因 $Q(b) = (Y - Cb)'(Y - Cb)$ (定理4.1.2的证明)

$$= (Y - C(C'C)^{-1}C'Y)'(I_n - H)Y = Y'(I_n - H)Y$$

$$= Y'PY \quad (P = I_n - H \text{ 是对称幂等阵})$$

$$Q(b) = Y'PY = (\underline{Y - C\beta} + C\beta)'P(\underline{Y - C\beta} + C\beta)$$

$$= \varepsilon'P\varepsilon \quad (Y - C\beta = \varepsilon, PC = 0)$$

$$\therefore E(Q(b)) = E(\varepsilon'P\varepsilon) = E(\text{tr}(\varepsilon'P\varepsilon))$$

$$= E(\text{tr}(P\varepsilon\varepsilon')) = \text{tr}[PE(\varepsilon\varepsilon')]$$

$$= \text{tr}(P \bullet \sigma^2 I_n) = \sigma^2 \text{tr}(P)$$

$$= \sigma^2 (n - m - 1)$$

5.2 回归分析—回归方程的显著性检验



在实际问题中,我们事先并不能判定因变量 Y 与变量 $x_1, x_2, \dots, x_m$ 之间确有线性关系.在求出回归系数 β 的估计之前,回归模型(4.1.2)只是一种假定,尽管这种假定常常不是没有根据的,但在求出线性回归方程后,还需对 Y 与 $x_1, x_2, \dots, x_m$ 有否线性关系进行统计检验,以给出肯定或者否定的结论.

我们假定 $E(Y) = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m$,如果 Y 与 $x_1, x_2, \dots, x_m$ 之间均无线性相关关系,则以上模型中 $x_i (i=1, 2, \dots, m)$ 的系数 β_i 应均为0.

5.2 回归分析—回归方程的显著性检验

首先应检验以下假设：

$$H_0: \beta_1 = \beta_2 = \dots = \beta_m = 0$$

使用的方法仍是方差分析法。从分析引起 $y_t (t=1, \dots, n)$ 变化的总变差Total SS的原因入手。显然使得 Y 变化的原因有二个：

第一，因 Y 与 $x_i (i=1, \dots, m)$ 线性相关，由 x_i 的变化引起 Y 的变化(Model SS)；

第二，其它因素或误差引起的(Error SS)。

若 Y 的变化主要是由 x_i 的变化引起的，则模型中的自变量 x_i 的系数 $\beta_i \neq 0$ 。

用方差分析的思想，把 $y_t (t=1, \dots, n)$ 的总变差进行分解：

$$\text{Total SS} = \text{Model SS} + \text{Error SS}$$

5.2 回归分析—回归方程的显著性检验

引理4.1.1 对任给定的观测数据阵

$$\begin{bmatrix} y_1 & x_{11} & x_{12} & \cdots & x_{1m} \\ y_2 & x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ y_n & x_{n1} & x_{n2} & \cdots & x_{nm} \end{bmatrix}_{n \times (m+1)}$$

恒有公式:

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \quad (4.1.4)$$

其中

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \cdots + \hat{\beta}_m x_{im} \quad (i = 1, \cdots, n).$$

5.2 回归分析—回归方程的显著性检验



而 $\beta = (C'C)^{-1}C'Y$ 是 β 的最小二乘估计。

公式(4.1.4)称为平方和分解公式。

平方和分解公式(4.1.4)的左边 $\sum (y_i - \bar{y})^2$ 体现了 Y 的观测值 $y_1, y_2, \dots, y_n$ 总波动大小, 称为总偏差平方和, 记作 l_{yy} (或TSS). (4.1.4)式右边的第二项 $\sum (\hat{y}_i - \bar{y})^2$ 体现了 n 个估计值 $\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n$ 的波动大小; 它是由于 Y 与变量 $x_1, x_2, \dots, x_m$ 之间确有线性关系而通过 $x_1, x_2, \dots, x_m$ 的变化而引起, 我们称它为回归平方和或模型平方和, 记为 U (或MSS)

5.2 回归分析—回归方程的显著性检验



(4.1.4)式右边第一项 $\sum (y_i - \hat{y}_i)^2 = \sum \varepsilon^2$ 称为残差平方和, 记为 Q (或ESS).

在模型(4.1.2)假定下, 即 $E(Y) = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m$, Q 是由于随机误差引起的. 实际上模型(4.1.2)只是一种假定, 变量 $x_1, x_2, \dots, x_m$ 和 Y 的关系除了线性关系外, 可能还有非线性的关系. Q 是除了 $x_1, x_2, \dots, x_m$ 对 Y 的线性关系之外的一切其它因素(包括 $x_1, x_2, \dots, x_m$ 对 Y 的非线性关系及随机误差)引起的. 故 Q 也称为剩余平方和或误差平方和. 利用以上记号(4.1.4)式可简写为:

$$l_{yy} = Q + U, \text{ 或 } TSS = ESS + MSS, \quad (4.1.5)$$

5.2 回归分析—回归方程的显著性检验



$$\text{Error SS} = \text{ESS} = Y (I - C(C' C)^{-1} C') Y$$

$$\hat{\sigma}^2 = s^2 = \text{MSE}$$

$$= \text{Error SS} / (n - m - 1)$$

$$R^2 = \text{Model SS} / \text{Total SS}$$

$$= U / l_{yy} \text{ 称为决定系数；}$$

而 R 称为复相关系数。

5.2 回归分析—回归方程的显著性检验



定理4.1.3 在模型(4.1.3)下有

(1) $\hat{\beta} \sim N_{m+1}(\beta, \sigma^2 (C' C)^{-1})$;

(2) $\frac{1}{\sigma^2} Q \sim \chi_{n-m-1}^2$;

(3) $\hat{\beta}$ 与 Q 相互独立;

(4) $H_0: \beta_1 = \beta_2 = \cdots = \beta_m = 0$ 成立时, $\frac{U}{\sigma^2} = \frac{\text{MSS}}{\sigma^2} \sim \chi_m^2$.

5.2 回归分析—回归方程的显著性检验



定理的结论(1)前面已经证明.

(2) $Q = Q(b) = \varepsilon' P \varepsilon$, 而 $\varepsilon \sim N_n(0, \sigma^2 I_n)$,
 P 是对称幂等阵, 且 $\text{tr}(P) = n - m - 1$. 且

$$\frac{1}{\sigma^2} Q \sim \chi^2(n - m - 1).$$

结论3 设 $X \sim N_n(0, \sigma^2 I_n)$, A 为 n 阶对称方阵,
 $\text{rk}(A) = r$, 则二次型 $X'AX/\sigma^2 \sim \chi^2(r) \Leftrightarrow$
 $A^2 = A$ (A 为对称幂等阵).

5.2 回归分析—回归方程的显著性检验



(3) 因 $Q = \varepsilon' P \varepsilon$,

$$\begin{aligned}\hat{\beta} = b &= (C' C)^{-1} C' Y = (C' C)^{-1} C' (C \beta + \varepsilon) \\ &= \beta + B \varepsilon \quad (B = (C' C)^{-1} C')\end{aligned}$$

贬 $BP = O$ (奢 $C' P = C' (I_n - H) = O$).

痰

定理 8. 设 $X \sim N_p(\mu, \Sigma)$, $\Sigma > 0$, A 为对称阵, C 为一 $p \times q$ 矩阵, 则 $C'X$ 和 $X'AX$ 相互独立的充要条件是 $C'\Sigma A = 0$.

$$\begin{aligned}(4) \text{ 因 } U = l_{yy} - Q &= (Y - 1_n \bar{Y})'(Y - 1_n \bar{Y}) - Y' P Y \\ &= Y' \left(I_n - \frac{1}{n} 1_n 1_n' \right) Y - Y' P Y = Y' (D - P) Y\end{aligned}$$

5.2 回归分析—回归方程的显著性检验



可以验证, $D - P$ 是对称幂等阵, 且

$$\text{tr}(D - P) = (n - 1) - (n - m - 1) = m.$$

在 H_0 下, $C\beta = (1_n X) \begin{pmatrix} \beta_0 \\ 0 \end{pmatrix} = 1_n \beta_0$, 所以

$$Y \sim N_n(1_n \beta_0, \sigma^2 I_n).$$

进而可知

$$\frac{1}{\sigma^2} Y'(D - P)Y \sim \chi^2(m, \delta)$$

5.2 回归分析—回归方程的显著性检验

非中心参数 δ 为

$$\begin{aligned}\delta &= \frac{1}{\sigma^2} (1_n \beta_0)' (D - P) 1_n \beta_0 \\ &= \frac{1}{\sigma^2} (1_n \beta_0)' (D 1_n - P 1_n) \beta_0 = 0\end{aligned}$$

所以
$$\frac{U}{\sigma^2} = \frac{1}{\sigma^2} Y' (D - P) Y \sim \chi^2(m).$$

5.2 回归分析—回归方程的显著性检验

为检验 H_0 ,由总变差的分解公式:

$$\text{Total SS} = \text{MSS} + \text{ESS}$$

可构造检验假设的检验统计量 F

$$F = \frac{\text{MSS} / f_m}{\text{ESS} / f_e} = \frac{\text{MMS (模型均方)}}{\text{MSE (均方误差)}}$$

$$= \frac{U / m}{Q / (n - m - 1)}$$

在 H_0 成立时,检验统计量 $F \sim F(m, n-m-1)$,其中 $f_m = m$ 和 $f_e = n-m-1$ 分别称为模型的自由度和误差的自由度.

5.2 回归分析—回归方程的显著性检验



由观测数据计算 F 值及显著性概率(p 值), p 值是指在 H_0 下, 利用 F 的分布规律, 计算出检验统计量 F 大于或等于样本 F 值(即比该组样本得到的 F 值更极端的事件)的概率。若得出的 p 值很小(小于显著性水平 α), 依统计思想, 小概率事件在一次实践中一般不会发生。如果发生小概率事件, 将否定前提假定 H_0 .

5.3 回归分析—正规方程的等价形式

回归模型(4.1.1)可以改写为

$$\begin{cases} y_i - \bar{y} = \beta_0^* + \beta_1(x_{i1} - \bar{x}_1) + \cdots + \beta_m(x_{im} - \bar{x}_m) + \varepsilon_i, \\ (i = 1, 2, \dots, n) \end{cases} \quad (4.1.7)$$
$$\varepsilon = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)' \sim N_n(0, \sigma^2 I_n)$$

它与原模型(4.1.1)没有本质差别,只不过是

$$\beta_0 = \beta_0^* - \sum_{i=1}^m \beta_i \bar{x}_i + \bar{y}.$$

模型(4.1.7)的特点是对观测数据 $(y_t, x_{t1}, x_{t2}, \dots, x_{tm})$ $(t=1, 2, \dots, n)$ 做了中心化处理. 下面将说明在(4.1.7)下得到的正规方程的形式.

5.3 回归分析—正规方程的等价形式

记

$$\tilde{X} = \begin{bmatrix} x_{11} - \bar{x}_1 & x_{12} - \bar{x}_2 & \cdots & x_{1m} - \bar{x}_m \\ x_{21} - \bar{x}_1 & x_{22} - \bar{x}_2 & \cdots & x_{2m} - \bar{x}_m \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} - \bar{x}_1 & x_{n2} - \bar{x}_2 & \cdots & x_{nm} - \bar{x}_m \end{bmatrix}_{n \times m}$$

$$B_{m \times 1} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_m \end{bmatrix}, \tilde{Y}_{n \times 1} = \begin{bmatrix} y_1 - \bar{y} \\ y_2 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{bmatrix}, \tilde{C} = (\mathbf{I}_n \mid \tilde{X}), \tilde{\beta} = \begin{bmatrix} \beta_0^* \\ B \end{bmatrix},$$

5.3 回归分析—正规方程的等价形式

则(4.1.7)的矩阵形式为

$$\begin{cases} \tilde{Y} = \tilde{C}\tilde{\beta} + \varepsilon, \\ \varepsilon \sim N_n(0, \sigma^2 I_n), \end{cases}$$

正规方程为: $\tilde{C}'\tilde{C}\tilde{\beta} = \tilde{C}'\tilde{Y}.$

又

$$\tilde{C}'\tilde{C} = (\mathbf{I}_n \mid \tilde{X})'(\mathbf{I}_n \mid \tilde{X}) = \begin{bmatrix} \mathbf{I}_n' \mathbf{I}_n & \mathbf{I}_n' \tilde{X} \\ \tilde{X}' \mathbf{I}_n & \tilde{X}' \tilde{X} \end{bmatrix} \stackrel{\text{def}}{=} \begin{bmatrix} n & 0 \\ 0 & L \end{bmatrix},$$

其中

$$L = \tilde{X}'\tilde{X} = (l_{ij})_{m \times m},$$

5.3 回归分析—正规方程的等价形式



$$l_{ij} = \sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j) \quad (i, j = 1, 2, \dots, m).$$

而

$$\tilde{C}'\tilde{Y} = (\mathbf{I}_n \mid \tilde{X})' \tilde{Y} = \begin{bmatrix} \mathbf{I}'_n \tilde{Y} \\ \tilde{X}'\tilde{Y} \end{bmatrix} \stackrel{\text{def}}{=} \begin{bmatrix} 0 \\ l \end{bmatrix},$$

其中

$$l = (l_{1y}, l_{2y}, \dots, l_{my})', l_{iy} = \sum_{k=1}^n (x_{ki} - \bar{x}_i)(y_k - \bar{y}).$$

于是正规方程可写为：

$$\begin{bmatrix} n & 0 \\ 0 & L \end{bmatrix} \begin{bmatrix} \beta_0^* \\ B \end{bmatrix} = \begin{bmatrix} 0 \\ l \end{bmatrix},$$

5.3 回归分析—正规方程的等价形式

由此可得出 $\beta_0^*=0$,故正规方程的另一等价形式为

$$LB = l, \quad (4.1.8)$$

其中 $L = \tilde{X}'\tilde{X}, l = \tilde{X}'\tilde{Y}.$

(4.1.8)是 m 阶线性方程组,解(4.1.8)得 B 的最小二乘估计为:

$$\hat{B} = L^{-1}l, \text{ 且 } \hat{B} \sim N_m(B, \sigma^2 L^{-1}).$$

5.3 回归分析—正规方程的等价形式



数据中心化后的线性回归模型(4.1.7)可表为

$$\begin{cases} \tilde{Y} = \tilde{X} B + \varepsilon, \\ \varepsilon \sim N_n(0, \sigma^2 I_n), \end{cases} \quad (4.1.9)$$

因为 $U = (\hat{Y} - \bar{y}1_n)'(\hat{Y} - \bar{y}1_n)$, $\tilde{Y} = Y - \bar{y}1_n = \tilde{X}B$,

所以回归平方和 U 有以下计算公式:

$$\begin{aligned} U &= (\tilde{X}\hat{B})' \tilde{X}\hat{B} = \hat{B}'L\hat{B} = \hat{B}'l \\ &= \hat{\beta}_1 l_{1y} + \hat{\beta}_2 l_{2y} + \cdots + \hat{\beta}_m l_{my} \end{aligned}$$

5.3 回归分析—正规方程的等价形式



设因变量 Y 与 x_1, x_2 线性相关, $n=5$ 次观测数据如下:

x_1	x_2	Y
0	-1	1
1	-1	4
2	2	3
3	3	8
4	2	9

设 n 次观测数据满足:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i \\ (i = 1, \dots, n)$$

- (1) 试求参数 $\beta_0, \beta_1, \beta_2$ 的最小二乘估计;
- (2) 计算 $\hat{Y}_i, \hat{\varepsilon}_i (i = 1, 2, \dots, 5)$ 及残差平方和 Q ;
- (3) 计算回归平方和 U 及决定系数 R^2 .

5.3 回归分析—正规方程的等价形式

(1) 试求参数 $\beta_0, \beta_1, \beta_2$ 的最小二乘估计;

假设 $n=5$ 次观测数据满足:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i \quad (i = 1, \dots, 5)$$

$$\Leftrightarrow \begin{cases} Y = C\beta + \varepsilon \\ \varepsilon \sim N_5(0, \sigma^2 I_5) \end{cases},$$

$$\text{其中 } C = \begin{pmatrix} 1 & 0 & -1 \\ 1 & 1 & -1 \\ 1 & 2 & 2 \\ 1 & 3 & 3 \\ 1 & 4 & 2 \end{pmatrix}, Y = \begin{pmatrix} 1 \\ 4 \\ 3 \\ 8 \\ 9 \end{pmatrix}, \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}, \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \varepsilon_4 \\ \varepsilon_5 \end{pmatrix}.$$

5.3 回归分析—正规方程的等价形式

解一：因

$$C'C = \begin{pmatrix} 5 & 10 & 5 \\ 10 & 30 & 20 \\ 5 & 20 & 19 \end{pmatrix}, \quad C'Y = \begin{pmatrix} 25 \\ 70 \\ 43 \end{pmatrix}$$

$$(C'C)^{-1} = \frac{1}{200} \begin{pmatrix} 170 & -90 & 50 \\ -90 & 70 & -50 \\ 50 & -50 & 50 \end{pmatrix} = \frac{1}{20} \begin{pmatrix} 17 & -9 & 5 \\ -9 & 7 & -5 \\ 5 & -5 & 5 \end{pmatrix}$$

所以参数 $\beta_0, \beta_1, \beta_2$ 的最小二乘估计：

$$\hat{\beta} = (C'C)^{-1} C'Y = \frac{1}{20} \begin{pmatrix} 10 \\ 50 \\ -10 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 2.5 \\ -0.5 \end{pmatrix}$$

5.3 回归分析—正规方程的等价形式

(2) 由 $\hat{Y}_i = 0.5 + 2.5x_{i1} - 0.5x_{i2} \quad (i = 1, \dots, 5)$

$$\hat{\varepsilon}_i = y_i - \hat{Y}_i \quad (i = 1, \dots, 5), Q = \sum_{i=1}^5 \hat{\varepsilon}_i^2$$

经计算可得:

$$\hat{Y} = \begin{pmatrix} 1 \\ 3.5 \\ 4.5 \\ 6.5 \\ 9.5 \end{pmatrix}, \quad \hat{\varepsilon} = Y - \hat{Y} = \begin{pmatrix} 0 \\ 0.5 \\ -1.5 \\ 1.5 \\ -0.5 \end{pmatrix},$$

残差平方和 Q 为

$$Q = 0 + 0.5^2 + (-1.5)^2 + 1.5^2 + (-0.5)^2 = 5$$

5.3 回归分析—正规方程的等价形式



(3) 计算回归平方和 U 及决定系数 R^2 :

$$\text{总偏差平方和 } l_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = 46,$$

由平方和分解公式可得回归平方和 U 为:

$$U = l_{yy} - Q = 46 - 5 = 41$$

$$\text{决定系数为: } R^2 = \frac{U}{l_{yy}} = \frac{41}{46} = 0.8913$$

5.3 回归分析—正规方程的等价形式

解二:(1)把数据中心化

$$\tilde{X} = \begin{pmatrix} 0-2 & -1-1 \\ 1-2 & -1-1 \\ 2-2 & 2-1 \\ 3-2 & 3-1 \\ 4-2 & 2-1 \end{pmatrix} = \begin{pmatrix} -2 & -2 \\ -1 & -2 \\ 0 & 1 \\ 1 & 2 \\ 2 & 1 \end{pmatrix}, \quad \tilde{Y} = \begin{pmatrix} 1-5 \\ 4-5 \\ 3-5 \\ 8-5 \\ 9-5 \end{pmatrix} = \begin{pmatrix} -4 \\ -1 \\ -2 \\ 3 \\ 4 \end{pmatrix}$$

由中心化后的正规方程可得:

$$\hat{B} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = (\tilde{X}'\tilde{X})^{-1} \tilde{X}'\tilde{Y}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2$$

5.3 回归分析—正规方程的等价形式

由

$$\tilde{X}'\tilde{X} = \begin{pmatrix} 10 & 10 \\ 10 & 14 \end{pmatrix}, \quad \tilde{X}'\tilde{Y} = \begin{pmatrix} 20 \\ 18 \end{pmatrix}$$

$$(\tilde{X}'\tilde{X})^{-1} = \frac{1}{40} \begin{pmatrix} 14 & -10 \\ -10 & 10 \end{pmatrix} = \frac{1}{4} \begin{pmatrix} 1.4 & -1 \\ -1 & 1 \end{pmatrix}$$

所以参数 β_1, β_2 的最小二乘估计:

$$\hat{B} = (\tilde{X}'\tilde{X})^{-1} \tilde{X}'\tilde{Y} = \frac{1}{4} \begin{pmatrix} 10 \\ 18 \end{pmatrix} = \begin{pmatrix} 2.5 \\ -0.5 \end{pmatrix}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2 = 5 - 2.5 \times 2 + 0.5 \times 1 = 0.5$$

5.3 回归分析—正规方程的等价形式

(2) 由 $\hat{Y}_i = 0.5 + 2.5x_{i1} - 0.5x_{i2} \quad (i = 1, \dots, 5)$

$$\hat{\varepsilon}_i = y_i - \hat{Y}_i \quad (i = 1, \dots, 5), Q = \sum_{i=1}^5 \hat{\varepsilon}_i^2$$

经计算可得:

$$\hat{Y} = \begin{pmatrix} 1 \\ 3.5 \\ 4.5 \\ 6.5 \\ 9.5 \end{pmatrix}, \quad \hat{\varepsilon} = Y - \hat{Y} = \begin{pmatrix} 0 \\ 0.5 \\ -1.5 \\ 1.5 \\ -0.5 \end{pmatrix},$$

残差平方和 Q 为

$$Q = 0 + 0.5^2 + (-1.5)^2 + 1.5^2 + (-0.5)^2 = 5$$

5.3 回归分析—正规方程的等价形式



(3) 计算回归平方和 U 及决定系数 R^2 :

总偏差平方和 $l_{yy} = \tilde{Y}'\tilde{Y} = 46$

由回归平方和 U 的另一计算公式计算可得:

$$U = \hat{\beta}_1 l_{1y} + \hat{\beta}_2 l_{2y} = (2.5, -0.5) \begin{pmatrix} 20 \\ 18 \end{pmatrix} = 41$$

决定系数为: $R^2 = \frac{U}{l_{yy}} = \frac{41}{46} = 0.8913$

复相关系数 $R = \sqrt{0.8913} = 0.9441.$

5.4 回归分析—回归系数的显著性检验



对回归方程的显著性检验,若否定 H_0 ,仅表示 $\beta_1, \beta_2, \dots, \beta_m$ 不全为0,但并不排除有个别 β_i 为0。若 $\beta_i=0$,说明自变量 x_i 对因变量 Y 的影响不明显,应从回归模型中删除。因此对回归系数 β_i ($i=1,2,\dots,m$)是否为0逐个进行检验是很必要的。即检验以下的假设:

$$H^{(i)} : \beta_i=0 \quad (i=1,2,\dots,m)$$

类似地,可构造检验以上假设的检验统计量 T ,并由 n 组观测计算 T 值和显著性概率(p 值)。从而对 $H^{(i)}$ 是否成立进行统计推断。

5.4 回归分析—回归系数的显著性检验

我们引进偏回归平方和的概念.它是刻画某个自变量对 Y 作用大小的统计量.

定义4.1.2 称 $P_i = U - U(i)$
(或 $P_i = Q(i) - Q$) 为变量 x_i 的 **偏回归平方和**.

其中 U 为 $x_1, \dots, x_m$ 对 Y 的回归平方和. $U(i)$ 为去掉 x_i 后余下的 $m-1$ 个变量对 Y 的回归平方和.

5.4 回归分析—回归系数的显著性检验



P_i 表示去掉变量 x_i 后回归平方和减少(或残差平方和增加)的数值,这个数值大,说明 x_i 重要,这个数值小,说明 x_i 不重要.

还可以证明 P_i 的计算公式为

$$P_i = \frac{\hat{\beta}_i^2}{l_{ii}} \quad (i = 1, 2, \dots, m),$$

其中 l_{ii} 为 L^{-1} 的第 i 个对角元素.

5.4 回归分析—回归系数的显著性检验



检验 $H_0: \beta_i = 0 (i=1, 2, \dots, m)$ 的检验统计量选为

$$F_i = \frac{P_i}{Q/(n-m-1)}, \text{ 或 } t_i = \frac{\hat{\beta}_i / \sqrt{l^{ii}}}{\sqrt{Q/(n-m-1)}},$$

由定理4.1.3知 $Q/\sigma^2 \sim \chi^2 (n-m-1)$. 又已知

$$\hat{B} = (\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_m)' \sim N_m(B, L^{-1} \sigma^2),$$

所以
$$\hat{\beta}_i \sim N(\beta_i, \sigma^2 l^{ii}),$$

5.4 回归分析—回归系数的显著性检验



在 H_0 成立时 $\frac{\beta_i}{\sigma \sqrt{l^{ii}}} \sim N(0, 1)$, 即 $\frac{\beta_i^2}{\sigma^2 l^{ii}} \sim \chi^2(1)$,

且与 Q 相互独立, 所以

$$F_i = \frac{P_i}{Q/(n-m-1)} \sim F(1, n-m-1),$$

或
$$t_i = \frac{\hat{\beta}_i / \sqrt{l^{ii}}}{\sqrt{Q/(n-m-1)}} \sim t(n-m-1),$$

5.4 回归分析—回归系数的显著性检验



给定检验水平 α , 由样本观测数据计算 Q 、 P_i 及检验统计量的值(记为 f_i), 并计算显著性概率值(p 值):

$$p = P\{F_i \geq f_i\}.$$

若 $p < \alpha$, 否定 H_0 , 即认为 x_i 对 Y 的作用是显著(x_i 在回归方程中是显著的); 否则 H_0 , 相容.

5.4 回归分析—回归系数的显著性检验



所谓“最优”回归方程是指包含所有在检验水平 α 下对 Y 作用显著的变量,而不包含在检验水平 α 下对 Y 作用不显著的变量的回归方程.经对 m 个变量逐个做检验后,如 m 个变量在给定的检验水平 α 下对 Y 作用都是显著的,即认为所得方程就是“最优”回归方程.

如果有不显著变量,则每次只能剔除一个,然后由余下的变量和 Y 再做回归,然后再逐个检验,每次只许剔除一个最不重要的变量.重复以上步骤,直至方程中的变量都是重要变量为止.这时得到的方程即为“最优”回归方程.利用这个方程可对生产过程作预报或进行控制.

5.4 回归分析—回归系数的显著性检验

预测值(P): $\hat{Y} = C\hat{\beta}$

均值E(y)的置信限(CLM): $\hat{y} \pm t_{\alpha/2} \sqrt{\text{Var}(\hat{y})}$

$$\text{Var}(\hat{y}) = (x'(C'C)^{-1}x)\text{MSE}$$

预测值y置信限(CLI): $\hat{y} \pm t_{\alpha/2} \sqrt{\text{Var}(y - \hat{y})}$

$$\text{Var}(y - \hat{y}) = (1 + x'(C'C)^{-1}x)\text{MSE}$$

预测残差平方和 $\text{PRESS} = \sum_{i=1}^n (y_i - \hat{y}_i(i))^2$

5.4 回归分析—回归系数的显著性检验

例4.1.1(水泥数据) 某种水泥在凝固时所释放的热量为 Y (卡/克) 与水泥中下列四种化学成份有关:

x_1 ___ $3\text{CaO} \cdot \text{Al}_2\text{O}_3$ 的成分(%);

x_2 ___ $3\text{CaO} \cdot \text{SiO}_2$ 的成分(%);

x_3 ___ $4\text{CaO} \cdot \text{Al}_2\text{O}_3 \cdot \text{Fe}_2\text{O}_3$ 的成分(%);

x_4 ___ $2\text{CaO} \cdot \text{SiO}_2$ 的成分(%).

共观测了13组数据(见表4.1), 试求出 Y 与 x_1 , x_2 , x_3 , x_4 的回归关系式, 并对回归方程和各个回归系数进行检验.

5.4 回归分析—回归系数的显著性检验



表4.1 水泥数据

序号	x_1	x_2	x_3	x_4	Y
1	7	26	6	60	78.5
2	1	29	15	52	74.3
3	11	56	8	20	104.3
4	11	31	8	47	87.6
5	7	52	6	33	95.9
6	11	55	9	22	109.2
7	3	71	17	6	102.7
8	1	31	22	44	72.5
9	2	54	18	22	93.1
10	21	47	4	26	115.9
11	1	40	23	34	83.8
12	11	66	9	12	113.3
13	10	68	8	12	109.4

5.4 回归分析—回归系数的显著性检验



解 使用SAS/STAT软件中最常用的REG过程来完成经典多元线性回归分析中的估计和检验问题。

一般先用DATA步创建SAS数据集,设该数据集的名字为d411.

用REG过程对d411数据进行回归计算:

```
proc reg data=d411;  
    model y=x1-x4;  
    title “水泥数据的多元回归模型”;  
run;
```

REG过程产生的主要结果见输出4.1.1.

5.4 回归分析—回归系数的显著性检验



Model: MODEL1

Dependent Variable: Y

Analysis of Variance

Source	DF	Sum of Squares	Mean Square	F Value	Prob>F
Model	4	2667.89944	666.97486	111.479	0.0001
Error	8	47.86364	5.98295		
C Total	12	2715.76308			
Root MSE		2.44601	R-square	0.9824	
Dep Mean		95.42308	Adj R-sq	0.9736	
C.V.		2.56333			

Parameter Estimates

Variable	DF	Parameter Estimate	Standard Error	T for H0: Parameter=0	Prob > T
INTERCEP	1	62.405369	70.07095921	0.891	0.3991
X1	1	1.551103	0.74476987	2.083	0.0708
X2	1	0.510168	0.72378800	0.705	0.5009
X3	1	0.101909	0.75470905	0.135	0.8959
X4	1	-0.144061	0.70905206	-0.203	0.8441

5.4 回归分析—回归系数的显著性检验



输出4.1.1给出以下几方面结果：

① 回归方程：

$$\hat{Y}=62.4054+1.5511x_1+0.5102x_2+0.1019x_3-0.1441x_4.$$

② 回归方程显著性检验的结果：由方差分析表可得平方和分解式为：

$$2715.7631=2667.8994+47.8636;$$

误差的均方为Error MS=47.86364/8=5.98295是模型中误差方差 σ^2 的估计.

给出检验统计量 F 值=111.479, p 值为0.0001, 表示拟合的模型是高度显著的, 该模型解释了这组数据总变差中的主要部分.

5.4 回归分析—回归系数的显著性检验



③ 回归系数显著性检验的结果：参数估计表不仅给出回归方程的系数，并给出检验 $H^{(i)}_0: \beta_i = 0$ ($i=0, 1, \dots, m$) 的结果. 见该表的最后一列 “Prob> | T | ” (即显著性概率 p 值), 若给定 $\alpha=0.05$, 常数项 (或称截距项) 和4个自变量的 p 值均 $\geq \alpha$, 这与回归方程高度显著产生矛盾. 从后面的讨论将看到此现象是因为4个自变量间存在较强的相关性. 为了得到“最优”回归方程, 应从方程中删除最不重要的变量 (如 x_3 , 因 x_3 的 p 值=0.8959为最大), 重新建立 Y 与其余变量的回归方程后再检验. 我们将在 § 4.2 中介绍变量选择问题.

④ 有关的回归统计量：决定系数 $R^2=0.9824$, 标准差 σ 的估计量 (Root MSE) 为 2.44601, 回归平方和 $U=2667.8994$, 残差平方和 $Q=47.9837$.