

判别分析



2023-2024学年第一学期

课程编码：03521003

主讲：董晓东

目录



- 距离判别
- 贝叶斯判别和广义平方判别

判别分析



判别分析是用于判断样品所属类型的一种统计分析方法.

在生产、科研和日常生活中经常遇到如何根据观测到的数据资料对所研究的对象进行判别归类的问题.

例如:在医学诊断中,一个病人肺部有阴影,医生要判断他是肺结核、肺部良性肿瘤还是肺癌.这里肺结核病人、良性瘤病人、肺癌病人组成三个总体,病人来源于这三个总体之一,判别分析的目的是通过测得病人的指标(阴影的大小,边缘是否光滑,体温多少.....)来判断他应该属哪个总体(即判断他生什么病).

判别分析



在气象学中,由气象资料判断明天是阴天还是晴天,是有雨还是无雨.

在市场预测中,由调查资料判断下季度(或下个月)产品是畅销、平常或滞销.**股票持有者**根据某种股票近期的变化情况判断此种股票价格下一周是上升还是下跌.

在环境科学中,由气象条件,污染浓度等判断该地区是属于严重污染,一般污染还是无污染.

在地质勘探中,由岩石标本的多种特征判断地层的地质年代,是有矿还是无矿,是富矿还是贫矿.

在体育运动中,由运动员的多项运动指标来判定游泳运动员的"苗子"是适合练蛙泳,仰泳还是自由泳等

判别分析



判别分析是应用性很强的一种多元统计方法,已渗透到各个领域.但不管是哪个领域,判别分析问题都可以这样描述:

设有 k 个 m 维总体 $G_1, G_2, \dots, G_k$,其分布特征已知(如已知分布函数分别为 $F_1(x), F_2(x), \dots, F_k(x)$, 或知道来自各个总体的训练样本).对给定的一个新样品 X ,我们要判断它来自哪个总体.

在进行判别归类时,由假设的前提,判别的依据及处理的手法不同,可得出不同判别方法.如距离判别, Bayes判别, Fisher判别或典型判别,逐步判别,序贯判别等.本章介绍几个常用的判别方法.

判别分析



距离判别的基本思想是：
样品和哪个总体距离最近，就判它属
哪个总体。

距离判别也称为直观判别法。

我们在具体讨论距离判别法之前，应给出合理的距离的定义。

5.1 距离判别法—马氏距离



已知有两个类 G_1 和 G_2 ，比如 G_1 是设备A生产的产品， G_2 是设备B生产的同类产品.设备A的产品质量高(如考察指标为耐磨度 X)，其平均耐磨度 $\mu_1=80$,反映设备精度的方差 $\sigma^2(1)=0.25$;设备B的产品质量稍差，其平均耐磨度 $\mu_2=75$,反映设备精度的方差 $\sigma^2(2)=4$.今有一产品 X_0 ，测得耐磨度 $x_0=78$ ，试判断该产品是哪一台设备生产的？

直观地看， x_0 与 μ_1 (设备A)的绝对距离近些，按距离最近的原则是否应把该产品 X_0 判断为设备A生产的？

5.1 距离判别法—马氏距离



考虑一种相对于分散性的距离.记 X_0 与 G_1 , G_2 的相对平方距离为 $d^2_1(x_0)$ 或 $d^2_2(x_0)$, 则:

$$d^2_1(x_0) = \frac{(x_0 - \mu_1)^2}{\sigma^2(1)} = \frac{(78 - 80)^2}{0.25} = 16 = 4^2$$

$$d^2_2(x_0) = \frac{(x_0 - \mu_2)^2}{\sigma^2(2)} = \frac{(78 - 75)^2}{4} = 2.25 = 1.5^2$$

因为 $d_2(x_0) = 1.5 < 4 = d_1(x_0)$, 按这种距离准则应判 X_0 为设备B生产的.

5.1 距离判别法—马氏距离



设备B生产的产品质量较分散，出现 x_0 为78的可能性仍较大；

而设备A生产的产品质量较集中，出现 x_0 为78的可能性较小。

因此，判 X_0 为设备B的产品更合理。

这种相对于分散性的距离就是**马氏距离**。

5.1 距离判别法—马氏距离



一般地,我们假设 G_1 的分布为 $N(\mu^{(1)}, \sigma_1^2)$, G_2 的分布为 $N(\mu^{(2)}, \sigma_2^2)$, 则利用相对距离的定义, 可以找出分界点 μ^* (不妨设 $\mu^{(2)} < \mu^{(1)}$), 当 $\mu^{(2)} < x < \mu^{(1)}$ 时, 令

$$\frac{(x - \mu^{(1)})^2}{\sigma_1^2} = \frac{(x - \mu^{(2)})^2}{\sigma_2^2} \Rightarrow \frac{\mu^{(1)} - x}{\sigma_1} = \frac{x - \mu^{(2)}}{\sigma_2}$$

$$\Rightarrow \sigma_1(x - \mu^{(2)}) = \sigma_2(\mu^{(1)} - x) \Rightarrow x = \frac{\sigma_2\mu^{(1)} + \sigma_1\mu^{(2)}}{\sigma_1 + \sigma_2} \stackrel{\text{def}}{=} \mu^*.$$

而按这种距离最近的判别准则为:

$$\begin{cases} \text{判 } x \in G_1, \text{ 当 } x > \mu^* \\ \text{判 } x \in G_2, \text{ 当 } x \leq \mu^* \end{cases}$$


5.1 距离判别法—马氏距离

利用马氏距离对两个一维正态总体判别归类

令：

$$\frac{\mu_1\sigma_2 + \mu_2\sigma_1}{\sigma_1 + \sigma_2} \triangleq \mu^*$$

($\mu^*=79$ 为到两总体相对距离相等的分界点)



5.1 距离判别法—马氏距离



定义5.1.1(马氏距离) 设总体 G 为 m 维总体(考察 m 个指标), 均值向量为 $\mu = (\mu_1, \mu_2, \dots, \mu_m)'$, 协方差阵为 $\Sigma = (\sigma_{ij})$, 则样品 $X = (x_1, x_2, \dots, x_m)'$ 与总体 G 的马氏距离定义为

$$d^2(X, G) = (X - \mu)' \Sigma^{-1} (X - \mu)$$

$$\text{当 } m=1 \text{ 时 } d^2(x, G) = \frac{(x - \mu)'(x - \mu)}{\sigma^2} = \frac{(x - \mu)^2}{\sigma^2}$$

5.1 距离判别法—马氏距离



设有 k 个总体 $G_i (i=1, \dots, k)$, 已知来自 $G_i (i=1, \dots, k)$ 的训练样本为:

$$X_{(t)}^{(i)} = (x_{t1}^{(i)}, x_{t2}^{(i)}, \dots, x_{tm}^{(i)})' (i=1, \dots, k; t=1, 2, \dots, n_i)$$

其中 n_i 是取自 G_i 的样品个数, 则均值向量 μ_i 的估计量为

$$\begin{aligned}\bar{X}^{(i)} &= \left(\frac{1}{n_i} \sum_{t=1}^{n_i} x_{t1}^{(i)}, \dots, \frac{1}{n_i} \sum_{t=1}^{n_i} x_{tm}^{(i)} \right)' \\ &= (x_1^{-(i)}, x_2^{-(i)}, \dots, x_m^{-(i)})'\end{aligned}$$

5.1 距离判别法—马氏距离



总体 G_i 的协方差阵 Σ_i 的估计 S_i 为

$$S_i = \frac{1}{n_i - 1} A_i = \left(s_{lj}^{(i)} \right)_{m \times m}, \text{ 并称 } S_i \text{ 为组内协方差阵.}$$

其中 $A_i = \sum_{t=1}^{n_i} (X_{(t)}^{(i)} - \bar{X}^{(i)})(X_{(t)}^{(i)} - \bar{X}^{(i)})'$ 称为组内离差阵,

$$s_{lj}^{(i)} = \frac{1}{n_i - 1} \sum_{t=1}^{n_i} (x_{tl}^{(i)} - \bar{x}_l^{(i)})(x_{tj}^{(i)} - \bar{x}_j^{(i)})$$

$$(l, j = 1, 2, \dots, m)$$

5.1 距离判别法—马氏距离

当假定 $\Sigma_1 = \dots = \Sigma_k = \Sigma$ 时, 反映分散性的协方差阵 Σ 的估计 S 为

$$S = \frac{1}{n-k} \sum_{i=1}^k A_i = (s_{lj})_{m \times m}, \text{ 并称 } S \text{ 为合并样本协差阵;}$$

$$\text{其中 } s_{lj} = \frac{1}{n-k} \sum_{i=1}^k \sum_{t=1}^{n_i} (x_{tl}^{(i)} - \bar{x}_l^{(i)})(x_{tj}^{(i)} - \bar{x}_j^{(i)})$$
$$(l, j = 1, 2, \dots, m)$$

问题是对任给定的 m 维样品 $X = (x_1, x_2, \dots, x_m)'$, 要判断它来自哪个总体.

5.1 距离判别法—马氏距离



最直观的想法是分别计算样品 X 到两个总体的距离 $d^2_1(X)$ 和 $d^2_2(X)$ (或记为 $d^2(X, G_1)$ 和 $d^2(X, G_2)$), 并按距离最近准则判别归类, 即判别准则为:

判 $X \in G_1$, 当 $d^2(X, G_1) < d^2(X, G_2)$ 时,

判 $X \in G_2$, 当 $d^2(X, G_1) > d^2(X, G_2)$ 时,

待判, 当 $d^2(X, G_1) = d^2(X, G_2)$ 时.

这里的距离指马氏距离. 利用马氏距离的定义及两总体协差阵相等的假设, 可以简化马氏距离的计算公式.

5.1 距离判别法—马氏距离



$$\begin{aligned}d^2(X, G_i) &= (X - \bar{X}^{(i)})' S^{-1} (X - \bar{X}^{(i)}) \\&= X' S^{-1} X - 2 \left[X' (S^{-1} \bar{X}^{(i)}) - \frac{1}{2} (\bar{X}^{(i)})' S^{-1} \bar{X}^{(i)} \right] \\&= X' S^{-1} X - 2Y_i(X) \quad (i = 1, 2)\end{aligned}$$

对给定样品 X ，为比较 X 到各总体的马氏距离，
只须计算 $Y_i(X)$ ：

$$Y_i(X) = X' (S^{-1} \bar{X}^{(i)}) - \frac{1}{2} (\bar{X}^{(i)})' S^{-1} \bar{X}^{(i)} \quad (i = 1, 2)$$

5.1 距离判别法—马氏距离



因为函数 $Y_i(X)$ 是 X 的线性函数 ($i=1, 2$), 故称为线性判别函数

$$Y_i(X) = X'(S^{-1}\bar{X}^{(i)}) - \frac{1}{2}(\bar{X}^{(i)})'S^{-1}\bar{X}^{(i)} \quad (i = 1, 2)$$

判别系数向量

常数项

5.1 距离判别法—马氏距离

若考察这两个马氏距离之差, 经计算可得:

$$\begin{aligned}d_2^2(X) - d_1^2(X) &= X'S^{-1}X - 2Y_2(X) - [X'S^{-1}X - 2Y_1(X)] \\&= 2[Y_1(X) - Y_2(X)] = 2W(X) \\W(X) &= \underbrace{[(S^{-1}\bar{X}^{(1)})'X]}_{\text{pink underline}} - \frac{1}{2}(\bar{X}^{(1)})'S^{-1}\bar{X}^{(1)} + \frac{1}{2}(\bar{X}^{(1)})'S^{-1}\bar{X}^{(2)} \\&\quad - \underbrace{[(S^{-1}\bar{X}^{(2)})'X]}_{\text{pink underline}} - \frac{1}{2}(\bar{X}^{(2)})'S^{-1}\bar{X}^{(2)} - \frac{1}{2}(\bar{X}^{(2)})'S^{-1}\bar{X}^{(1)} \\&= \underbrace{(\bar{X}^{(1)} - \bar{X}^{(2)})'S^{-1}X}_{\text{pink underline}} - \frac{1}{2}(\bar{X}^{(1)})'S^{-1}[\bar{X}^{(1)} - \bar{X}^{(2)}] \\&\quad - \frac{1}{2}(\bar{X}^{(2)})'S^{-1}[\bar{X}^{(1)} - \bar{X}^{(2)}]\end{aligned}$$

5.1 距离判别法—马氏距离



$$\begin{aligned} &= \underline{X'S^{-1}[\bar{X}^{(1)} - \bar{X}^{(2)}]} - \frac{1}{2}(\bar{X}^{(1)} + \bar{X}^{(2)})' \underline{S^{-1}[\bar{X}^{(1)} - \bar{X}^{(2)}]} \\ &= [X - \frac{1}{2}(\bar{X}^{(1)} + \bar{X}^{(2)})]' S^{-1} [\bar{X}^{(1)} - \bar{X}^{(2)}] \end{aligned}$$

即 $W(X) = (X - X^*)' S^{-1} (\bar{X}^{(1)} - \bar{X}^{(2)}),$

$$X^* = \frac{1}{2}(\bar{X}^{(1)} + \bar{X}^{(2)}),$$

5.1 距离判别法—马氏距离

则判别准则还可以写为：

判 $X \in G_1$, 当 $W(X) > 0$ 时,

判 $X \in G_2$, 当 $W(X) < 0$ 时

待判, 当 $W(X) = 0$ 时.

$W(X)$ 是 X 的线性函数, 即

$$W(X) = a'(X - X^*) = Y_1(X) - Y_2(X),$$

其中 $a = S^{-1}(X^{(1)} - X^{(2)})$,

$W(X)$ 也称为线性判别函数, a 为判别系数.

5.1 距离判别法—马氏距离

$W(X)$ 把 m 维空间 R^m 划分为三部分:

$$D_1 = \{X: W(X) > 0\}, D_2 = \{X: W(X) < 0\},$$

$$D_0 = \{X: W(X) = 0\}.$$

则 D_1, D_2, D_0 是 R^m 的一个划分.

显然,判别方法的最终结果是得到 R^m 中的一个划分.由判别函数 $W(X)$ 得到划分 D_1, D_2, D_0


当样品 X 落入 D_1 时判 $X \in G_1$,

当样品 X 落入 D_2 时,判 $X \in G_2$,

当样品 X 落入 D_0 时,待判.

5.1 距离判别法—马氏距离

例如 $m=2$ 时,直线 $W(X)=0$ 把平面分为两个区域 D_1 和 D_2 .



5.1 距离判别法—马氏距离



考察 $m=1$ 的特殊情况,并设两总体为正态总体,其分布已知为 $N(\mu_1, \sigma^2)$ 和 $N(\mu_2, \sigma^2)$ (两总体的方差相同,记为 σ^2),这时判别函数为

$$W(x) = \left(x - \frac{\mu_1 + \mu_2}{2}\right) \frac{1}{\sigma^2}(\mu_1 - \mu_2) = a(x - \bar{\mu})$$


其中

$$\bar{\mu} = \frac{\mu_1 + \mu_2}{2}, a = \frac{\mu_1 - \mu_2}{\sigma^2}$$

不妨设 $\mu_1 > \mu_2$,则 a 为正数, $W(x)$ 的符号取决于 $x > \bar{\mu}$ 或 $x < \bar{\mu}$.

5.1 距离判别法—马氏距离

用这种判别法会发生错判, 如 X 来自 G_1 , 但却落入 D_2 , 被判为属 G_2 . 错判的概率为下图中阴影左半部分的面积, 并记为 $P(2|1)$. 类似有 $P(1|2)$.



5.1 距离判别法—马氏距离



上例中,当 $\mu_1=80, \mu_2=75, \sigma=2$ 时
分界点 $\mu=(80+75)/2=77.5$,故错判概率为

$$\begin{aligned} P(2|1) &= P\{X < 77.5 | X \in G_1\} \quad (X \sim N(80, 4)) \\ &= P\{(X-80)/2 < (77.5-80)/2\} \\ &= P\{U < -1.25\} \quad (U=(X-80)/2 \sim N(0, 1)) \\ &= 1 - \Phi(1.25) = 0.1056 \end{aligned}$$

$$\begin{aligned} P(1|2) &= P\{X > 77.5 | X \in G_2\} \quad (X \sim N(75, 4)) \\ &= P\{(X-75)/2 > (77.5-75)/2\} \\ &= P\{U > 1.25\} \quad (U=(X-75)/2 \sim N(0, 1)) \\ &= 1 - \Phi(1.25) = 0.1056 = P(2|1) \end{aligned}$$

5.1 距离判别法—马氏距离



一般地, 经计算可得:

$$P(2|1) = P(1|2) = 1 - \Phi\left(\frac{\mu_1 - \mu_2}{2\sigma}\right)$$

由错判概率的公式及上图可见, 当两总体均值靠得很近(即 $|\mu_1 - \mu_2|$ 很小)时, 则错判概率很大, 这时作判别分析是没有意义的. 因此只有当两总体的均值有显著性差异时, 作判别分析才有意义.

5.1 距离判别法—马氏距离

简例1: 记二维正态总体 $N_2(\mu^{(i)}, \Sigma)$ 为 $G_i (i=1, 2)$ (两总体协差阵相同), 已知来自 $G_i (i=1, 2)$ 的样本数据阵为

$$X_{4 \times 2}^{(1)} = \begin{pmatrix} 2 & 12 \\ 4 & 10 \\ 3 & 8 \\ 3 & 10 \end{pmatrix}, \quad X_{3 \times 2}^{(2)} = \begin{pmatrix} 5 & 7 \\ 3 & 9 \\ 4 & 5 \end{pmatrix} \cdot \begin{pmatrix} k=2, & m=2 \\ n_1=4, & n_2=3 \end{pmatrix}$$

(1) 试求两总体的样本组内离差阵 A_1, A_2 和合并样本协差阵 S .

(2) 今有样品 $x_0 = (2, 8)$, 试问按马氏距离准则样品 x_0 应判归哪一类.

5.1 距离判别法—马氏距离

(1) 解: $\bar{X}^{(1)} = \begin{pmatrix} 3 \\ 10 \end{pmatrix}, \bar{X}^{(2)} = \begin{pmatrix} 4 \\ 7 \end{pmatrix}.$

$$\tilde{X}_{4 \times 2}^{(1)} = \begin{pmatrix} -1 & 2 \\ 1 & 0 \\ 0 & -2 \\ 0 & 0 \end{pmatrix}, A_1 = (\tilde{X}^{(1)})' \tilde{X}^{(1)} = \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix}$$

$$\tilde{X}_{3 \times 2}^{(2)} = \begin{pmatrix} 1 & 0 \\ -1 & 2 \\ 0 & -2 \end{pmatrix}, A_2 = (\tilde{X}^{(2)})' \tilde{X}^{(2)} = \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix}$$

5.1 距离判别法—马氏距离

样本合并组内离差阵 A 为

$$A = A_1 + A_2 = \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix} + \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix} = \begin{pmatrix} 4 & -4 \\ -4 & 16 \end{pmatrix}, \text{故}$$

$$S = \frac{1}{n_1 + n_2 - 2} A = \frac{1}{5} \begin{pmatrix} 4 & -4 \\ -4 & 16 \end{pmatrix} = \frac{4}{5} \begin{pmatrix} 1 & -1 \\ -1 & 4 \end{pmatrix},$$

而且 $|S| = \left(\frac{4}{5}\right)^2 \begin{vmatrix} 1 & -1 \\ -1 & 4 \end{vmatrix} = \frac{16}{25} \times 3 = \frac{48}{25},$

$$S^{-1} = \frac{25}{48} \times \frac{4}{5} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} = \frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix}$$

5.1 距离判别法—马氏距离

(2) 解一: 计算马氏距离

$$d_1^2(x_0) = (x_0 - \bar{X}^{(1)})' S^{-1} (x_0 - \bar{X}^{(1)}) = (-1, -2) \frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ -2 \end{pmatrix}$$

$$= \frac{5}{12} (-1, -2) \begin{pmatrix} -6 \\ -3 \end{pmatrix} = 5$$

$$d_2^2(x_0) = (x_0 - \bar{X}^{(2)})' S^{-1} (x_0 - \bar{X}^{(2)}) = (-2, 1) \frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} -2 \\ 1 \end{pmatrix}$$

$$= \frac{5}{12} (-2, 1) \begin{pmatrix} -7 \\ -1 \end{pmatrix} = \frac{5 \times 13}{12} = 5.4167$$

因 $d_1^2(x_0) < d_2^2(x_0)$, 故判 $x_0 \in G_1$.

5.1 距离判别法—马氏距离



(2) 解二: 计算线性判别函数 $Y_i(X)$ ($i=1, 2$)

$$Y_i(X) = (S^{-1} \bar{X}^{(i)})' X - \frac{1}{2} (\bar{X}^{(i)})' S^{-1} \bar{X}^{(i)} \quad (i=1, 2).$$

$$a_1 = S^{-1} \bar{X}^{(1)} = \frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 10 \end{pmatrix} = \frac{5}{12} \begin{pmatrix} 22 \\ 13 \end{pmatrix},$$

$$a_2 = S^{-1} \bar{X}^{(2)} = \frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 4 \\ 7 \end{pmatrix} = \frac{5}{12} \begin{pmatrix} 23 \\ 11 \end{pmatrix},$$

$$C_1 = -\frac{1}{2} (\bar{X}^{(1)})' a_1 = -\frac{1}{2} \times \frac{5}{12} (3, 10) \begin{pmatrix} 22 \\ 13 \end{pmatrix} = -\frac{245}{6} = -40.8333,$$

$$C_2 = -\frac{1}{2} (\bar{X}^{(2)})' a_2 = -\frac{1}{2} \times \frac{5}{12} (4, 7) \begin{pmatrix} 23 \\ 11 \end{pmatrix} = -\frac{5 \times 169}{24} = -35.2083.$$

5.1 距离判别法—马氏距离



线性判别函数为

$$Y_1(X) = \frac{5}{12}(22X_1 + 13X_2) - 40.8333,$$

$$Y_2(X) = \frac{5}{12}(23X_1 + 11X_2) - 35.2083.$$

当 $x_0 = \begin{pmatrix} 2 \\ 8 \end{pmatrix}$ 时, $Y_1(x_0) = 20.8333, Y_2(x_0) = 20.6250$.

因 $Y_1(x_0) > Y_2(x_0)$, 故判 $x_0 \in G_1$.

5.1 距离判别法—马氏距离

(2) 解三: 计算线性判别函数 $W(X)$

$$W(X) = \frac{1}{2}[d_2^2(X) - d_1^2(X)] = Y_1(X) - Y_2(X) = (X - X^*)'a$$

$$\text{其中 } X^* = \frac{1}{2}(\bar{X}^{(1)} + \bar{X}^{(2)}) = \frac{1}{2}\left[\begin{pmatrix} 3 \\ 10 \end{pmatrix} + \begin{pmatrix} 4 \\ 7 \end{pmatrix}\right] = \begin{pmatrix} 3.5 \\ 8.5 \end{pmatrix}$$

$$a = S^{-1}(\bar{X}^{(1)} - \bar{X}^{(2)}) = \frac{5}{12}\begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix}\begin{pmatrix} -1 \\ 3 \end{pmatrix} = \frac{5}{12}\begin{pmatrix} -1 \\ 2 \end{pmatrix}, \text{因而}$$

$$W(X) = \frac{5}{12}(X_1 - 3.5, X_2 - 8.5)\begin{pmatrix} -1 \\ 2 \end{pmatrix} = \frac{5}{12}(-X_1 + 2X_2 - 13.5).$$

$$\text{由于 } W(x_0) = \frac{5}{12}(-2 + 2 \times 8 - 13.5) = \frac{5}{24} > 0, \text{故判 } x_0 \in G_1.$$

5.1 距离判别法—马氏距离



当两总体协差阵不等时, 按距离判别准则先分别计算 X 到两个总体的距离 $d^2(X, G_1)$ 和 $d^2(X, G_2)$, 然后按距离最近准则判别归类. 或者类似地计算判别函数 $W(X)$, 并用于判别归类.

令 $W(X) = d^2(X, G_2) - d^2(X, G_1) = \dots = Z(X) - Z_0$,

其中 $Z(X)$ 为 X 的二次函数(因 $\Sigma_1 \neq \Sigma_2$), Z_0 是一常数(具体表达式省略了). 判别准则仍可以写为:

判 $X \in G_1$, 当 $W(X) > 0$ 时, 或者

判 $X \in G_2$, 当 $W(X) < 0$ 时, 判 $X \in G_1$, 当 $W(X) > 0$ 时,
待判, 当 $W(X) = 0$ 时. 判 $X \in G_2$, 当 $W(X) \leq 0$ 时.

5.1 距离判别法—马氏距离



当 $m=1$,两总体为正态总体时,记 G_i 的均值为 μ_i ,方差为 σ_i^2 ($i=1,2$),这时马氏距离的平方根为

$$d(x, G_i) = \frac{|x - \mu_i|}{\sigma_i} \quad (i = 1, 2)$$

不妨设 $\mu_1 > \mu_2, \sigma_1 < \sigma_2$,观测值 x 满足: $\mu_2 < x < \mu_1$ 时

$$d_2(x) - d_1(x) = \frac{x - \mu_2}{\sigma_2} - \frac{\mu_1 - x}{\sigma_1} = \frac{\sigma_1 + \sigma_2}{\sigma_1 \sigma_2} (x - \mu^*)$$

其中 $\mu^* = \frac{\mu_1 \sigma_2 + \mu_2 \sigma_1}{\sigma_1 + \sigma_2}$ 是 μ_1, μ_2 的加权平均值

5.1 距离判别法—马氏距离



分界点 μ^* 把区间 (μ_2, μ_1) 分为两部分:

$$D_1 = \{\mu_1 > x > \mu^*\}$$

和

$$D_2 = \{\mu_2 < x \leq \mu^*\}.$$

这时判别准则为

判 $X \in G_1$, 当 $\mu_1 > x > \mu^*$ 时,

判 $X \in G_2$, 当 $\mu_2 < x \leq \mu^*$ 时,

5.1 距离判别法—马氏距离



设有 k 个 m 维总体: $G_1, G_2, \dots, G_k$ ($k > 2$). 它们的均值, 协差阵分别为 μ_i, Σ_i ($i=1, 2, \dots, k$). 对任给定的 m 维样品 $X = (x_1, x_2, \dots, x_m)'$, 要判断它来自哪个总体.

多个总体的情况, 按距离最近的准则对 X 进行判别归类时, 首先计算样品 X 到 k 个总体的马氏距离 $d^2_i(X)$ ($i=1, 2, \dots, k$), 然后进行比较, 把 X 判归距离最小的那个总体.

5.1 距离判别法—马氏距离



设 $i = l$ 时, 若 $d_i^2(X) = \min_{i=1, \dots, k} \{d_i^2(X)\}$, 则 $X \in G_l$.

计算马氏距离 $d_i^2(X)$ ($i = 1, 2, \dots, k$) 时, 类似地可考虑 $\Sigma_1 = \Sigma_2 = \dots = \Sigma_k$ 或 Σ_i 不全相等的两种情况。并用样本统计量作为 μ_i 和 Σ_i 的估计。

5.2 贝叶斯判别和广义平方判别



距离判别只要求知道总体的特征量(即参数)---均值和协差阵,不涉及总体的分布类型.

当参数未知时,就用样本均值和样本协差阵来估计. 距离判别方法简单,结论明确,是很实用的方法. 但该方法也有缺点:

1. 该判别法与各总体出现的机会大小(先验概率)完全无关;
2. 判别方法没有考虑错判造成的损失,这是不合理的.

Bayes判别法正是为解决这两方面问题而提出的判别方法.

5.2 贝叶斯判别和广义平方判别



Bayes的统计思想总是假定对所研究的对象已有一定的认识,常用先验概率分布来描述这种认识.然后我们抽取一个样本,用样本来修正已有的认识(先验概率分布),得到后验概率分布.

各种统计推断都通过后验概率分布来进行.将贝叶斯思想用于判别分析就得到贝叶斯判别法.

5.2 贝叶斯判别和广义平方判别



设有 k 个总体 $G_1, G_2, \dots, G_k$. 假设事先对所研究的问题有一定的认识, 这种认识常用先验概率来描述. 即已知这 k 个总体各自出现的概率(验前概率)为 $q_1, q_2, \dots, q_k$ (显然 $q_i > 0, q_1 + q_2 + \dots + q_k = 1$).

比如研究人群中得癌(G_1)和没有得癌(G_2)两类群体的问题, 由长期经验知: $q_1 = 0.001, q_2 = 0.999$. 这组验前概率 $q_1, \dots, q_k$ 称为先验概率. 先验概率是一种权重(比例). 所谓“先验”是指先于我们抽取样品作判别分析之前.

Bayes判别准则要求给出 $q_i (i=1, 2, \dots, k)$ 的值.

5.2 贝叶斯判别和广义平方判别



q_i 的赋值方法有以下几种:

(a) 利用历史资料及经验进行估计. 例如某地区成年人中得癌症的概率为 $P(\text{癌})=0.001=q_1$, 而 $P(\text{无癌})=0.999=q_2$.

(b) 利用训练样本中各类样品占的比例 n_i/n 做为 q_i 的值, 即 $q_i=n_i/n (i=1, \dots, k)$, 其中 n_i 是第 i 类总体的样品个数, 而 $n=n_1+n_2+\dots+n_k$. 这时要求训练样本是通过随机抽样得到的, 各类的样品被抽到的机会大小就是验前概率.

(c) 假定 $q_1=q_2=\dots=q_k=1/k$.

5.2 贝叶斯判别和广义平方判别

在马氏距离判别的基础上, 进一步考虑先验概率及各组内协差阵的不同, 可定义样品 X 到总体 G_t 的广义平方距离 $D_t^2(X)$ 或 $D^2(X, G_t)$ 为:

$$D_t^2(X) = D^2(X, G_t) = d_t^2(X) + g_1(t) + g_2(t)$$

其中 $g_1(t) = \begin{cases} \log |S_t| & \text{若组内协差阵 } \Sigma_t \text{ 不全等} \\ 0 & \text{若组内协差阵相等} \end{cases}$

S_t 为第 i 类的组内样本协差阵)

$$g_2(t) = \begin{cases} -2\log |q_t| & \text{若先验概率不全相等} \\ 0 & \text{若先验概率全相等} \end{cases}$$

5.2 贝叶斯判别和广义平方判别



由 $D_t^2(X)$ 的公式可见, 当 $d_t^2(X)$ 不变, 而某个 q_t 大 (即总体 G_t 出现的机会大) 时, 则 $g_2(t)$ 变小, 故广义平方距离也变小, 进而判 X 为 G_t 的可能性大——符合直观想法.

当 Σ_i 不全相等时, $g_1(t) = \text{Log} |S_t|$, 且马氏距离 $d_t^2(X)$ 的公式中也考虑了 Σ_i 的不等, 这时广义平方距离中的 $g_1(t)$ 可看成是一种修正.

5.2 贝叶斯判别和广义平方判别



引入 $g_l(t)$ 后,使广义平方距离判别法的概率意义更明显:

广义平方距离判别法 $\Leftrightarrow$ 后验概率判别法

利用广义平方距离的判别法为:

判 $X \in G_t$, 当 $D_t^2(X) < D_i^2(X) \ (i \neq t, i = 1, \dots, k)$

(后验概率及后验概率判别法将在下面介绍)

5.2 贝叶斯判别和广义平方判别



标准的Bayes方法应该计算后验概率分布. 即计算当样品 X 已知时, 它属于 G_t 的概率, 记为 $P(G_t|X)$ (或 $P(t|X)$), 这个概率作为判别归类的准则, 其概率意义更为直观.

假定总体 G_t 的概率密度函数 $f_t(x)$ ($t=1, \dots, k$) 给定, 由条件概率的定义可以导出:

$$P(t | X) = P\{X \in G_t | X \text{ 已知}\} = \frac{q_t f_t(x)}{\sum_{i=1}^k q_i f_i(x)}$$

5.2 贝叶斯判别和广义平方判别



$$P(t | X = x) = \lim_{\sigma(x) \rightarrow x} P\{X \in G_i | X \in \sigma(x)\}$$

($\sigma(x)$ 是半径为 ρ 包含 x 的小区域)

$$= \lim_{\rho \rightarrow 0} \frac{P\{X \in G_i \text{ 且 } X \in \sigma(x)\}}{P\{X \in \sigma(x)\}}$$

$$= \lim_{\rho \rightarrow 0} \frac{P\{X \in G_i\} P\{X \in \sigma(x) | X \in G_i\}}{\sum_{i=1}^k P\{X \in G_i\} P\{X \in \sigma(x) | X \in G_i\}}$$

$$= \lim_{\rho \rightarrow 0} \frac{q_i \int_{\sigma(x)} f_i(x) dx}{\sum_{i=1}^k q_i \int_{\sigma(x)} f_i(x) dx} = \frac{q_i f_i(x)}{\sum_{i=1}^k q_i f_i(x)}$$

5.2 贝叶斯判别和广义平方判别

若假设 $G_i (i=1, \dots, k)$ 为 m 维正态总体, 其密度函数 $f_i(x)$ 为

$$\begin{aligned} f_i(x) &= \frac{1}{(2\pi)^{\frac{m}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(x - \mu^{(i)})' \Sigma_i^{-1} (x - \mu^{(i)})\right] \\ &= \frac{1}{(2\pi)^{\frac{m}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}d_i^2(x)\right] \end{aligned}$$

$$q f_i(x) = \exp\left[\text{Ln} q_i - \frac{1}{2} \text{Ln} |\Sigma_i| - \frac{1}{2} d_i^2(x)\right] (2\pi)^{-\frac{m}{2}}$$

5.2 贝叶斯判别和广义平方判别

$$\begin{aligned} q f_i(x) &= \exp\left[\ln q_i - \frac{1}{2} \ln |\Sigma_i| - \frac{1}{2} d_i^2(x)\right] (2\pi)^{-\frac{n}{2}} \\ &= \exp\left[-\frac{1}{2}(-2\ln q_i + \ln |\Sigma_i| + d_i^2(x))\right] (2\pi)^{-\frac{n}{2}} \\ &= \exp\left[-\frac{1}{2} D_i^2(x)\right] (2\pi)^{-\frac{n}{2}} \end{aligned}$$

则 X 属于第 i 组的后验概率为：

$$P(i | X) = \frac{\exp(-0.5 D_i^2(x))}{\sum_{i=1}^k \exp(-0.5 D_i^2(x))}$$

其中 $D_i^2(x)$ 是 X 到第 i 组的广义平方距离。

5.2 贝叶斯判别和广义平方判别



在正态假设下按后验概率最大进行归类的准则，等价于按广义平方距离最小准则进行归类。而按后验概率最大准则归类的判别法就是Bayes判别的一种情况。

一般Bayes判别即考虑先验概率的不同，还考虑了错判损失的大小，在这里我们假定错判损失相等。

5.2 贝叶斯判别和广义平方判别



所谓Bayes判别准则,就是给出空间 R^m 一个划分 $D=\{D_1, D_2, \dots, D_k\}$,使得当通过这个划分D来判别归类时,所带来的平均损失达到最小.

定义5.2.1 设有 k 个总体: $G_1, G_2, \dots, G_k$,相应的先验概率为 $q_1, q_2, \dots, q_k$ ($q_i > 0, q_1 + \dots + q_k = 1$). 如果有判别法 D^* ,使得 D^* 带来的平均损失 $g(D^*)$ 达最小,即

$$g(D^*) = \min_{\text{一切 } D} g(D)$$

则称判别法 D^* 符合Bayes准则,或称 D^* 为Bayes判别的解.

5.2 贝叶斯判别和广义平方判别



有了先验概率的概念后, 判别法 D 关于先验概率的错判平均损失 $g(D)$ 定义为

$$g(D) = \sum_{t=1}^k q_t \sum_{j=1}^k P(j|t) L(j|t) \triangleq \sum_{t=1}^k q_t r_t(D)$$

其中 $r_t(D)$ 表示实属 G_t 的样品被错判为其他总体的损失.

$L(j|i;D)$ (简记为 $L(j|i)$) 表示样品实属第 i 个总体 G_i , 今用判别法 D 判别时被错判为 $G_j (j \neq i)$ 时所造成的损失.

5.2 贝叶斯判别和广义平方判别

$P(j|i;D)$ (或简记为 $P(j|i)$) 表示用判别法 D 把实属 G_i 的样品错判为 G_j 的概率.

当总体 G_i 的分布密度已知 (记为 $f_i(x_1, \dots, x_m)$), 可以计算错判概率:

$$P\{j|i;D\} = \int \cdots \int_{D_j} f_i(x_1, \dots, x_m) dx_1 \cdots dx_m$$

错判概率 $P(j|i)$ 虽可以计算, 但在实际应用中常使用估计的方法。

5.2 贝叶斯判别和广义平方判别



当样品 $X \in G_i$, 但用判别法 D 判别时, 把 X 判归 G_j (即 X 落入区域 D_j , $j \neq i$), 这时判错了.

错判概率 $P(j|i)$ 估计方法 有以下几种:

- ① 利用训练样本作为检验集;
- ② 可留出一些已知类别的样品不参加建立判别准则, 而是作为检验集;
- ③ 舍一法 (或称交叉确认法), 每次留出一个已知类别的样品, 而用其余 $n-1$ 个样品建立判别准则, 然后对留出的这一个已知类别的样品进行判别归类. 对训练样本中 n 个样品按此法逐个归类后, 最后把错判的比率作为错判率的估计.

5.2 贝叶斯判别和广义平方判别



在实际问题中,错判的损失可以给出定性的分析,但很难用数值来表示.但应用Bayes判别准则时,要求定量地给出 $L(j|i)$.

$L(j|i)$ 的赋值法常用的有以下两种:

(a) 由经验人为赋值.例如

$$L(\text{判癌}|\text{得肺结核})=10,$$

$$L(\text{判肺结核}|\text{得癌症})=1000.$$

(b) 假定各种错判损失都相等.

5.2 贝叶斯判别和广义平方判别

定理5.2.1: 设有 k 个总体: $G_1, G_2, \dots, G_k$, 已知 G_i 的联合密度函数为 $f_i(X)$, 先验概率为 $q_i (i=1, \dots, k)$, 错判损失为 $L(j|i)$. 则Bayes判别的解 $D^* = \{D_1^*, \dots, D_k^*\}$ 为

$$D_t^* = \{X \mid h_t(X) < h_j(X), j \neq t, j = 1, 2, \dots, k\} \\ (t = 1, 2, \dots, k)$$

其中 $h_j(X) = \sum_{i=1}^k q_i L(j|i) f_i(X)$, 它表示把样品 X 判归 G_j 的平均损失。

5.2 贝叶斯判别和广义平方判别

证明： 根据定义5.2.1来证明 D^* 带来的平均损失最小。

$$\begin{aligned} g(D^*) &= \sum_{i=1}^k q_i \sum_{t=1}^k L(t|i) \int_{D_t^*} f_i(X) dX \\ &= \sum_{t=1}^k \int_{D_t^*} \left(\sum_{i=1}^k q_i L(t|i) f_i(X) \right) dX \\ &= \sum_{t=1}^k \int_{D_t^*} h_t(X) dX \end{aligned}$$

5.2 贝叶斯判别和广义平方判别



如果 $D = \{D_1, \dots, D_k\}$ 是 R^m 上的任一种划分, 则它带来的平均损失为

于是

$$g(D) = \sum_{j=1}^k \int_{D_j} h_j(X) dX$$

$$\begin{aligned} g(D^*) - g(D) &= \sum_{i=1}^k \int_{D_i^*} h_i(X) dX - \sum_{j=1}^k \int_{D_j} h_j(X) dX \\ &= \sum_{j=1}^k \sum_{i=1}^k \int_{D_i^* \cap D_j} [h_i(X) - h_j(X)] dX \end{aligned}$$

5.2 贝叶斯判别和广义平方判别



由 D^* 的定义知在 D_t^* 上恒有 $h_t(X) < h_j(X)$ ($j=1, \dots, k$), 所以

$$g(D^*) - g(D) \leq 0$$
$$g(D^*) = \min_{\text{一切 } D} g(D)$$

即

根据定义5.2.1由知 D^* 是Bayes判别的解.
判别方法:

对样品 X , 分别计算 k 个 $h_j(X)$ ($j=1, \dots, k$), 选其最小者, 即可判定样品来自相应的总体.

5.2 贝叶斯判别和广义平方判别

推论 当错判损失都相等 (当 i 不等于 j 时, $L(i|j)=1$), 根据 $h_j(X)$ 的公式, 即得 Bayes 判别的解 $D^* = \{D_1^*, \dots, D_k^*\}$ 为

$$D_t^* = \{X \mid q_t f_t(X) > q_j f_j(X), j \neq t, j = 1, 2, \dots, k\}$$
$$(t = 1, 2, \dots, k)$$

其中 $f_j(X)$ 是 G_j 的联合概率密度函数。

$$\text{其实 } h_t(X) = \sum_{i=1}^k q_i L(t|i) f_i(X) = \sum_{i \neq t}^k q_i f_i(X) = C(X) - q_t f_t(X)$$

$h_t(X)$ 最小 $\iff q_t f_t(X)$ 最大.

5.2 贝叶斯判别和广义平方判别

设 G_j 来自正态总体 $N_m(\mu^{(j)}, \Sigma_j)$ ($j=1, \dots, k$), 并假定错判损失相等, 先验概率为 $q_1, q_2, \dots, q_k$.

当 $\Sigma_1 = \Sigma_2 = \dots = \Sigma_m = \Sigma$ 时, 设第 j 个总体的样本均值为 $\bar{X}^{(j)}$, 合并样本协差阵为 S . 把样本均值和协差阵代入正态密度函数 $f_j(X)$, 经计算:

$$\begin{aligned} \text{Ln} q_j f_j(x) &= \text{Ln} q_j - \frac{1}{2} (\bar{X}^{(j)})' S^{-1} \bar{X}^{(j)} + \underbrace{X' S^{-1} \bar{X}^{(j)}}_{C_j} \\ &\quad - \frac{m}{2} \text{Ln}(2\pi) - \frac{1}{2} \text{Ln} |S| - \frac{1}{2} X' S^{-1} X \\ &= C_{j0} + C_j' X + C_0 = Y_j(X) + C_0 \end{aligned}$$

5.2 贝叶斯判别和广义平方判别



经整理可得Bayes判别的解

$$D^* = \{D_1^*, \dots, D_k^*\} \text{ 为}$$

$$D_t^* = \{X \mid Y_t(X) > Y_j(X), j \neq t, j = 1, 2, \dots, k\} \\ (t = 1, 2, \dots, k)$$

$$Y_j(X) = C_{j0} + C'_j X \quad (j = 1, 2, \dots, k)$$

称为线性判别函数.

5.2 贝叶斯判别和广义平方判别

当 $\Sigma_i (i=1, \dots, k)$ 不全相等时, 设第 i 个总体的样本均值为 $X^{(i)}$, 样本协差阵为 S_i . 可得 Bayes 判别的解 $D^* = \{D_1^*, \dots, D_k^*\}$ 为

$$D_t^* = \{X \mid Z_t(X) > Z_j(X), j \neq t, j = 1, 2, \dots, k\} \\ (t = 1, 2, \dots, k)$$

其中

$$\begin{aligned} Z_j(X) &= \ln q_j f_j(X) + d_0 \\ &= -\frac{1}{2} [-2\ln q_j + \ln |S_j| + d_j^2(X)] \\ &= -\frac{1}{2} D_j^2(X) \quad (d_0 = \frac{m}{2} \ln(2\pi)) \end{aligned}$$

5.2 贝叶斯判别和广义平方判别

与距离判别比较：

正态总体协差阵全相等时的Bayes判别法除线性判别函数的常数项增加考虑先验概率的部分($\ln q_t$)外，与协差阵相等情况下的马氏距离判别法是一致的。

正态总体协差阵不全相等时的Bayes判别法与协差阵不全相等情况下的广义平方距离判别法是一致的。

(假设错判损失都相等)