

聚类分析



2023-2024学年第一学期

课程编码：03521003

主讲：董晓东

目录



- 聚类分析的方法
- 距离与相似系数
- 系统聚类法
- 系统聚类法的性质及类的确定

6.1 聚类分析的方法



聚类分析又称群分析,它是研究对样品或指标进行分类的一种多元统计方法.

所谓的“类”,通俗地说就是相似元素的集合.聚类分析是按照观测样品(或变量)取值的相似程度,对观测样品(或变量)进行分类,使在同一类内的观测样品(或变量)是相似的,不同类间的观测(或变量)是不相似的.

什么是分类?它只不过是将一个观测对象指定到某一类(组).

6.1 聚类分析的方法



分类的问题可以分成两种：

一种是对当前所研究的问题已知它的类别数目,且知道各类的特征(如分布规律,或知道来自各类的训练样本),我们的目的是要将另一些未知类别的个体正确归属于其中某一类,这是第五章判别分析所要解决的问题。

另一种是事先不知道研究的问题应分为几类,更不知道观测到的个体的具体分类情况,我们的目的正是需要通过观测数据所进行的分析处理,选定一种度量个体接近程度的量,确定分类数目,建立一种分类方法,并按亲近程度对观测对象给出合理的分类.这种问题在实际中大量存在,它正是聚类分析所要解决的问题。

6.1 聚类分析的方法



聚类分析是实用多元统计分析的一个新的分支,正处于发展阶段,理论上虽不很完善,但由于它能够解决许多实际问题,因此这个方法很受人们的重视,特别是和其他方法联合起来使用往往效果更好。

例如对一批观测对象先用聚类分析进行分类,然后用判别分析的方法建立判别准则,用以对新的观测对象判别归类。

6.1 聚类分析的方法



聚类分析的方法可分为以下几种:

(1) 系统聚类法: 开始每个对象自成一类,然后每次将最相似的两类合并,合并后重新计算新类与其他类的距离或相近性测度.这一过程一直继续直到所有对象归为一类为止.并类的过程可用一张谱系聚类图描述.

(2) 调优法(动态聚类法);

(3) 最优分割法(有序样品聚类法);

(4) 模糊聚类法;

(5) 图论聚类法; (6) 聚类预报法。

6.1 聚类分析的方法



聚类分析根据分类对象的不同分为R型和Q型两大类,R型是对变量(指标)进行分类处理,Q型是对样品进行分类处理.

R型聚类分析的目的有以下方面:

- ① 了解变量间及变量组合间的亲疏关系;
- ② 对变量进行分类;
- ③ 根据分类结果及它们之间的关系,在每一类中选择有代表性的变量作为典型变量,利用少数几个典型变量进一步作分析计算,如进行回归分析或Q型聚类分析等.

6.1 聚类分析的方法



Q型聚类分析的目的主要是对样品进行分类.分类的结果是直观的,且比传统分类方法更细致、全面、合理.当然使用不同的分类方法通常会得到不同的分类结果.对任何观测数据都没有唯一“正确的”的分类方法.

实际应用中,常采用不同的分类方法,对数据进行分析计算,以便对分类提供意见,并由实际工作者决定所需要的分类数及分类情况.

本章重点介绍应用最广泛的系统聚类法;且主要讨论Q型聚类分析问题.

6.2 距离与相似系数



为了对观测样品(或变量)进行分类,就必须研究它们之间的关系.描述样品之间亲疏相似程度的统计量很多,目前用得最多的是距离和相似系数,这两个统计量的定义与变量的类型密切相关,我们首先介绍变量的类型.

6.2 距离与相似系数



根据变量取值的不同,变量可分为两大类:
定量变量和定性(属性)变量.

定量变量就是我们通常所说的连续变量,例如长度、重量、产量、人口、温度等,它们是由测量或计数、统计所得到的量,这类变量具有数值特征,称为定量变量.

.

6.2 距离与相似系数



定性(属性)变量只有性质上的差异,例如天气(阴、晴),性别(男、女),产品质量分为上中下三个等级. 这些变量都是属性(定性)变量.

属性变量又分为名义变量和有序变量二种:

(1)有序变量:其值有明确的逻辑次序,但各个值之间的距离并不清楚.

(2)名义变量:其值之间无逻辑次序,可按任何次序排序编码.例如性别,职业,地区,...都是名义变量.

不同类型的变量在定义距离或相似性测度时有很大差异.

6.2 距离与相似系数

设有 n 个样品,每个样品测得 m 项指标(变量),得观测数据 $x_{ij}(i=1,\dots,n,j=1,\dots,m)$.通常将数据列成以下表格的形式.

变 量 样 品	X_1	...	X_j	...	X_m
$X_{(1)}$	x_{11}	...	x_{1j}	...	x_{1m}
...	...		...		...
$X_{(i)}$	x_{i1}	...	x_{ij}	...	x_{im}
...	...		...		...
$X_{(n)}$	x_{n1}	...	x_{nj}	...	x_{nm}
均值	$\bar{x}_1$	...	$\bar{x}_j$	...	$\bar{x}_m$
标准差	s_1	...	s_j	...	s_m
极差	R_1	...	R_j	...	R_m

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$$

$$s_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}$$

$$(j = 1, 2, \dots, m)$$

6.2 距离与相似系数



1. **中心化变换** $x_{ij}^* = x_{ij} - \bar{x}_j \quad (i = 1, 2, \dots, n; j = 1, \dots, m)$

变换后数据的均值为0，而协差阵不变。

2. **标准化变换**

$$x_{ij}^* = \frac{x_{ij} - \bar{x}_j}{s_j} \quad \begin{pmatrix} i = 1, 2, \dots, n \\ j = 1, 2, \dots, m \end{pmatrix}$$

变换后的数据,每个变量的样本均值为0,标准差为1,而且标准化变换后的数据 $\{x_{ij}^*\}$ 与变量的量纲无关。

3. **极差标准化变换**

$$x_{ij}^* = \frac{x_{ij} - \bar{x}_j}{R_j} \quad \begin{pmatrix} i = 1, 2, \dots, n \\ j = 1, 2, \dots, m \end{pmatrix}$$

变换后的数据,每个变量的样本均值为0,极差为1,变换后的数据也是无量纲的量。

6.2 距离与相似系数



4. 极差正规化变换(规格化变换)

$$x_{ij}^* = \frac{x_{ij} - \min_{1 \leq l \leq n} x_{lj}}{R_j} \quad \begin{pmatrix} i = 1, 2, \dots, n \\ j = 1, 2, \dots, m \end{pmatrix}$$

变换后的数据 $0 \leq x_{ij}^* \leq 1$; 极差为1, 也是无量纲的量.

5. 对数变换

$$x_{ij}^* = \log(x_{ij}) \quad (\text{要求 } x_{ij} > 0) \\ (i = 1, 2, \dots, n; j = 1, 2, \dots, m)$$

它可将具有指数特征的数据结构化为线性数据结构.

6.2 距离与相似系数

描述样品间的亲疏程度最常用的是距离。


n 个样品看成 m 维空间中的 n 个点,用 d_{ij} 表示样品 $X_{(i)}$ 和 $X_{(j)}$ 之间的距离,一般要求:

① $d_{ij} \geq 0$, 对一切 i, j ;

当 $d_{ij} = 0 \iff X_{(i)} = X_{(j)}$;

② $d_{ij} = d_{ji}$, 对一切 i, j ;

③ $d_{ij} \leq d_{ik} + d_{kj}$, 对一切 i, j, k (三角不等式).



6.2 距离与相似系数



1. 闵科夫斯基(Minkowski)距离

$$d_{ij}(q) = \left[\sum_{l=1}^m |x_{il} - x_{jl}|^q \right]^{1/q} (i, j = 1, 2, \dots, n)$$

当 $q=1$ 时的一阶Minkowski度量就称为**绝对值距离**。

$$d_{ij}(1) = \sum_{l=1}^m |x_{il} - x_{jl}| \quad (i, j = 1, 2, \dots, n)$$

6.2 距离与相似系数



当 $q=2$ 时的二阶Minkowski度量称为**欧氏距离**.欧氏距离是聚类分析中用得最广泛的距离.

$$d_{ij}(2) = \sqrt{\sum_{l=1}^m |x_{il} - x_{jl}|^2} \quad (i, j = 1, 2, \dots, n)$$

当 $q=\infty$ 时的Minkowski度量称为**切比雪夫距离**.

$$d_{ij}(\infty) = \max_{1 \leq l \leq m} |x_{il} - x_{jl}| \quad (i, j = 1, 2, \dots, n).$$

6.2 距离与相似系数



缺点:(1) 与各变量的量纲有关;
(2) 没有考虑指标间的相关性;
(3) 没有考虑各变量方差的不同.如欧氏距离,变差大的变量在距离中的作用(贡献)就会大,这是不合适的.

合理的方法就是对各变量加权,如用 $1/s^2$ 作为权数可得出“统计距离”:

$$d_{ij}^* = \sqrt{\sum_{t=1}^m \left(\frac{x_{it} - x_{jt}}{s_t} \right)^2} \quad (i, j = 1, 2, \dots, n)$$

6.2 距离与相似系数



对 n 个样品计算两两间的距离 d_{ij} 后,可排成矩阵 D

$$D = \begin{pmatrix} d_{11} & d_{12} & \dots & d_{1n} \\ d_{21} & d_{22} & \dots & d_{2n} \\ \dots & \dots & \dots & \dots \\ d_{n1} & d_{n2} & \dots & d_{nn} \end{pmatrix}_{n \times n}$$

d_{ij} 值越小,表示两个样品越接近, d_{ij} 值越大,表示两个样品越不相近.

6.2 距离与相似系数



2. 兰氏距离(要求 $x_{ij} > 0$)

这是由Lance和Williams最早提出的,故称为兰氏距离.

$$d_{ij}(L) = \frac{1}{m} \sum_{l=1}^m \frac{|x_{il} - x_{jl}|}{(x_{il} + x_{jl})} \quad (i, j = 1, 2, \dots, n)$$

这是一个无量纲的量.克服了闵氏距离与各指标的量纲有关的缺点.且兰氏距离对大的奇异值不敏感,这样使得它特别适合高度偏倚的数据.

但兰氏距离也没有考虑变量间的相关性.

6.2 距离与相似系数



3. 马氏距离(Mahalanobis)

样品 $X_{(i)}$ 和 $X_{(j)}$ 的马氏距离为

$$d_{ij}(M) = (X_{(i)} - X_{(j)})' S^{-1} (X_{(i)} - X_{(j)})$$

其中 S^{-1} 为样本协差阵的逆矩阵.

马氏距离既排除了变量间相关性的干扰,而且还不受各项指标量纲的影响.另马氏对线性变换具有不变性.

6.2 距离与相似系数



马氏距离虽然可以排除变量之间相关性的干扰,并且不受量纲的影响,但是在聚类分析处理之前,如果用全部数据计算均值和协差阵来求马氏距离,效果不是很好。

比较合理的办法是用各个类的样本来计算各自的协差阵,同一类样品间的马氏距离应当用这一类的协差阵来计算,但类的形成都要依赖于样品间的距离,而样品间合理的马氏距离又依赖于类,这就形成了一个恶性循环,因此在实际聚类分析中,马氏距离也不是理想的距离。

6.2 距离与相似系数



4. 斜交空间距离

在 m 维空间中,为使具有相关性变量的谱系结构不发生变形,采用斜交空间距离,即

$$\text{令 } d_{ij} = \left[\frac{1}{m^2} \sum_{k=1}^m \sum_{l=1}^m (x_{ik} - x_{jk}) (x_{il} - x_{jl}) r_{kl} \right]^{1/2}$$
$$(i, j = 1, 2, \dots, n).$$

在数据标准化处理下, r_{kl} 为变量 X_k 和 X_l 之间的相关系数

5. 相似系数

样品间的亲疏程度除了用距离描述外,也可用相似系数来表示. 参见以下“**变量间的相似系数**”的定义.

6.2 距离与相似系数



6.定性变量样品间的距离或相似系数

下面来介绍定性变量(名义变量或有序变量)的距离或相似系数的定义方法.

在数量化理论中,常把定性变量叫做**项目**,而把定性变量的各种不同取"值"叫做**类目**.

例如性别是项目,而男或女是这个项目的类目;体形也是一个项目,而适中、胖、瘦、壮等是

这个项目的类目.性别只能取男或女中一类,不能兼取;而体形可以是适中且壮,即兼取两类.

6.2 距离与相似系数



设样品 $X_{(i)}$ 的第 k 个项目($k=1,2,\dots,m$)的取值为
 $(\delta_i(k,1),\delta_i(k,2),\dots,\delta_i(k,r_k))$ ($i=1,2,\dots,n$),
其中 n 为样品的个数, m 为项目的个数, r_k 是第 k
个项目的类目数.

$$\delta_i(k,l) = \begin{cases} 1 & \text{当第 } i \text{ 个样品中第 } k \text{ 个项目的} \\ & \text{定性数据为第 } l \text{ 个类目时,} \\ 0 & \text{否则,} \end{cases}$$

并称 $\delta_i(k,l)$ 为第 k 项目之 l 类目在第 i 个样品中的反应.

6.2 距离与相似系数

表 6.2 两样品的取值情况

项目 样品	项目 1				项目 2		项目 3					项目 4		
	1	2	3	4	1	2	1	2	3	4	5	1	2	3
$X_{(i)}$	1	0	0	0	0	1	1	0	0	0	1	0	1	0
$X_{(j)}$	0	1	0	0	0	1	0	0	1	0	1	0	1	0

设两个样品为 $X_{(i)}$ 和 $X_{(j)}$,若 $\delta_i(k,l)=\delta_j(k,l)=1$,则称这两个样品在第 k 个项目的第 l 类目上**1-1配对**;若 $\delta_i(k,l)=\delta_j(k,l)=0$,则称这两个样品在第 k 个项目之 l 类目上**0-0配对**;若 $\delta_i(k,l)\neq\delta_j(k,l)$,则称为**不配对**.

6.2 距离与相似系数



记 m_1 为 $X_{(i)}$ 和 $X_{(j)}$ 在 m 个项目的所有类目中1-1配对的总数; m_0 为0-0配对的总数; m_2 为不配对总数.显然 $m_0 + m_1 + m_2 = \text{总类目数 } p (p = r_1 + r_2 + \dots + r_m)$.

表6.2给出两个样品的取“值”情况.显然 $m_1 = 3$, $m_0 = 7$, $m_2 = 4$.项目数 $m = 4$,总类目数 $p = 14$.

6.2 距离与相似系数



(1) 两个样品为 $X_{(i)}$ 和 $X_{(j)}$ 间的距离定义为

$$d_{ij} = \frac{m_2}{m_1 + m_2}.$$

即不配对的类目数在有反应的类目(包括1-1配对和不配对)数中的比例.比如表6.2, $d_{ij}=4/7$.

6.2 距离与相似系数



当项目只能取可能类目中的一类,不能兼取的情况下,两样品的距离定义为:

$$d_{ij} = \frac{m_2^*}{m},$$

其中 m_2^* 是不配对的项目(变量)个数; m 表示项目总个数.

类似于欧氏距离,还可以定义不配对的总数:

$$d_{ij}^2 = \sum_{k=1}^m \sum_{l=1}^{r_k} (\delta_i(k, l) - \delta_j(k, l))^2.$$

6.2 距离与相似系数



(2) 样品 $X_{(i)}$ 和 $X_{(j)}$ 间的相似性度量由表6.3给出几种定义方法.这种相似性度量也称为**匹配系数**

表 6.3 两样品间相似性的几种度量

	匹配系数	说 明
1	$\frac{m_0 + m_1}{p}$	配对的总数在总类目数中的比率
2	$\frac{m_1}{p}$	1 - 1 配对的总数在总类目数中的比率
3	$\frac{m_1}{m_1 + m_2}$	不考虑 0 - 0 配对的情况

6.2 距离与相似系数



4	$\frac{2(m_0 + m_1)}{p + m_0 + m_1}$	对 1-1 和 0-0 对配对数双倍加权
5	$\frac{m_0 + m_1}{p + m_2}$	对不配对数双倍加权
6	$\frac{2m_1}{2m_1 + m_2}$	对 1 - 1 配对数双倍加权, 不考虑 0 - 0 配对
7	$\frac{m_1}{m_1 + 2m_2}$	不考虑 0 - 0 配对, 且对不配对数双倍加权
8	$\frac{m_1}{m_2}$	不考虑 0 - 0 配对, 1 - 1 配对数与不配对数之比.

6.2 距离与相似系数



在对变量进行分类时,通常采用相似系数来表示变量之间的亲疏程度.

设 C_{ij} 表示变量 X_i 和 X_j 间的相似系数,一般要求

① $C_{ij} = \pm 1 \iff X_i = a X_j (a \neq 0, \text{常数});$

② $|C_{ij}| \leq 1, \text{对一切 } i, j \text{ 成立};$

③ $C_{ij} = C_{ji}, \text{对一切 } i, j \text{ 成立}.$

$|C_{ij}|$ 越接近1,则表示 X_i 和 X_j 的关系越密切, $|C_{ij}|$ 越接近0,两者关系越疏远.

6.2 距离与相似系数



1. 夹角余弦

变量 X_i 的 n 次观测值 $(x_{1i}, x_{2i}, \dots, x_{ni})$ 看成 n 维空间的向量. X_i 和 X_j 夹角 α_{ij} 的余弦称为两向量的相似系数, 记为 $C_{ij}(1)$, 即

$$C_{ij}(1) = \cos[\alpha_{ij}] = \frac{\sum_{t=1}^n x_{ti} x_{tj}}{\sqrt{\sum_{t=1}^n x_{ti}^2} \sqrt{\sum_{t=1}^n x_{tj}^2}}$$

当 $i=j$ 时, 夹角 $\alpha_{ij}=0$, $C_{ij}(1)=1$, 说明两向量完全相似; 当 X_i 和 X_j 正交时, $\alpha_{ij}=90$, $C_{ij}(1)=0$, 说明两变量不相关.

6.2 距离与相似系数



2. 相关系数

相关系数就是对数据作中心化或标准化处理后的夹角余弦. 变量 X_i 和 X_j 的相关系数常用 r_{ij} 表示, 在这里我们记为 $C_{ij}(2)$, 即

$$C_{ij}(2) = \frac{\sum_{t=1}^n (x_{ti} - \bar{x}_i)(x_{tj} - \bar{x}_j)}{\sqrt{\sum_{t=1}^n (x_{ti} - \bar{x}_i)^2} \sqrt{\sum_{t=1}^n (x_{tj} - \bar{x}_j)^2}} \\ (i, j = 1, 2, \dots, m).$$

当 $i=j$ 时, $C_{ij}(2)=1$ 表示两变量线性相关.
一般情况, $|C_{ij}(2)| \leq 1$.

6.2 距离与相似系数



3. 变量间的距离

(1) 利用相似系数来定义变量间的距离

令 $d_{ij}=1-|C_{ij}|$ 或 $d^2_{ij}=1-C^2_{ij}$ ($i,j=1,2,\dots,m$).

(2) 利用样本协差阵来定义距离

设样本协差阵 $S=(s_{ij}) > 0$, 变量 X_i 和 X_j 间的距离可定义为

$$d_{ij}=s_{ii} + s_{jj} - 2s_{ij}$$

(3) 把变量 X_i 的 n 次观测值看成 n 维空间的点. 在 n 维空间中按“样品间的距离和相似系数”中介绍的方法类似可定义 m 个变量间的种种距离.

6.2 距离与相似系数



4. 定性变量间的相似系数

当变量 X_i 是定性变量时,也可以定义多种相似系数.

设变量 X_i 的 p 种取值记为 $r_1, r_2, \dots, r_p$ (或称项目 X_i 有 p 个类目); X_j 的 q 种取值记为 $t_1, t_2, \dots, t_q$. n 个样品中两个定性变量的实际观察数列成表, 其中 n_{kl} 表示在 n 个样品中 X_i 取 r_k 且 X_j 取 t_l 的频数. 称构成的表为列联表.

6.2 距离与相似系数



利用列联表对两定性变量独立性的检验中常用到的统计量

$$\chi_{ij}^2 = n \sum_{i=1}^n \sum_{j=1}^p \frac{(p_{ij} - p_{i \cdot} p_{\cdot j})^2}{p_{i \cdot} p_{\cdot j}}$$

建立在卡方统计量基础上的相似系数有

(1) 联列系数

$$C_{ij}(3) = \sqrt{\frac{\chi_{ij}^2}{\chi_{ij}^2 + n}},$$

6.2 距离与相似系数



(2) 连关系数 (有三种)

$$C_{ij}(4) = \sqrt{\frac{\chi_{ij}^2}{n \cdot \max(p-1, q-1)}},$$

$$C_{ij}(5) = \sqrt{\frac{\chi_{ij}^2}{n \cdot \min(p-1, q-1)}},$$

$$C_{ij}(6) = \sqrt{\frac{\chi_{ij}^2}{n \cdot \sqrt{(p-1)(q-1)}}}.$$

6.2 距离与相似系数



如果 X_i 和 X_j 只取二个值(不妨记为0或1),则列联表化为:

表 6.5 二值变量的列联表

$X_i \backslash X_j$	1	0	求行和
1	a	b	$a + b$
0	c	d	$c + d$
求列和	$a + c$	$b + d$	总和 $n = a + b + c + d$

X_i	X_j
1	1
1	0
0	0
$\vdots$	$\vdots$
0	1

这时常用的相似系数有

(3) 点相关系数

$$C_{ij}(7) = \frac{ad - bc}{\sqrt{(a+b)(c+d)(a+c)(b+d)}}$$

(6.2.2)

6.2 距离与相似系数



点相关系数是与定量变量的相关系数相对应的统计量。

(4) 四分相关系数

$$C_{ij}(8) = \sin \left(90^\circ \frac{(a + d) - (b + c)}{a + b + c + d} \right).$$

(5) 夹角余弦

$$C_{ij}(9) = \left(\frac{a}{a + b} \frac{a}{a + c} \right)^{\frac{1}{2}} = \frac{a}{\sqrt{(a + b)(a + c)}}.$$

(6.2.3)

6.2 距离与相似系数



考虑到 $C_{ij} = C_{ji}$ ，改进的统计量为

$$\begin{aligned} C_{ij}(10) &= \left(\frac{a}{a+b} \frac{a}{a+c} \frac{d}{d+b} \frac{d}{d+c} \right)^{\frac{1}{2}} \\ &= \frac{ad}{\sqrt{(a+b)(a+c)(d+b)(d+c)}}. \end{aligned}$$

6.3 系统聚类法



聚类所需的数据可以是通常的多变量的观测记录,也可以是描述样品间或变量间亲近(proximity)程度的一个矩阵.如用相关系数描述相似程度或用距离描述不相关程度。

根据亲近程度进行聚类有多种方法,常用的方法是系统聚类方法(Hierarchical Clustering Method).他将 n 个样品各自看成一类,然后选择距离最近(或最相似)的一对合并成一个新的类.再将距离最近的两类合并成一个新的类.每一步减少一个类,直至所有样品都成为一个类为止。

6.2 距离与相似系数



系统聚类法的基本步骤如下:

数据变换:可以使用上节介绍的方法对数据进行变换.数据变换目的是为了便于比较、计算上的方便或改变数据的结构.

选择度量样品间距离的定义(如欧氏距离)及度量类间距离的定义(如最短距离法,见下面“系统聚类分析的方法”中的介绍).

① 计算 n 个样品(个体)两两间的距离,得初始的距离矩阵 $D^{(1)}$.

6.3 系统聚类法



② 一开始(第一步: $i=1$) n 个样品各自构成一类,得类的个数 $k=n$ 个类: $G_t=\{X_{(t)}\}$ ($t=1,\dots,n$).此时类间的距离就是样品间的距离.对步骤 $i=2,\dots,n$ 执行并类过程的步骤——③和④.


③ 步骤 i 得到的 $D^{(i-1)}$,每次合并类间距离最小的两类为一新类.此时类的总个数 k 减少1类,即 $k=n-i+1$.

④ 计算新类与其他类的距离,得新的距离矩阵 $D^{(i)}$.若此时类的总个数 k 大于1类,重复③和④步;直到类的总个数为1时止.

6.3 系统聚类法

⑤ 画谱系聚类图；

⑥ 决定分类的个数及各类的成员。



6.3 系统聚类法



例6.3.1 设有5个产品,每个产品测得一项质量指标 X ,其值如下: 1, 2, 4.5, 6, 8.试对5个产品按质量指标进行分类.

解 设样品间的距离取为欧氏距离,类间的距离取为类间的最短距离.根据上面介绍的步骤,计算如下:

① 计算5个样品 $\{X_{(1)}, X_{(2)}, X_{(3)}, X_{(4)}, X_{(5)}\}$ 两两间的距离,得初始的类间距离矩阵 $D^{(1)}$:

6.3 系统聚类法



	x_1	x_2	x_3	x_4	x_5
x_1	0	1	3.5	5	7
x_2		0	2.5	4	6
x_3			0	1.5	3.5
x_4				0	2
x_5					0

$= D^{(1)}$



② 一开始 n 个样品各自构成一类,得5个类:
 $G_i = \{X_{(i)}\} (i=1, \dots, 5)$, 类的个数 $k=5$.

6.3 系统聚类法




③ 由 $D^{(1)}$ 可知距离为1时最小,首先合并 $X_{(1)}$ 和 $X_{(2)}$ 为一新类,记为 $CL4=\{X_{(1)}, X_{(2)}\}$;此时类的总个数 k 减少1类,变为 $k=4$,故把此步得到的新类记为 $CL4$.

④ 按最短距离法计算新类 $CL4$ 与其他类的距离,得新的距离矩阵 $D^{(2)}$.

6.3 系统聚类法

	x_3	x_0	x_5	CL4
x_3	0	1.5	3.5	2.5
x_0		0	2	4
x_5			0	6
CL4				0

$= D^{(2)}$



因此时类的总个数 $k=4$ 大于1类,重复并类过程.

6.3 系统聚类法

⑤ 由 $D^{(2)}$ 可知距离为1.5时最小,故合并 $X_{(3)}$ 和 $X_{(4)}$ 为一新类,记为 $CL3=\{X_{(3)}, X_{(4)}\}$; 此时类的总个数 k 减少1类,变为 $k=3$,故把此步得到的新类记为 $CL3$.

⑥ 按最短距离法计算新类 $CL3$ 与其他类的距离,得新的距离矩阵 $D^{(3)}$.

	x_5	$CL4$	$CL3$
x_5	0	6	2
$CL4$		0	2.5
$CL3$			0

 $= D^{(3)}$

6.3 系统聚类法



因此时类的总个数 $k=3$ 大于1类,重复并类过程.

⑦ 由 $D^{(3)}$ 可知,应合并 $X_{(5)}$ 和CL3为一新类,记为 $CL2=\{X_{(5)},X_{(3)},X_{(4)}\}$;此时类的总个数 k 减少1类,变为 $k=2$,故把此步得到的新类为CL2.

⑧ 按最短距离法计算新类CL2与其他类的距离,得新的距离矩阵 $D^{(4)}$.

	CL4	CL2
CL4	0	2.5
CL2		0

$$= D^{(4)}$$

6.3 系统聚类法



因此时类的总个数 $k=2$ 大于1类,重复并类过程.

⑨ 由 $D^{(4)}$ 可知,最后应合并CL4和CL2为一新类,记为 $CL1=\{X_{(1)}, X_{(2)}, X_{(3)}, X_{(4)}, X_{(5)}\}$;此时类的总个数 $k=1$,故把此步得到的新类为CL1.

⑩ 此时所有样品全并成一类,得新的距离矩阵 $D^{(5)}$.


	CL1
CL1	$\begin{bmatrix} 0 \end{bmatrix}$

 $= D^{(5)}$

6.3 系统聚类法




根据并类过程绘制的谱系聚类图



6.3 系统聚类法

并类的直观过程



6.3 系统聚类法



根据谱系聚类图可得到分类的结果:

若分为两类,则分为:

$\{X_{(1)}, X_{(2)}\}$ 和 $\{X_{(5)}, X_{(3)}, X_{(4)}\}$

若分为三类,则分为:

$\{X_{(1)}, X_{(2)}\}$, $\{X_{(5)}\}$ 和 $\{X_{(3)}, X_{(4)}\}$;

若分为四类,则分为:

$\{X_{(1)}, X_{(2)}\}$, $\{X_{(5)}\}$ 和 $\{X_{(3)}\}$ 和 $\{X_{(4)}\}$;

若分为五类,则分为:

$\{X_{(1)}\}$, $\{X_{(2)}\}$, $\{X_{(3)}\}$, $\{X_{(4)}\}$ 和 $\{X_{(5)}\}$.

6.3 系统聚类法



系统聚类法的聚类原则决定于样品间的距离(或相似系数)及类间距离的定义,类间距离的不同定义就产生了不同的系统聚类分析方法.

几个记号:

用 d_{ij} 表示样品 $X_{(i)}$ 和 $X_{(j)}$ 之间的距离,
当样品间的亲疏关系采用相似系数 C_{ij} 时,

令 $d_{ij}=1-|C_{ij}|$ (或 $d^2_{ij}=1-C^2_{ij}$);

用 D_{ij} 表示类 G_i 和 G_j 间的距离.

6.3 系统聚类法



1. 最短距离法(SINgle linkage)

类与类之间的距离定义为两类中最近样品之间的距离,即类 G_p 和 G_q 之间的距离 D_{pq} 定义为

$$D_{pq} = \min_{i \in G_p, j \in G_q} d_{ij}$$

(这里 $i \in G_p$ 表示 $X_{(i)} \in G_p$, 以下同)

比如:当 $G_1=\{1, 2\}$, $G_2=\{4.5, 6\}$ 时,

$$D_{12}=4.5-2=2.5$$

(即最近两样品 $x_{(2)}=2$ 和 $x_{(3)}=4.5$ 之间的距离)

6.3 系统聚类法



当某步类 G_p 和 G_q 合并为 G_r 后,按最短距离法计算新类 G_r 与其他类 G_k 的类间距离,递推公式为

$$\begin{aligned} D_{rk} &= \min_{i \in G_r, j \in G_k} d_{ij} \quad (G_r = \{G_p, G_q\}) \\ &= \min \left\{ \min_{i \in G_p, j \in G_k} d_{ij}, \min_{i \in G_q, j \in G_k} d_{ij} \right\} \\ &= \min \{D_{pk}, D_{qk}\} \quad (k \neq p, q). \end{aligned}$$

例6.3.1中类间距离就是使用最短距离法定义的.

6.3 系统聚类法



如第一步类 G_1 和 G_2 合并为 G_r (记为CL4)后,按最短距离法计算新类 G_r 与其他类 G_k ($k=3, 4, 5$)的类间距离,按递推公式计算:

由 $D^{(1)} = \begin{pmatrix} 0 & 1 & 3.5 & 5 & 7 \\ 1 & 0 & 2.5 & 4 & 6 \\ 3.5 & 2.5 & 0 & 1.5 & 3.5 \\ 5 & 4 & 1.5 & 0 & 2 \\ 7 & 6 & 3.5 & 2 & 0 \end{pmatrix}$

可得

$$D_{r5} = \min(7, 6) = 6, D_{r4} = \min(5, 4) = 4,$$

$$D_{r3} = \min(3.5, 2.5) = 2.5,$$

6.3 系统聚类法



2. 最长距离法 (COMplete method)

类与类之间的距离定义为两类中最远样品之间的距离, 即类 G_p 和 G_q 之间的距离 D_{pq} 定义为

$$D_{pq} = \max_{i \in G_p, j \in G_q} d_{ij}$$

比如: 当 $G_1 = \{1, 2\}$, $G_2 = \{4, 5, 6\}$ 时, $D_{12} = 6 - 1 = 5$.


类 G_p 和 G_q 合并为 G_r 后, 按最长距离法计算新类 G_r 与其他类 G_k 的类间距离也有类似的递推公式:

$$D_{rk} = \max \{D_{pk}, D_{qk}\} \quad (k \neq p, q).$$

6.3 系统聚类法

3. 中间距离法(MEDian method)

如果类与类之间的距离既不采用两类间的最近距离,也不采用最远的距离,而是采用介于两者间的距离,这种方法称为中间距离法.



6.3 系统聚类法



当某步类 G_p 和 G_q 合并为 G_r 后,按中间距离法计算新类 G_r 与其他类 G_k 的类间距离,递推公式为 $(-1/4 \leq \beta \leq 0)$

$$D_{rk}^2 = \frac{1}{2}(D_{pk}^2 + D_{qk}^2) + \beta D_{pq}^2 \quad (\text{常取 } \beta = -\frac{1}{4}, k \neq p, q).$$

当 $\beta = -1/4$ 时,由初等几何知 D_{rk} 就是上面三角形的中线.如果用最长距离法,则 $D_{rk} = D_{qk}$;用最短距离法,则 $D_{rk} = D_{pk}$.

6.3 系统聚类法



4. 重心法(CENtroid method)

在定义类与类之间距离时,考虑每一类中所包含的样品个数.将两类间的距离定义为两类重心间的距离,这种聚类方法称为重心法.对样品分类而言,每一类的重心就是属于该类样品的均值.

比如:当 $G_1 = \{1, 2\}$, $G_2 = \{4, 5, 6\}$ 时, $D_{12}^2 = (5.25 - 1.5)^2 = (3.75)^2$.

设某一步将 G_p 和 G_q 合并成 G_r , 它们所包含的样品个数分别为 n_p 、 n_q 和 n_r ($n_r = n_p + n_q$). 重心分别为 $\bar{X}^{(p)}$ 、 $\bar{X}^{(q)}$ 和 $\bar{X}^{(r)}$.

6.3 系统聚类法



显然有 $\bar{X}^{(r)} = \frac{1}{n_r} (n_p \bar{X}^{(p)} + n_q \bar{X}^{(q)})$

设某一类 $G_k (k \neq p, q)$ 的重心为 $\bar{X}^{(k)}$, 它与新类 G_r 的距离是 $D_{rk} = d \{ \bar{X}^{(r)}, \bar{X}^{(k)} \}$.

如果样品间的距离定义为欧氏距离, 则有

$$\begin{aligned} D_{rk}^2 &= (\bar{X}^{(k)} - \bar{X}^{(r)})' (\bar{X}^{(k)} - \bar{X}^{(r)}) \\ &= \left(\frac{n_p + n_q}{n_r} \bar{X}^{(k)} - \frac{n_p}{n_r} \bar{X}^{(p)} - \frac{n_q}{n_r} \bar{X}^{(q)} \right)' (\dots) \end{aligned}$$

6.3 系统聚类法



$$\begin{aligned} D_{rk}^2 &= \left(\frac{n_p}{n_r} \right)^2 (\bar{X}^{(k)} - \bar{X}^{(p)})'(\dots) + \left(\frac{n_q}{n_r} \right)^2 (\bar{X}^{(k)} - \bar{X}^{(q)})'(\dots) \\ &\quad + \frac{n_p n_q}{n_r^2} (\bar{X}^{(k)} - \bar{X}^{(p)})'(\bar{X}^{(k)} - \bar{X}^{(q)}) \\ &\quad + \frac{n_p n_q}{n_r^2} (\bar{X}^{(k)} - \bar{X}^{(q)})'(\bar{X}^{(k)} - \bar{X}^{(p)}) \\ &= \frac{n_p^2}{n_r^2} D_{pk}^2 + \frac{n_q^2}{n_r^2} D_{qk}^2 + \frac{n_p n_q}{n_r^2} (\bar{X}^{(k)} - \bar{X}^{(p)})'(\bar{X}^{(k)} - \bar{X}^{(p)} + \bar{X}^{(p)} - \bar{X}^{(q)}) \\ &\quad + \frac{n_p n_q}{n_r^2} (\bar{X}^{(k)} - \bar{X}^{(q)})'(\bar{X}^{(k)} - \bar{X}^{(q)} + \bar{X}^{(q)} - \bar{X}^{(p)}) \end{aligned}$$

6.3 系统聚类法




$$\begin{aligned} D_{rk}^2 &= \frac{n_p^2}{n_r^2} D_{pk}^2 + \frac{n_q^2}{n_r^2} D_{qk}^2 + \frac{n_p n_q}{n_r^2} D_{pk}^2 + \frac{n_p n_q}{n_r^2} D_{qk}^2 \\ &\quad + \frac{n_p n_q}{n_r^2} (\bar{X}^{(k)} - \bar{X}^{(p)})' (\bar{X}^{(p)} - \bar{X}^{(q)}) \\ &\quad - \frac{n_p n_q}{n_r^2} (\bar{X}^{(k)} - \bar{X}^{(q)})' (\bar{X}^{(p)} - \bar{X}^{(q)}) \\ &= \frac{n_p}{n_r} D_{pk}^2 + \frac{n_q}{n_r} D_{qk}^2 - \frac{n_p n_q}{n_r^2} D_{pq}^2 \end{aligned}$$

6.3 系统聚类法



5. 类平均法(AVErAge linkage)

重心法虽有较好的代表性,但并未充分利用各个样品的信息.比如下面两组类按重心法类间距离相等,这是不合理的.



6.3 系统聚类法



类平均法把类与类之间的距离定义为两类样品两两之间的平均平方距离,即

$$D_{pq}^2 = \frac{1}{n_p n_q} \sum_{i \in G_p, j \in G_q} d_{ij}^2$$

比如:当 $G_1 = \{1, 2\}$, $G_2 = \{4.5, 6\}$ 时,

$$\begin{aligned} D_{12}^2 &= [(4.5-1)^2 + (4.5-2)^2 + (6-1)^2 + (6-2)^2] / 4 \\ &= [12.25 + 6.25 + 25 + 16] / 4 \\ &= 59.5 / 4 = 14.875 \end{aligned}$$

$$\text{或 } D_{12} = 3.85681$$

6.3 系统聚类法



设某一步将 G_p 和 G_q 合并成 G_r , 它们所包含的样品个数分别为 n_p, n_q 和 n_r ($n_r = n_p + n_q$). G_r 与其他类 G_k 的类间距离的递推公式为

$$D_{rk}^2 = \frac{n_p}{n_r} D_{pk}^2 + \frac{n_q}{n_r} D_{qk}^2 \quad (k \neq p, q)$$

6.3 系统聚类法



由类平均法类间距离的定义可得:

$$\begin{aligned} D_{rk}^2 &= \frac{1}{n_r n_k} \sum_{i \in G_r, j \in G_k} d_{ij}^2 = \frac{1}{n_r n_k} \left[\sum_{i \in G_p, j \in G_k} d_{ij}^2 + \sum_{i \in G_q, j \in G_k} d_{ij}^2 \right] \\ &= \frac{1}{n_r n_k} \left[n_p n_k D_{pk}^2 + n_q n_k D_{qk}^2 \right] \\ &= \frac{n_p}{n_r} D_{pk}^2 + \frac{n_q}{n_r} D_{qk}^2 \end{aligned}$$

6.3 系统聚类法



6. 可变类平均法 (FLEXible beta method)

类平均法的类间距离递推公式中, 类 G_p 和 G_q 间的距离没有反映进去, 有人建议将合并后新类 G_r 与其他类 G_k 的距离公式改为:

$$D_{rk}^2 = (1-\beta) \frac{n_p}{n_r} D_{pk}^2 + (1-\beta) \frac{n_q}{n_r} D_{qk}^2 + \beta D_{pq}^2 \quad (k \neq p, q)$$

其中 β 是可变参数, 一般取 $\beta < 1$. 可变类平均法是由类平均法和中间距离法适当推广得到的。

6.3 系统聚类法



7. 可变法及McQuitty相似分析法(MCQ)

当 G_p 和 G_q 合并为 G_r 后,可变法把 G_r 与其他类 G_k 的类间距离的递推公式定义为($\beta < 1$)

$$D_{rk}^2 = \frac{(1-\beta)}{2} (D_{pk}^2 + D_{qk}^2) + \beta D_{pq}^2 \quad (k \neq p, q)$$

在cluster过程中使用 $\beta = 0$ 时的递推公式 :

$$D_{rk}^2 = (D_{pk}^2 + D_{qk}^2) / 2 \quad (k \neq p, q)$$

并把此方法称为McQuitty相似分析法.

6.3 系统聚类法



8. 离差平方和法(WARD)

离差平方和法是Ward(1936)提出的,也称为Ward法. 它基于方差分析思想, 如果类分得正确, 则同类样品之间的离差平方和应当较小, 不同类样品之间的离差平方和应当较大.

假定已将 n 个样品分为 k 类, 记为 $G_1, G_2, \dots, G_k$, n_i 表示 G_i 类的样品个数, $\bar{X}^{(i)}$ 表示 G_i 的重心, $X_{(i)}^{(i)}$ 表示 G_i 中第 i 个样品 ($i = 1, \dots, n_i$), 则 G_i 中样品的离差平方和为

6.3 系统聚类法



$$S_t = \sum_{i=1}^{n_t} (X_{(i)}^{(t)} - \bar{X}^{(t)})' (X_{(i)}^{(t)} - \bar{X}^{(t)}),$$

其中 $\bar{X}_{(i)}^{(t)}, \bar{X}^{(t)}$ 为 m 维向量, S_t 为一数值.

k 个类的总离差平方和为

$$W = \sum_{t=1}^k W_t = \sum_{t=1}^k \sum_{i=1}^{n_t} (\bar{X}_{(i)}^{(t)} - \bar{X}^{(t)})' (\bar{X}_{(i)}^{(t)} - \bar{X}^{(t)})$$

当 k 固定时, 要选择使 W 达到极小的分类.

6.3 系统聚类法



Ward法的基本思想是, 先将 n 个样品各自成一类, 此时 $W=0$, 然后每次将其中某两类合并为一类, 因每缩小一类离差平方和就要增加, 每次选择使 W 增加最小的两类进行合并, 直至所有样品为一类为止.

Ward法把两类合并后增加的离差平方和看成类间的平方距离, 即把类 G_p 和 G_q 的平方距离定义为

$$D_{pq}^2 = W_r - (W_p + W_q)$$

6.3 系统聚类法



比如：当 $G_1 = \{1, 2\}$, $G_2 = \{4.5, 6\}$ 时，

$$W_1 = (1-1.5)^2 + (2-1.5)^2 = 0.25 + 0.25 = 0.5$$

$$\begin{aligned} W_2 &= (4.5-5.25)^2 + (6-5.25)^2 \\ &= 0.5625 + 0.5625 = 1.125 \end{aligned}$$

记 $G_3 = \{G_1, G_2\} = \{1, 2, 4.5, 6\}$ (均值=3.375)

$$\begin{aligned} W_3 &= (1-3.375)^2 + (2-3.375)^2 + (4.5-3.375)^2 + (6-3.375)^2 \\ &= 15.5865 \end{aligned}$$

$$\begin{aligned} \text{则 } D_{12}^2 &= W_3 - (W_1 + W_2) \\ &= 15.5865 - (0.5 + 1.125) = 13.9615 \end{aligned}$$

$$\text{或 } D_{12} = 3.7365$$

6.3 系统聚类法



下面来推导 D^2_{pq} 的公式.利用 W_r 的定义:

$$\begin{aligned} W_r &= \sum_{t=1}^{n_r} (X_{(t)}^{(r)} - \bar{X}^{(r)})' (X_{(t)}^{(r)} - \bar{X}^{(r)}) \\ &= \sum_{t=1}^{n_p} (X_{(t)}^{(p)} - \bar{X}^{(r)})' (X_{(t)}^{(p)} - \bar{X}^{(r)}) \\ &\quad + \sum_{t=1}^{n_q} (X_{(t)}^{(q)} - \bar{X}^{(r)})' (X_{(t)}^{(q)} - \bar{X}^{(r)}) \end{aligned}$$

$$\text{求} \bar{X}^{(r)} = \frac{1}{n_r} (n_p \bar{X}^{(p)} + n_q \bar{X}^{(q)}) \text{ 求}$$

6.3 系统聚类法

经整理可得

$$D_{pq}^2 = \frac{n_p n_q}{n_r} (\bar{X}^{(p)} - \bar{X}^{(q)})' (\bar{X}^{(p)} - \bar{X}^{(q)})$$

当样品间距离采用欧氏距离时, 上式可表为

$$D_{pq}^2 = \frac{n_p n_q}{n_r} d_{pq}^2$$

d_{pq}^2 表示 G_p, G_q 的重心 $\bar{X}^{(p)}$ 与 $\bar{X}^{(q)}$ 的平方距离

这表明Ward法定义的类间距离与重心法只相差一个常数倍.

6.3 系统聚类法



当 G_p 和 G_q 合并为 G_r 后, G_r 与其他类 G_k 的距离有如下递推公式:

$$D_{rk}^2 = \frac{n_k + n_p}{n_r + n_k} D_{pk}^2 + \frac{n_k + n_q}{n_r + n_k} D_{qk}^2 - \frac{n_k}{n_r + n_k} D_{pq}^2$$

在实际应用中, 离差平方和法应用比较广泛, 分类效果较好. 但它要求样品间距离必须采用欧氏距离.

6.3 系统聚类法



以上介绍的八种方法聚类的步骤完全一样,所不同的是类与类之间的距离有不同的定义方法,因而得到不同的递推公式,Lance和Williams于1967年首先给出了统一公式.当 G_p 和 G_q 合并为 G_r 后,新类 G_r 与其他类 G_k 的平方距离为:

$$D_{rk}^2 = \alpha_p D_{pk}^2 + \alpha_q D_{qk}^2 + \beta D_{pq}^2 + \gamma |D_{pk}^2 - D_{qk}^2|$$

其中 α_p 、 α_q 、 β 和 γ 是参数,不同的系统聚类方法有不同的取值.

6.3 系统聚类法



系统聚类法的参数表

方 法	α_p	α_q	β	γ
最短距离法	$\frac{1}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$
最长距离法	$\frac{1}{2}$	$\frac{1}{2}$	0	$\frac{1}{2}$
中间距离法	$\frac{1}{2}$	$\frac{1}{2}$	$-\frac{1}{4} \leq \beta \leq 0$	0
重心法	$\frac{n_p}{n_r}$	$\frac{n_q}{n_r}$	$-\alpha_p \alpha_q$	0
类平均法	$\frac{n_p}{n_r}$	$\frac{n_q}{n_r}$	0	0
可变类平均法	$\frac{(1-\beta)n_p}{n_r}$	$\frac{(1-\beta)n_q}{n_r}$	$\beta < 1$	0
可变法	$\frac{(1-\beta)}{2}$	$\frac{(1-\beta)}{2}$	$\beta < 1$	0
离差平方和法	$\frac{n_p + n_k}{n_r + n_k}$	$\frac{n_p + n_k}{n_r + n_k}$	$-\frac{n_k}{n_r + n_k}$	0

6.4 系统聚类法的性质及类的确定



(1) 单调性

设 D_k 表示系统聚类法中第 k 次并类时的距离. 一个系统聚类法若能保证 $\{D_k, k=1, 2, \dots, n-1\}$ 是单调的, 则称它具有单调性.

如例6.3.1, 用最短距离时有: $D_1=1, D_2=1.5, D_3=2, D_4=2.5$. 满足 $D_1 \leq D_2 \leq D_3 \leq D_4$. 并类距离有单调性符合系统聚类法的基本思想.

可以证明, 最短距离法, 最长距离法, 类平均法, 可变类平均法, 离差平方和法都具有单调性, 只有重心法和中间距离法不具有单调性.

6.4 系统聚类法的性质及类的确定



(2) 空间的浓缩与扩张

比较最短距离法和最长距离法的并类过程及相应的距离阵可以看出. 每一步都有:

$$D_{ij}(\text{短}) \leq D_{ij}(\text{长}) \quad (\text{对一切 } i, j).$$

这种性质称为**最长距离法比最短距离法扩张**;
或称**最短距离法比最长距离法浓缩**.

6.4 系统聚类法的性质及类的确定



对前面介绍的系统聚类方法,有如下结论:
类平均法(或中间距离法)比最短距离法扩张,
而且比最长距离法浓缩;**类平均法**比重心法扩张,
而且比离差平方和法浓缩. 太浓缩的方法不够
灵敏,太扩张的方法当样品容量大时容易失真.

**类平均法比较适中,相对于其他方法不太浓
缩也不太扩张,而且具有单调性. 因而是一种应
用广泛、聚类效果较好的方法.**

6.4 系统聚类法的性质及类的确定




聚类分析的目的是对样品或变量进行分类,但至今对什么是类还没有给出定义.在实际应用中,不同领域里类的含义是不尽相同的,要给出一个严格的统一定义是不容易的。Rao在1977年 曾给三种定义.

定义6.4.1 设阈值 T 是给定的正数,若集合 G 中任二个元素的距离 d_{ij} 都满足:


$$d_{ij} \leq T \quad (i, j \in G),$$

则称 G 对于阈值 T 组成一个类.

6.4 系统聚类法的性质及类的确定



如最长距离法:给定 $T=3.51$ 时,5个样品分为两类,这时两个类中,每一类里任二个样品的距离 $d_{ij} \leq T$. 故最长距离法符合定义6.4.1.



若用最短距离法(例6.3.1):给定 $T=2.01$ 时,5个样品分为两类,这时两个类中,每一类里任二个样品的距离不满足 $d_{ij} \leq T$.

6.4 系统聚类法的性质及类的确定




定义6.4.2 设阈值 T 是给定的正数, 如果集合 G 中每个 $i \in G$, 都满足:


$$\frac{1}{n-1} \sum_{j \in G} d_{ij} \leq T$$

其中 n 是集合 G 中元素的个数, 则称 G 对于阈值 T 组成一个类.

6.4 系统聚类法的性质及类的确定



如类平均法:给定 $T=2.86$ 时,5个样品分为两类,这时每一类里任一个样品与其它样品的平均距离 $\leq T$. 故类平均法符合定义6.4.2.



若用最短距离法(例6.3.1):给定 $T=2.01$ 时,5个样品分为两类,这时每一类里任一个样品与其它样品的平均距离不满足 $\leq T$.

6.4 系统聚类法的性质及类的确定



定义 6.4.3 设 T 和 H ($H > T$) 是两个给定的正数, 如果集合 G 中两两元素距离的平均满足:

$$\frac{1}{n(n-1)} \sum_{i \in G} \sum_{j \in G} d_{ij} \leq T, d_{ij} \leq H (i, j \in G)$$

其中 n 是集合 G 中元素的个数, 则称 G 对于阈值 T, H 组成一个类.

6.4 系统聚类法的性质及类的确定



类似地还可以给出以下二个定义.

定义 6.4.4 设 T 是给定的正数, 若对集合 G 中任一个 $i \in G$, 一定存在 $j \in G$, 使得这二个元素的距离 d_{ij} 满足:

$$d_{ij} \leq T \quad (i, j \in G),$$

则称 G 对于阈值 T 组成一个类.

如最短距离法(例6.3.1): 给定 $T=2.01$ 时, 5个样品分为两类, 这时每一类里的任一个样品, 都存在另一样品使其距离不满足 $\leq T$. 故最短距离法符合定义6.4.4.

6.4 系统聚类法的性质及类的确定




定义 6.4.5 设阈值 T 是给定的正数, 将集合 G 任意分为二类: G_1 和 G_2 , 这两类之间的距离 $D(G_1, G_2)$ 满足:


$$D(G_1, G_2) \leq T,$$

则称 G 对于阈值 T 组成一个类.

6.4 系统聚类法的性质及类的确定



如最短距离法:给定 $T=2.01$ 时,5个样品分为两类.显然把每一类再任分为两类,则两类间的距离 $D_{ij} \leq T$.故最短距离法符合定义6.4.5.



其实,以上定义的8种类间距离都符合定义6.4.5.

6.4 系统聚类法的性质及类的确定



在系统聚类的方法中，我们重点介绍了类与类之间的8种距离及统一的递推公式。

类的定义6.4.5可用于8种类间距离的任一种。

定义6.4.1可用于最长距离法；

定义6.4.4可用于最短距离法；

定义6.4.2可用于类平均法。

容易看出，以上前4种定义中，定义6.4.1要求是最高的，凡是符合它的类，一定也是符合后三种定义的类。此外，凡是符合定义6.4.2的类，也一定是符合后二种定义的类。

6.4 系统聚类法的性质及类的确定



设类 G 包含的样品记为

$$X_{(1)}, X_{(1)}, \dots, X_{(n)},$$

其中 $X_{(t)}$ ($t=1, 2, \dots, n$) 为 m 维总体的样本.

可以从不同角度来刻画 G 的特征, 常用的特征有以下三种:

1. 均值 (重心)

$$\overline{X}_G = \frac{1}{n} \sum_{i=1}^n X_{(i)}$$

6.4 系统聚类法的性质及类的确定



2. 样本离差阵及样本协差阵

$$A_G = \sum_{i=1}^n (X_{(i)} - \overline{X}_G)(X_{(i)} - \overline{X}_G)'$$

$$S_G = \frac{1}{n-1} A_G$$

6.4 系统聚类法的性质及类的确定



3. 类的直径

用 D_G 表示类 G 的直径,常用的直径有:

$$D_G = \sum_{i=1}^n (X_{(i)} - \bar{X}_G)'(X_{(i)} - \bar{X}_G)$$

$$D_G = \max_{i,j \in G} d_{ij}$$

6.4 系统聚类法的性质及类的确定



聚类分析中，类的个数如何确定的问题是一个十分困难的问题，人们至今仍未找到令人满意的方法；但这又是一个不可回避的问题。

迄今为止，虽给出了类的定义，只是从不同的角度直观地叙述了“类”的概念，并未给出严格的统一定义，但要对各种不同形式的类给予统一的定义是比较困难的，“类”的概念是一个模糊的概念。因此在实际应用中，人们并不完全从类的定义来确定类。

6.4 系统聚类法的性质及类的确定



确定类个数的几种常见方法：

1. 由适当的阈值确定

介绍系统聚类法的基本步骤时,由谱系聚类图及临界值,即可给出分类结果.

2. 根据数据点的散布图直观地确定类的个数

3. 根据统计量确定分类个数

4. 根据谱系图确定分类个数的准则

6.4 系统聚类法的性质及类的确定



用于确定分类个数的统计量：

假定已将 n 个样品分为 k 类, 为 $G_1, G_2, \dots, G_k$, n_t 表示 G_t 类的样品个数 ($n_1 + \dots + n_k = n$), $X^{(t)}$ 表示 G_t 的重心. $X_{(i)}^{(t)}$ 表示 G_t 中第 i 个样品 ($i=1, \dots, n_t$), $\bar{X}$ 表示所有样品的重心, W_t 表示 G_t 中样品的离差平方和.

所有样品的总离差平方和 T 可以分解为：

$$\begin{aligned} T &= \sum_{t=1}^k \sum_{i=1}^{n_t} (X_{(i)}^{(t)} - \bar{X})' (X_{(i)}^{(t)} - \bar{X}) \\ &= P_k + B_k \end{aligned} \quad \text{其中} \quad P_k = \sum_{t=1}^k W_t$$

6.4 系统聚类法的性质及类的确定



(1) R_k^2 统计量

$$R_k^2 = 1 - \frac{P_k}{T} = \frac{B_k}{T},$$

由 R_k^2 的定义可知, R_k^2 值越大, 也就是 P_k/T 越小, 表示 k 个类内离差平方和之和 P_k 在总离差平方和 T 中占的比例越小, 这说明 k 个类区分得越开.

6.4 系统聚类法的性质及类的确定



R_k^2 统计量可用于评价合并为 k 个类时的聚类效果. R_k^2 越大, 聚类效果越好.

R_k^2 的值总是在 0 和 1 之间, 而且 R_k^2 的值总是随着分类个数 k 的减少而变小.

如果用户希望通过分析 R_k^2 值来确定 n 个样品应分为几类最合适, 应该看 R_k^2 值的变化. 假定分为 4 类时的 $R_4^2 = 0.797$, 而下一次合并后分为 3 类时 R^2 下降较多, 比如 $R_3^2 = 0.402$, 下降了 $0.395 (=0.797 - 0.402)$. 这时通过分析 R_k^2 统计量可得出, 分为 4 个类是较合适的.

6.4 系统聚类法的性质及类的确定

(2) 半偏 R_k^2 统计量

$$\text{宽封 } R_k^2 = B_{KL}^2 / T = R_{k+1}^2 - R_k^2$$

其中 $B_{KL}^2 = W_M - (W_K + W_L)$ 表示合并类 G_K 和 G_L 为新类 G_M 后类内离差平方和的增值。

该统计量用于评价合并 G_K 和 G_L 的效果。

根据以上定义，半偏 R_k^2 的值是上一步 R_{k+1}^2 与该步 R_k^2 的差值，故查看 R_k^2 变化的大小可以得到半偏 R_k^2 。某步半偏 R_k^2 的值越大，说明上一次合并为 $k+1$ 类后的效果好。

该统计量用于评价一次合并的效果。

6.4 系统聚类法的性质及类的确定



(3) 伪 F 统计量

$$\text{伪}F_k = \frac{(T - P_k)/(k-1)}{P_k/(n-k)} = \frac{B_k}{P_k} \bullet \frac{n-k}{k-1}$$

该统计量用于评价分为 k 个类聚类效果. 伪 F_k 值越大表示这 n 个样品可显著地分为 k 个类. 伪 F_k 统计量可以作为确定类个数的有用指标, 但并不具有像 F 统计量的分布.

6.4 系统聚类法的性质及类的确定



(4) 伪 t^2 统计量

$$\text{伪}t^2 = \frac{B_{KL}^2}{(W_K + W_L)/(n_K + n_L - 2)}$$

该统计量用以评价此步合并类 G_K 和 G_L 的效果。

由伪 t^2 统计量的定义知该值大表示 G_K 和 G_L 合并为 G_M 后类内离差平方和的增量 B_{KL}^2 相对于 G_K 和 G_L 两类的类内离差平方和大。这表明上一次被合并的两个类是很分开的，也就是上一次聚类的效果是好的。

.

伪 t^2 统计量可以作为确定类个数的有用指标，但并不具有像随机变量 t^2 那样的分布。