

5.1 距离判别法——马氏距离

简例1：记二维正态总体 $N_2(\mu^{(i)}, \Sigma)$ 为 $G_i (i=1, 2)$ (两总体协差阵相同), 已知来自 $G_i (i=1, 2)$ 的样本数据阵为

$$X_{4 \times 2}^{(1)} = \begin{pmatrix} 2 & 12 \\ 4 & 10 \\ 3 & 8 \\ 3 & 10 \end{pmatrix}, \quad X_{3 \times 2}^{(2)} = \begin{pmatrix} 5 & 7 \\ 3 & 9 \\ 4 & 5 \end{pmatrix}, \quad \begin{pmatrix} k=2, & m=2 \\ n_1=4, & n_2=3 \end{pmatrix}$$

(1) 试求两总体的样本组内离差阵 A_1, A_2 和合并样本协差阵 S .

(2) 今有样品 $x_0 = (2, 8)$, 试问按马氏距离准则样品 x_0 应判归哪一类.

5.1 距离判别法——马氏距离

(1) 解: $\bar{X}^{(1)} = \begin{pmatrix} 3 \\ 10 \end{pmatrix}, \quad \bar{X}^{(2)} = \begin{pmatrix} 4 \\ 7 \end{pmatrix}.$

$$\tilde{X}_{4 \times 2}^{(1)} = \begin{pmatrix} -1 & 2 \\ 1 & 0 \\ 0 & -2 \\ 0 & 0 \end{pmatrix}, \quad A_1 = (\tilde{X}^{(1)})' \tilde{X}^{(1)} = \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix}$$

$$\tilde{X}_{3 \times 2}^{(2)} = \begin{pmatrix} 1 & 0 \\ -1 & 2 \\ 0 & -2 \end{pmatrix}, \quad A_2 = (\tilde{X}^{(2)})' \tilde{X}^{(2)} = \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix}$$

5.1 距离判别法——马氏距离

样本合并组内离差阵 A 为

$$A = A_1 + A_2 = \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix} + \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix} = \begin{pmatrix} 4 & -4 \\ -4 & 16 \end{pmatrix}, \text{故}$$

$$S = \frac{1}{n_1 + n_2 - 2} A = \frac{1}{5} \begin{pmatrix} 4 & -4 \\ -4 & 16 \end{pmatrix} = \frac{4}{5} \begin{pmatrix} 1 & -1 \\ -1 & 4 \end{pmatrix},$$

而且 $|S| = \left(\frac{4}{5}\right)^2 \begin{vmatrix} 1 & -1 \\ -1 & 4 \end{vmatrix} = \frac{16}{25} \times 3 = \frac{48}{25},$

$$S^{-1} = \frac{25}{48} \times \frac{4}{5} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} = \frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix}$$

5.1 距离判别法——马氏距离

(2) 解二：计算线性判别函数 $Y_i(X)$ ($i=1, 2$)

$$Y_i(X) = (S^{-1} \bar{X}^{(i)})' X - \frac{1}{2} (\bar{X}^{(i)})' S^{-1} \bar{X}^{(i)} \quad (i=1, 2).$$

$$a_1 = S^{-1} \bar{X}^{(1)} = \frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 10 \end{pmatrix} = \frac{5}{12} \begin{pmatrix} 22 \\ 13 \end{pmatrix},$$

$$a_2 = S^{-1} \bar{X}^{(2)} = \frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 4 \\ 7 \end{pmatrix} = \frac{5}{12} \begin{pmatrix} 23 \\ 11 \end{pmatrix},$$

$$C_1 = -\frac{1}{2} (\bar{X}^{(1)})' a_1 = -\frac{1}{2} \times \frac{5}{12} (3, 10) \begin{pmatrix} 22 \\ 13 \end{pmatrix} = -\frac{245}{6} = -40.8333,$$

$$C_2 = -\frac{1}{2} (\bar{X}^{(2)})' a_2 = -\frac{1}{2} \times \frac{5}{12} (4, 7) \begin{pmatrix} 23 \\ 11 \end{pmatrix} = -\frac{5 \times 169}{24} = -35.2083.$$

这道题目是关于两个正态总体（协方差矩阵相等）的距离判别法（马氏距离）。

关键词：离差阵，协方差阵，合并协方差阵，马氏距离，样本判别

“二维正态总体”指的就是：我们要研究的每一个样本点，都包含两个特征指标（比如身高和体重），这两个指标构成的向量服从二元正态分布（Bivariate Normal Distribution）。

离差 (Deviation) 就是单个数据与均值的差，怎么算，之前说过。

概念	均值（中心位置）	协方差阵（形状胖瘦）
总体参数 (Population) 上帝视角，客观存在但通常未知的真值	μ (Mu)	Σ (Sigma)
样本统计量 (Sample) 人类视角，通过手中的数据算出来的估计值	$\bar{x}$ (x bar)	S

- **协方差阵 (S)**: 决定了**山的形状**（是圆山还是长山）。我们把数据合并，是为了**把这个形状看得更清楚**。
- **均值向量 ($\bar{x}$) / 峰值**: 决定了**山在哪里**。这是两座山**唯一的区别**。

马氏距离的几何理解：马氏距离就是把那个**底面是椭圆**的山峰，在数学上强行“**拉伸/压缩**”成**一个底面是正圆**的山峰，然后再用尺子去量 x-y 平面上的距离。

1. **马氏距离：理论公式**（如果有上帝视角）：
真正的马氏距离应该用 Σ 和 μ 来算：
$$D^2 = (x - \mu)' \Sigma^{-1} (x - \mu)$$
2. **实际操作**（我们只有几行数据）：
因为 μ 和 Σ 未知，我们只能用样本统计量去**替代**它们：
 - 用 $\bar{x}$ 替代 μ
 - 用 S 替代 Σ于是公式变成了样本马氏距离：
$$D^2 = (x - \bar{x})' S^{-1} (x - \bar{x})$$

符号	数学术语	平方是一个动作还是名字的一部分？	也就是...
R^2	决定系数	是名字的一部分	R^2 这个整体就是系数本身。
D^2	马氏距离的平方	是一个动作	它确实是把“距离”给平方了。

多元正态分布的概率密度函数 (PDF):
$$f(x) = \underbrace{\frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}}}_{\text{常数项 } C} \cdot \exp\left(-\frac{1}{2}(x - \mu)' \Sigma^{-1} (x - \mu)\right)$$

马氏距离的平方:
$$D^2 = (x - \mu)' \Sigma^{-1} (x - \mu)$$

所以，多元正态分布完全可以写成：
$$f(x) = C \cdot e^{-\frac{1}{2} D^2}$$

这意味着什么？

1. **概率只取决于距离**：一个样本点 x 出现的概率密度大小，**完全取决于**它到中心 μ 的马氏距离 D 。
2. **等高线**：如果你把所有 D^2 相同的点连起来，它们的概率密度 $f(x)$ 也是相等的。这就是为什么二维正态分布的等高线是**椭圆**（因为 $D^2 = \text{常数}$ 就是椭圆方程）。

用马氏距离的概念去理解多元正态分布，公式的物理意义瞬间就清晰了，不再是一堆可怕的矩阵运算。

我们可以把它看作是 “**一维标准正态分布的推广**”：

- **一维情况**：
$$f(x) \propto e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2} = e^{-\frac{1}{2}z^2}$$
这里的 z 是 z-score（标准分数），也就是**标准化的欧氏距离**。
- **多维情况**：
$$f(x) \propto e^{-\frac{1}{2}D^2}$$
这里的 D 是马氏距离，它其实就是**多维空间下的 z-score**。

马氏距离判别的一种比喻

- **两个总体 (G_1, G_2)**: 就是平原上的两座**山峰**。
 - 因为题目说“协方差阵相同”，所以这两座山是“**双胞胎山**”——胖瘦、高矮、坡度完全一模一样，只是坐落在不同的位置。
- **新样本 (x_0)**: 就是一个站在平原上的**登山者**。
- **马氏距离**: 登山者到达山顶需要跨越的“**等高线圈数**”。

- 普通（单组）样本协方差阵 (S_i)
针对每一个单独的类别 i 计算。只利用该类别下的 n_i 个样本。
 - 公式：**
$$S_i = \frac{1}{n_i-1} A_i$$

(其中 A_i 是第 i 组的组内离差阵)
 - 意义：**只描述第 i 类数据自己长什么样（胖瘦、倾斜方向）。

- 合并样本协方差阵 (S_{pooled})
当假设两组协方差矩阵相等时，我们将两组的离差阵“加起来”，共同估计那个统一的协方差矩阵。

- 公式：**
$$S = \frac{A_1+A_2}{(n_1-1)+(n_2-1)} = \frac{A_1+A_2}{n_1+n_2-2}$$
- 直观理解：**它其实是两个单组协方差阵的**加权平均**（权重是自由度）：
$$S = \frac{(n_1-1)S_1+(n_2-1)S_2}{(n_1-1)+(n_2-1)}$$

为什么可以用合并样本协方差阵？

我们在算马氏距离的时候均值是不一样的，所以我们认为两座山的位置不一样。

然而，山的形状是一样的，相当于用了一个更加准确的山的形状估计（由协方差阵描述）

一、 题目描述

已知：
有两个二维正态总体 G_1, G_2 ，即 $N_2(\mu^{(i)}, \Sigma), (i = 1, 2)$ 。两总体的协方差矩阵相同。
已知来自 G_1, G_2 的样本数据阵分别为：

$$X^{(1)} = \begin{pmatrix} 2 & 12 \\ 4 & 10 \\ 3 & 8 \\ 3 & 10 \end{pmatrix}, \quad X^{(2)} = \begin{pmatrix} 5 & 7 \\ 3 & 9 \\ 4 & 5 \end{pmatrix}$$

其中 $k = 2$ (类别数), $m = 2$ (维数), $n_1 = 4, n_2 = 3$ 。

- 问题：**
- 试求两总体的样本组内离差阵 A_1, A_2 和合并样本协方差阵 S 。
 - 今有样品 $x_0 = (2, 8)'$ ，试问按马氏距离准则，样品 x_0 应判归哪一类？

二、 计算离差阵和(合并)协方差阵

- 样本均值向量：**
$$\bar{X}^{(1)} = \begin{pmatrix} 3 \\ 10 \end{pmatrix}, \quad \bar{X}^{(2)} = \begin{pmatrix} 4 \\ 7 \end{pmatrix}$$
- 组内离差阵：**
$$A_1 = \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix}, \quad A_2 = \begin{pmatrix} 2 & -2 \\ -2 & 8 \end{pmatrix}$$
$$A = A_1 + A_2 = \begin{pmatrix} 4 & -4 \\ -4 & 16 \end{pmatrix}$$
- 合并协方差阵 S 及其逆矩阵 S^{-1} ：**
$$S = \frac{1}{n_1 + n_2 - 2} A = \frac{1}{5} \begin{pmatrix} 4 & -4 \\ -4 & 16 \end{pmatrix} = \frac{4}{5} \begin{pmatrix} 1 & -1 \\ -1 & 4 \end{pmatrix}$$
$$S^{-1} = \frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix}$$

三、 判别过程详解

题目要求判断 $x_0 = \begin{pmatrix} 2 \\ 8 \end{pmatrix}$ 的归属。这里提供两种解法。

解法一：直接计算马氏距离 (Mahalanobis Distance)

判别准则： 计算样品 x_0 到两个总体中心的马氏距离平方 $D^2(x_0, G_i)$, **距离哪个小就属于哪一类。**

公式: $D^2(x_0, G_i) = (x_0 - \bar{X}^{(i)})' S^{-1} (x_0 - \bar{X}^{(i)})$

1. 计算到 G_1 的距离平方：

$$x_0 - \bar{X}^{(1)} = \begin{pmatrix} 2 \\ 8 \end{pmatrix} - \begin{pmatrix} 3 \\ 10 \end{pmatrix} = \begin{pmatrix} -1 \\ -2 \end{pmatrix}$$

$$\begin{aligned} D^2(x_0, G_1) &= \begin{pmatrix} -1 & -2 \end{pmatrix} \left[\frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} \right] \begin{pmatrix} -1 \\ -2 \end{pmatrix} \\ &= \frac{5}{12} \begin{pmatrix} -1 & -2 \end{pmatrix} \begin{pmatrix} 4(-1) + 1(-2) \\ 1(-1) + 1(-2) \end{pmatrix} \\ &= \frac{5}{12} \begin{pmatrix} -1 & -2 \end{pmatrix} \begin{pmatrix} -6 \\ -3 \end{pmatrix} \\ &= \frac{5}{12} ((-1)(-6) + (-2)(-3)) \\ &= \frac{5}{12} (6 + 6) = \frac{60}{12} = \mathbf{5} \end{aligned}$$

2. 计算到 G_2 的距离平方：

$$x_0 - \bar{X}^{(2)} = \begin{pmatrix} 2 \\ 8 \end{pmatrix} - \begin{pmatrix} 4 \\ 7 \end{pmatrix} = \begin{pmatrix} -2 \\ 1 \end{pmatrix}$$

$$\begin{aligned} D^2(x_0, G_2) &= \begin{pmatrix} -2 & 1 \end{pmatrix} \left[\frac{5}{12} \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix} \right] \begin{pmatrix} -2 \\ 1 \end{pmatrix} \\ &= \frac{5}{12} \begin{pmatrix} -2 & 1 \end{pmatrix} \begin{pmatrix} -7 \\ -1 \end{pmatrix} \\ &= \frac{5}{12} (14 - 1) \\ &= \frac{5}{12} \times 13 = \frac{65}{12} \approx \mathbf{5.417} \end{aligned}$$

3. 结论：

因为 $D^2(x_0, G_1) = 5 < D^2(x_0, G_2) = 5.417$, 即样品到 G_1 的距离更近。

故判 x_0 属于第一类 G_1 。

解法二：线性判别函数

判别准则： 比较线性判别函数值 $Y_i(x_0)$ 的大小, **数值大的属于该类** (注: Y 值反映了对数似然比, 值越大可能性越大)。

系数 a_i 和常数 C_i :

- $a_1 = S^{-1} \bar{X}^{(1)} = \frac{5}{12} \begin{pmatrix} 22 \\ 13 \end{pmatrix}$
- $a_2 = S^{-1} \bar{X}^{(2)} = \frac{5}{12} \begin{pmatrix} 23 \\ 11 \end{pmatrix}$
- $C_1 \approx -40.8333$
- $C_2 \approx -35.2083$

判别函数公式: $Y_i(x) = a_i'x + C_i$

1. 计算 $Y_1(x_0)$:

$$\begin{aligned} a_1'x_0 &= \frac{5}{12} \begin{pmatrix} 22 & 13 \end{pmatrix} \begin{pmatrix} 2 \\ 8 \end{pmatrix} \\ &= \frac{5}{12} (44 + 104) = \frac{5 \times 148}{12} = \frac{740}{12} \approx 61.6667 \\ Y_1(x_0) &= 61.6667 + (-40.8333) = \mathbf{20.8334} \end{aligned}$$

2. 计算 $Y_2(x_0)$:

$$\begin{aligned} a_2'x_0 &= \frac{5}{12} \begin{pmatrix} 23 & 11 \end{pmatrix} \begin{pmatrix} 2 \\ 8 \end{pmatrix} \\ &= \frac{5}{12} (46 + 88) = \frac{5 \times 134}{12} = \frac{670}{12} \approx 55.8333 \\ Y_2(x_0) &= 55.8333 + (-35.2083) = \mathbf{20.625} \end{aligned}$$

3. 结论：

因为 $Y_1(x_0) = 20.8334 > Y_2(x_0) = 20.625$ 。

故判 x_0 属于第一类 G_1 。

(两种方法得出的结论是一致的)