

一、 梯度下降法 (Gradient Descent) 的核心思路

梯度下降的直观理解是“下山”：想象你站在山上（目标函数 $f(x)$ ），目标是走到山谷最低点。

- 寻找方向（梯度）**： 在当前位置，计算函数在各个方向的斜率。**梯度** (∇f) 指向函数增长最快的方向，那么**负梯度** ($-\nabla f$) 就是函数下降最快的方向。
- 迈出步伐（步长）**： 沿着负梯度方向走一小步。这一步的大小由**学习率** (Learning Rate, α) 决定。
- 循环往复**： 走到新位置后，重新计算梯度，再走一步，直到梯度接近于 0（达到平坦的山谷）或函数值不再减小。

基本公式：

$$x^{(k+1)} = x^{(k)} - \alpha \nabla f(x^{(k)})$$

二、 最速下降法 (Steepest Descent) 的特点与缺陷

在刚才的例题中，使用的是“最速下降法”。它与普通梯度下降的区别在于：**每一步的步长 α 都是通过计算求出的“最优解”**（即通过一维搜索，保证在当前方向上能走到最低点）。

- 优点**： 理论上每一步下降幅度最大，在初始阶段收敛很快。
- 致命缺陷**：
 - “之”字形（Zig-zag）现象**： 正如例题验证的那样，相邻两个搜索方向是**严格正交（垂直）**的。
 - 如果目标函数的等高线是扁平的椭圆（函数性质较差），算法会像锯齿一样在山谷两侧来回震荡，前进极其缓慢，效率远不如预期。

三、 对最速下降法的改进方向

为了克服“之”字形震荡和收敛慢的问题，发展出了以下几种主要的改进思路：

1. 共轭梯度法 (Conjugate Gradient) —— “修正方向”

- 思路**： 既然“垂直”走会导致回头路，那就要求每一个新的搜索方向都与之前的方向关于函数的矩阵“共轭”。
- 效果**： 它保证了在 n 维二次函数中，最多只需要 n 步就能走到极小点。它比最速下降法快得多，且不需要存储复杂的矩阵。

2. 牛顿法 (Newton's Method) —— “利用二阶导数”

- 思路**： 梯度下降只利用了一阶导数（斜率），牛顿法利用了**二阶导数（曲率/海森矩阵）**。
- 效果**： 它不仅知道往哪走，还知道地形的弯曲程度。如果函数是二次的，牛顿法仅需 **1步** 就能达到极值点。缺点是计算海森矩阵及其逆矩阵的开销巨大。

3. 拟牛顿法 (Quasi-Newton, 如 BFGS / L-BFGS)

- 思路**： 想要牛顿法的快速收敛，又不想计算复杂的二阶导数。于是通过某种方式**模拟/逼近**海森矩阵。
- 效果**： 这是目前工程领域（特别是无约束优化）中最常用的高级算法，兼顾了计算速度和收敛效率。

一、 题目复述

题目：

设目标函数为 $f(x_1, x_2) = x_1^2 + 4x_2^2$ ，试从初始点 $x^{(0)} = (1, 1)^T$ 出发，使用最速下降法求该函数的极小点。

要求：

- 迭代计算两次。
- 计算每一个迭代点的函数值、梯度向量及其模长。
- 验证相邻两个搜索方向（下降方向）之间具有正交性（即内积为0）。

二、题解

1. 准备工作

- **目标函数：** $f(x) = x_1^2 + 4x_2^2$
- **梯度向量：** $\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 2x_1 \\ 8x_2 \end{pmatrix}$
- **初始点：** $x^{(0)} = (1, 1)^T$
- **初始函数值：** $f(x^{(0)}) = 1^2 + 4(1)^2 = 5$

2. 第一步迭代 ($k = 0$)

- **计算梯度：** $\nabla f(x^{(0)}) = (2 \cdot 1, 8 \cdot 1)^T = (2, 8)^T$
- **梯度模长：** $\|\nabla f(x^{(0)})\| = \sqrt{2^2 + 8^2} = \sqrt{68} \approx 8.24621$
- **确定搜索方向：** $d^{(0)} = -\nabla f(x^{(0)}) = (-2, -8)^T$
- **一维搜索求步长 α_0 ：**
令 $\phi(\alpha) = f(x^{(0)} + \alpha d^{(0)}) = f(1 - 2\alpha, 1 - 8\alpha) = (1 - 2\alpha)^2 + 4(1 - 8\alpha)^2$
求导： $\frac{d\phi}{d\alpha} = 2(1 - 2\alpha)(-2) + 8(1 - 8\alpha)(-8) = 520\alpha - 68$
令导数为0, 解得： $\alpha_0 = \frac{68}{520} \approx 0.13077$
- **更新迭代点 $x^{(1)}$ ：**
$$x^{(1)} = x^{(0)} + \alpha_0 d^{(0)} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + 0.13077 \begin{pmatrix} -2 \\ -8 \end{pmatrix} = \begin{pmatrix} 0.73846 \\ -0.04616 \end{pmatrix}$$
- **计算函数值：** $f(x^{(1)}) \approx 0.73846^2 + 4(-0.04616)^2 \approx 0.55385$

3. 第二步迭代 ($k = 1$)

- **计算梯度：** $\nabla f(x^{(1)}) = (2 \cdot 0.73846, 8 \cdot (-0.04616))^T = (1.47692, -0.36928)^T$
- **梯度模长：** $\|\nabla f(x^{(1)})\| \approx 1.52237$
- **确定搜索方向：** $d^{(1)} = -\nabla f(x^{(1)}) = (-1.47692, 0.36928)^T$
- **一维搜索求步长 α_1 ：**
重复上述过程, 通过令 $\frac{df(x^{(1)} + \alpha d^{(1)})}{d\alpha} = 0$, 解得： $\alpha_1 = 0.42500$
- **更新迭代点 $x^{(2)}$ ：**
$$x^{(2)} = x^{(1)} + \alpha_1 d^{(1)} = \begin{pmatrix} 0.73846 \\ -0.04616 \end{pmatrix} + 0.425 \begin{pmatrix} -1.47692 \\ 0.36928 \end{pmatrix} = \begin{pmatrix} 0.11076 \\ 0.11076 \end{pmatrix}$$
- **后续参数：**
 $\nabla f(x^{(2)}) = (2 \cdot 0.11076, 8 \cdot 0.11076)^T = (0.22152, 0.88608)^T$
 $\|\nabla f(x^{(2)})\| \approx 0.91335$
 $d^{(2)} = -\nabla f(x^{(2)}) = (-0.22152, -0.88608)^T$

4. 验证搜索方向的正交性

最速下降法的一个重要性质是：**相邻两次迭代的搜索方向是正交的。**

- **验证 $d^{(0)}$ 与 $d^{(1)}$ ：**
$$d^{(1)T} d^{(0)} = (-1.47692) \times (-2) + (0.36923) \times (-8) = 2.95384 - 2.95384 = 0$$
- **验证 $d^{(1)}$ 与 $d^{(2)}$ ：**
$$d^{(2)T} d^{(1)} = (-0.22152) \times (-1.47692) + (-0.88608) \times (0.36923) \approx 0.32717 - 0.32717 = 0$$

结论： 计算结果符合最速下降法的理论性质，即相邻下降方向正交，搜索路径呈“之”字形。